

# Kapitel 14

## Parameterschätzung

### Modell

Es sei  $\{P_\theta | \theta \in \Theta\}$ ,  $\Theta \subset \mathbb{R}^m$  eine Familie von Verteilungen auf  $\chi$  (sog. Stichprobenraum),  $x = (x_1, \dots, x_n)$  sei eine Realisierung der Zufallsstichprobe  $X = (X_1, \dots, X_n)$  zu einer Verteilung  $P \in \{P_\theta | \theta \in \Theta\}$ , wobei der wahre Parameter  $\theta$  unbekannt ist.

### Problem

Schätze unbekanntes  $\theta$  aus der konkreten Realisierung von  $X$ .

### Definition 14.1

Seien  $X_1, \dots, X_n$  unabhängig und identisch verteilte Zufallsvariablen mit Verteilung  $P$ .

Dann heißt der Zufallsvektor  $(X_1, \dots, X_n)$  **Zufallsstichprobe zur Verteilung  $P$** . Eine Realisierung  $(x_1, \dots, x_n)$  von  $(X_1, \dots, X_n)$  nennt man **Stichprobe**.

### Beispiel 14.1

Gegeben sei ein Würfel, den wir  $n$ -mal werfen dürfen. Aus der Beobachtung ist die Wahrscheinlichkeit zu schätzen eine 6 zu würfeln.

Modell:  $\chi = \{0, 1\}$ :  $0 \hat{=}$  keine 6 gewürfelt,  $1 \hat{=}$  6 gewürfelt.

$P_\theta = B(1, \theta)$ ,  $\Theta = [0, 1]$

**Definition 14.2** Eine messbare Abbildung  $T : \chi^n \rightarrow \tilde{\Theta}$ ,  $\tilde{\Theta} \supset \Theta$ , heißt **Schätzer** für  $\theta$ .

**Beispiel 14.2** a) Die Statistik  $\bar{X} = \frac{1}{n}(X_1 + \dots + X_n)$  heißt **Stichprobenmittel**

b) Die Statistik  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$  heißt **Stichprobenvarianz**

### Beispiel 14.3 (Schätzung eines Fischbestandes)

Teich enthält unbekannte Zahl  $N = \theta$  von Fischen

$r$  Fische werden gefangen, (rot) markiert und wieder ausgesetzt.

In einem zweiten Zug werden  $m$  Fische gefangen  $x$  davon seien markiert.

Wie groß ist  $N$ ?

### Modell

Urne mit  $N = \theta$  Kugeln,  $r$  rot,  $N - r =: s$  schwarz  
 $m$  Kugeln werden ohne Zurücklegen gezogen. Die Zufallsvariable  $X$  beschreibe die Anzahl der roten unter den gezogenen Kugeln.

**Also**

$\chi = \mathbb{N}_0$ ,  $P_\theta \sim \text{Hypergeom.}(\theta, r, m)$ ,  $\Theta = \mathbb{N}$ . Beachte:  $n = 1$

## 14.1 Maximum-Likelihood-Methode

**Idee:**

Wir wählen für  $\theta$  den Wert, unter dem die Wahrscheinlichkeit, dass die konkrete Stichprobe vorliegt maximiert wird.

Im folgenden sei  $P_\theta$  diskret mit Zähldichte  $p(x; \theta)$  oder stetig mit Dichte  $f(x; \theta)$

### Definition 14.3

Gegeben sei eine Stichprobe  $x = (x_1, \dots, x_n)$ . Dann heißt die Funktion

$$L_x(\theta) := f(x_1; \theta) \cdots f(x_n; \theta) \quad \text{bzw.} \quad L_x(\theta) := \underbrace{p(x_1; \theta) \cdots p(x_n; \theta)}_{P_\theta(X_1, \dots, X_n) = (x_1, \dots, x_n)}$$

die **Likelihood-Funktion** der Stichprobe.

Eine Funktion  $\hat{\theta}_{\text{ML}}(x)$  heißt **Maximum-Likelihood Schätzer (MLS)**, falls

$$L_x(\hat{\theta}_{\text{ML}}(x)) = \sup_{\theta \in \Theta} L_x(\theta)$$

### Bemerkung 14.1

a) Ist  $P_\theta$  diskret, so gilt:

$$L_X(\theta) = p(x_1; \theta) \cdots p(x_n; \theta) = P_\theta(X_1 = x_1) \cdots P_\theta(X_n = x_n) \stackrel{X \text{ unabhängig}}{=} P_\theta(X = x)$$

b) Der MLS  $\hat{\theta}_{\text{ML}}(x)$  ist nicht immer eindeutig.

### Beispiel 14.4 (vgl. Beispiel 14.3)

$n = 1$

$$\text{Likelihood-Funktion: } L_x(\theta) = \frac{\binom{r}{x} \binom{\theta-r}{k-x}}{\binom{\theta}{k}}$$

Für welches  $\theta$  ist  $L_x(\theta)$  maximal?

Betrachte:

$$\frac{L_x(\theta)}{L_x(\theta-1)} = \frac{\binom{r}{x} \binom{\theta-r}{m-x} \binom{\theta-1}{m}}{\binom{\theta}{m} \binom{r}{x} \binom{\theta-1-r}{m-x}} = \frac{(\theta-r)(\theta-m)}{\theta(\theta-r-m+x)}$$

$$L_x(\theta) > L_x(\theta-1) \Leftrightarrow (\theta-r)(\theta-m) > \theta(\theta-r-m+x) \Leftrightarrow mr > \theta x \Leftrightarrow \theta < \frac{mr}{x}$$

Also ist  $L_x(\theta)$  maximal für  $\hat{\theta}(x) = \lfloor \frac{mr}{x} \rfloor$

$\hat{\theta}(x)$  ist eindeutig, falls  $\frac{mr}{x} \notin \mathbb{N}$

Falls  $\frac{mr}{x} \in \mathbb{N}$  sind  $\hat{\theta}_1(x) = \frac{mr}{x}$  und  $\hat{\theta}_2(x) = \frac{mr}{x} - 1$  MLS

**Beispiel 14.5 (Schätzung einer Erfolgswahrscheinlichkeit)**

Aus  $n$  Bernoulli-Experimenten liegen  $x$  Erfolge vor, gesucht ist die Erfolgswahrscheinlichkeit:

Modell:  $\chi = \mathbb{N}$ ,  $n = 1$ ,  $P_\theta = B(m, \theta)$ ,  $\Theta = (0, 1)$ .

$$\text{Likelihood-Funktion: } L_x(\theta) = \binom{m}{x} \theta^x (1 - \theta)^{m-x}, \theta \in [0, 1]$$

Statt  $L_x(\theta)$  ist es oft einfacher,  $\log(L_x(\theta))$  zu maximieren, die sogenannte **Log-Likelihoodfunktion**

$$\log(L_x(\theta)) = \log \binom{m}{x} + x \log \theta + (m - x) \log(1 - \theta)$$

$$\frac{\partial}{\partial \theta} \log(L_x(\theta)) = \frac{x}{\theta} - \frac{(m - x)}{1 - \theta} = 0 \quad \Leftrightarrow \quad \theta = \frac{x}{m}$$

$\theta$  ist tatsächlich Maximum-Stelle, dass heißt  $\hat{\theta}_{\text{ML}}(x) = \frac{x}{m}$

**14.2 Momentenmethode****Idee:**

Die ersten Momente von  $P_\theta$  sollten mit den empirischen Momenten übereinstimmen. Aus diesen Gleichungssystemen bestimmen wir den Schätzer.

Es sei  $X \sim P_\theta$ . Dann ist das  $k$ -te Moment

$$\mu_k = \mu_k(\theta) = E_\theta X^k, \quad k = 1, 2, \dots$$

Wir betrachten nun die **empirischen Momente** zur Stichprobe  $x = (x_1, \dots, x_n)$ .

$$\overline{x_k} := \frac{1}{n} \sum_{i=1}^n x_i^k$$

Es soll nun gelten:  $\mu_k(\theta) = \overline{x_k} \quad k = 1, 2, \dots, m$ . Aufgelöst nach  $\theta$  ergibt sich dann der Momentenschätzer  $\hat{\theta}_{\text{MM}}(x) \in \Theta$ .

**Beispiel 14.6**

$P_\theta = N(\mu, \sigma^2)$ ,  $\theta = (\mu, \sigma^2)$ ,  $m = 2$

$$(1) \quad \mu_1 = \mu = E_\theta X = \overline{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$(2) \quad \mu_2 = E_\theta X^2 = \text{Var}_\theta(X) + (E_\theta X)^2 = \sigma^2 + \mu^2 = \frac{1}{n} \sum_{i=1}^n x_i^2$$

Aus (1) folgt:  $\hat{\mu}(x) = \frac{1}{n} \sum_{i=1}^n x_i = \overline{x}$

Aus (2) folgt:  $\hat{\sigma}^2(x) = \frac{1}{n} \sum_{i=1}^n x_i^2 - (\overline{x})^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \overline{x})^2$

### 14.3 Wünschenswerte Eigenschaften von Punktschätzern

Im folgenden sei  $X = (X_1, \dots, X_n)$  eine Zufallsstichprobe zur Verteilung  $P_\theta$  und  $T: \chi \rightarrow \tilde{\Theta}$  ein Schätzer von  $\theta$ . Mit  $E_\theta$  bezeichnen wir den Erwartungswert bezüglich  $P_\theta$ .

#### Definition 14.4

a) Der Schätzer  $T$  heißt **erwartungstreu** (unbiased), falls

$$E_\theta T(X_1, \dots, X_n) = \theta \quad \forall \theta \in \Theta$$

b)  $b_T(\theta) := E_\theta T(X_1, \dots, X_n) - \theta$  heißt **Verzerrung** (Bias) des Schätzers  $T$ . Ein erwartungstreuer Schätzer ist unverzerrt.

#### Beispiel 14.7 (vgl. Bsp.14.6)

- $T(x) = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$  ist ein erwartungstreuer Schätzer für  $\theta = E_\theta X_i$ , denn  $E_\theta(T(X)) = E_\theta\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E_\theta X_i = \theta$
- Ein erwartungstreuer Schätzer für  $\theta = \text{Var}_\theta(X_i)$  ist  $[S^2(x) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2]$

#### Definition 14.5

Sei  $T$  ein Schätzer für  $\theta$ . Dann heißt

$$\text{MSE}(T) := E_\theta[(T(X_1, \dots, X_n) - \theta)^2]$$

(mittlerer) **quadratischer Fehler** ("mean-squared-error")

#### Beispiel 14.8

Sei  $P_\theta = U(0, \theta)$ ,  $\Theta = \mathbb{R}$ ,  $\chi = \mathbb{R}_+$  und  $X = (X_1, \dots, X_n)$  eine Zufallsstichprobe zur Verteilung  $U(0, \theta)$

**Momentenmethode:**  $\bar{x} = E_\theta X_i = \frac{\theta}{2} \Rightarrow \hat{\theta}_{\text{MM}} = 2 \cdot \bar{x}$

**Maximum-Likelihood-Methode:**

$$f(x, \theta) = \begin{cases} \frac{1}{\theta}, & 0 \leq x \leq \theta \\ 0, & \text{sonst} \end{cases}$$

$$\Rightarrow L_x(\theta) = L_{(x_1, \dots, x_n)}(\theta) = f(x_1; \theta) \cdot \dots \cdot f(x_n; \theta) = \begin{cases} \frac{1}{\theta^n}, & 0 \leq x_1, \dots, x_n \leq \theta \\ 0, & \text{sonst} \end{cases}$$

Maximiere  $L_x(\theta)$  in  $\theta$ :  $\hat{\theta}_{\text{ML}}(x) = \max(x_1, \dots, x_n)$

Welcher Schätzer ist besser?

$$E_\theta[\hat{\theta}_{\text{MM}}(X)] = 2E_\theta \bar{X} = \theta, \text{ also ist } \hat{\theta}_{\text{MM}} \text{ erwartungstreu}$$

Verteilungsfunktion von  $\hat{\theta}_{\text{ML}}(X)$  ist

$$F_\theta(x) = P_\theta(\max(X_1, \dots, X_n) \leq x) = P_\theta(X_1 \leq x, \dots, X_n \leq x)$$

$$= P_\theta(X_1 \leq x) \cdots P_\theta(X_n \leq x) = \left(\frac{x}{\theta}\right)^n, \text{ falls } 0 \leq x \leq \theta$$

Also Dichte von  $\hat{\theta}_{\text{ML}}(X)$ :

$$f_{\hat{\theta}_{\text{ML}}}(x) = \begin{cases} \frac{n}{\theta} \left(\frac{x}{\theta}\right)^{n-1} & , \text{ falls } 0 \leq x \leq \theta \\ 0 & , \text{ sonst} \end{cases}$$

und

$$E_\theta[\hat{\theta}_{\text{ML}}(X)] = \int_0^\theta x f_{\hat{\theta}_{\text{ML}}}(x) dx = \int_0^\theta n \left(\frac{x}{\theta}\right)^n dx = \frac{n}{n+1} \theta$$

also nicht erwartungstreu.

Aber:

$$\text{MSE}(\hat{\theta}_{\text{MM}}(X)) = E_\theta \left( \left[ 2 \frac{1}{n} \sum_{i=1}^n X_i - \theta \right]^2 \right) = \frac{\theta^2}{3n}$$

$$\text{MSE}(\hat{\theta}_{\text{ML}}(X)) = E_\theta([\max(X_1, \dots, X_n) - \theta]^2) = \frac{2\theta^2}{(n+2)(n+1)}$$

$$\frac{\text{MSE}(\hat{\theta}_{\text{MM}}(X))}{\text{MSE}(\hat{\theta}_{\text{ML}}(X))} = \frac{2}{3} \frac{n}{(n+2)(n+1)} \quad \text{relative Effizienz}$$

Bei großem  $n$  ist  $\text{MSE}(\hat{\theta}_{\text{ML}}(X))$  kleiner als  $\text{MSE}(\hat{\theta}_{\text{MM}}(X))$ .

#### Bemerkung 14.2

Falls  $T$  erwartungstreu ist, gilt  $\text{MSE}(T) = \text{Var}_\theta(T)$

Für  $\text{Var}_\theta(T)$  kann man die folgende untere Abschätzung angeben.

#### Satz 14.1 (Ungleichung von Rao-Cramér)

Sei  $X = (X_1, \dots, X_n)$  eine Zufallsstichprobe zur Verteilung  $P_\theta$ .  $T$  sei ein Schätzer für  $\theta$ . Dann gilt:

$$\text{Var}_\theta(T(X)) \geq \frac{(1 + \frac{\partial}{\partial \theta} b_T(\theta))^2}{E_\theta[(\frac{\partial}{\partial \theta} \log L_X(\theta))^2]}$$

#### Bemerkung 14.3

(i)  $I(\theta) := E_\theta[(\frac{\partial}{\partial \theta} \log L_X(\theta))^2]$  heißt **Fisher-Information**

(ii) Ist  $T$  erwartungstreu, so ist  $b_T(\theta) = 0$  und  $\text{Var}_\theta(T(X)) \geq \frac{1}{I(\theta)}$

#### Beweis

Wir nehmen an, dass  $L_x(\theta) > 0 \forall x \in \chi^n \forall \theta \in \Theta$ ,  $\Theta$  sei ein offenes Intervall in  $\mathbb{R}$  und  $P_\theta$  sei diskret. Es gilt:

$$\frac{\partial}{\partial \theta} \log L_x(\theta) = \frac{L'_x(\theta)}{L_x(\theta)}$$

Weiter gilt:

$$(1) \sum_{x \in \chi^n} L_x(\theta) = \sum_{x \in \chi^n} P_\theta(X = x) = 1$$

$$(2) \theta + b_T(\theta) = E_\theta T(X) = \sum_{x \in \chi^n} T(x) \cdot L_x(\theta)$$

Wir differenzieren (1) und (2) nach  $\theta$ , und nehmen an, dass wir  $\frac{\partial}{\partial \theta}$  und  $\sum$  vertauschen könne.

(1')

$$0 = \sum_{x \in \chi^n} L'_x(\theta) = \sum_{x \in \chi^n} \frac{\partial}{\partial \theta} \log(L_x(\theta)) \cdot L_x(\theta) = E_\theta \left[ \frac{\partial}{\partial \theta} \log L_X(\theta) \right]$$

(2')

$$1 + b'_T(\theta) = \sum_{x \in \chi^n} T(x) L'_x(\theta)$$

$$\sum_{x \in \chi^n} T(x) \frac{\partial}{\partial \theta} \log(L_x(\theta)) \cdot L_x(\theta) = E_\theta \left[ T(X) \cdot \frac{\partial}{\partial \theta} \log L_X(\theta) \right]$$

(2') - (1')  $E_\theta T(X)$

$$1 + b'_T(\theta) = E_\theta [(T(X) - E_\theta T(X)) \frac{\partial}{\partial \theta} \log L_X(\theta)]$$

Mit der Ungleichung von Cauchy-Schwarz folgt:

$$\begin{aligned} (1 + b'_T(\theta))^2 &= \left( E_\theta [(T(X) - E_\theta T(X)) \frac{\partial}{\partial \theta} \log L_X(\theta)] \right)^2 \\ &\leq E_\theta [(T(X) - E_\theta T(X))^2] \cdot E_\theta \left[ \frac{\partial}{\partial \theta} \log L_X(\theta)^2 \right] = \text{Var}_\theta T \cdot I(\theta) \end{aligned}$$