

Stochastik II

Prof. Dr. Bäuerle

Im Wintersemester 06/07

Das Team von <http://mitschriebwiki.nomeata.de/>

Dieses Dokument ist eine persönliche Vorlesungsmitschrift der
Vorlesung Stochastik II im Wintersemester 2006/07 bei Prof. Dr. Bäuerle.

Das latexki-Team gibt keine Garantie für die
Richtigkeit oder Vollständigkeit des Inhaltes und übernimmt keine
Verantwortung für etwaige Fehler.
Auch ist Frau Bäuerle nicht verantwortlich für den Inhalt dieses Skriptes.

Inhaltsverzeichnis

1	Maß-Integral und Erwartungswert	5
2	Eigenschaften des Maß-Integrals	15
2.1	Konvergenzsätze	15
2.2	Verhalten bei Transformationen	16
2.3	Nullmengen und Maße mit Dichten	18
2.4	Ungleichungen und Räume integrierbarer Funktionen	21
3	Produktmaße und Unabhängigkeit	25
3.1	Der allgemeine Fall	25
3.2	Reellwertige Abbildungen, Rechnen mit Verteilungen	32
4	Das starke Gesetz der großen Zahlen	37
5	Zentraler Grenzwertsatz von Lindeberg-Lévy	41
5.1	Charakteristische Funktionen	41
5.2	Umkehrsätze	42
5.3	Verteilungskonvergenz	44
6	Zentraler Grenzwertsatz in \mathbb{R}^n	57
6.1	Mehrdimensionale Normalverteilung	58
6.2	Zentraler Grenzwertsatz in \mathbb{R}^d	59
7	Bedingte Erwartungswerte und Bedingte Verteilungen	61
8	Martingale und Stoppzeiten	71
9	Konvergenzsätze für Martingale	85

1 Maß-Integral und Erwartungswert

Stochastik I: Ein Wahrscheinlichkeitsraum (Ω, \mathcal{A}, P) bestehend aus:

- (i) $\Omega \neq \emptyset$ bel. Menge, der Ergebnisraum
- (ii) $\mathcal{A} \subset \mathcal{P}(\Omega)$ eine σ -Algebra, d.h.
 - $\Omega \in \mathcal{A}$
 - $A \in \mathcal{A} \implies A^c \in \mathcal{A}$
 - $A_1, A_2, \dots \in \mathcal{A} \implies \bigcup_{i=1}^{\infty} A_i \in \mathcal{A}$
- (iii) $P : \mathcal{A} \rightarrow [0, 1]$ ein Wahrscheinlichkeitsmaß, d.h.
 - $P(\Omega) = 1$
 - $A_1, A_2, \dots \in \mathcal{A}$, paarweise disjunkt $\implies P(\sum_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$
(σ -Additivität)

Statt das Wahrscheinlichkeitsmaßes P betrachten wir jetzt eine allgemeine Funktion $\mu : \mathcal{A} \rightarrow \mathbb{R}_+ \cup \{\infty\}$, die beliebige positive Werte annehmen kann.

Definition

Sei (Ω, \mathcal{A}) ein messbarer Raum. Eine Abbildung $\mu : \mathcal{A} \rightarrow \mathbb{R}_+ \cup \{\infty\}$ heißt **Maß** auf (Ω, \mathcal{A}) , wenn $\mu(\emptyset) = 0$ und $\mu(\sum_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} \mu(A_i)$ für alle paarweise disjunkten Ereignisse A_1, A_2, \dots , $(\Omega, \mathcal{A}, \mu)$ heißt **Maßraum**.

Bemerkung

Da $\mu(A) = \infty$ möglich, definieren wir: $a + \infty = \infty \forall a \in \mathbb{R} \cup \{\infty\}$.

Definition

Sei μ ein Maß auf (Ω, \mathcal{A}) .

1. μ heißt **endlich**, falls $\mu(\Omega) < \infty$,
2. μ heißt **σ -endlich**, falls \exists eine Folge $(A_i), i \in \mathbb{N}, A_i \in \mathcal{A}$ mit $\bigcup_{i=1}^{\infty} A_i = \Omega$ und $\mu(A_i) < \infty \forall i \in \mathbb{N}$.

Beispiel 1.1

- a) Sei (Ω, \mathcal{A}) ein messbarer Raum, $\omega \in \Omega$ fest.

$$\delta_{\omega}(A) := \begin{cases} 1, & \omega \in A \\ 0, & \text{sonst} \end{cases}$$

für $A \in \mathcal{A}$ definiert ein Maß.

δ_{ω} heißt **Einpunktmaß** oder **Dirac-Maß** im Punkt ω . Da $\delta_{\omega}(\Omega) = 1$ ist δ_{ω} sogar ein Wahrscheinlichkeitsmaß.

- b) $\mu := \sum_{\omega \in \Omega} \delta_\omega$ ist das **abzählende Maß** auf Ω .
 (Falls $|A| < \infty$: $\mu(A) = |A|$ Anzahl der Elemente in A .)
 μ ist endlich $\Leftrightarrow \Omega$ ist endlich,
 μ ist σ -endlich $\Leftrightarrow \Omega$ ist abzählbar.
- c) Sei $\Omega = \mathbb{R}$, $\mathcal{A} = \mathfrak{B}(\mathbb{R})$ Borelsche σ -Algebra.

$$\mathfrak{B}(\mathbb{R}) = \underbrace{\sigma(\{(a, b], -\infty < a < b < \infty\})}_{=: \varepsilon \text{ Erzeuger}} = \sigma(\varepsilon) := \bigcap_{\mathcal{A} \text{ } \sigma\text{-Algebra, } \varepsilon \subset \mathcal{A}} \mathcal{A}$$

Sei $a, b \in \mathbb{R}$ mit $a < b$. Durch $\lambda((a, b]) := b - a$ wird auf $(\mathbb{R}, \mathfrak{B}(\mathbb{R}))$ ein Maß definiert, das sogenannte **Lebesgue-Maß**. Die Eindeutigkeit von λ folgt aus dem **Eindeutigkeitssatz für Maße**:

Sei $\mathcal{A} = \sigma(\varepsilon)$ und ε durchschnittsstabil (d.h.: $A, B \in \varepsilon \implies A \cap B \in \varepsilon$). Weiter seien μ_1, μ_2 Maße auf \mathcal{A} mit $\mu_1(A) = \mu_2(A) \forall A \in \varepsilon$. \exists eine Folge $(A_n)_{n \in \mathbb{N}} \subset \varepsilon$ mit $A_n \uparrow \Omega$ und $\mu_1(A_n) = \mu_2(A_n) < \infty \forall n$, so gilt $\mu_1 = \mu_2$.

Eine nichttriviale Aufgabe ist es hier zu zeigen, dass λ auf ganz $\mathfrak{B}(\mathbb{R})$ zu einem Maß fortgesetzt werden kann. (gezeigt von Carathéodory; s. z.B. Henze, Bauer)

Bei $\Omega = \bar{\mathbb{R}} = \mathbb{R} \cup \{\infty, -\infty\}$, ist $\mathfrak{B}(\bar{\mathbb{R}}) := \{B \subset \bar{\mathbb{R}} \mid B \cap \mathbb{R} \in \mathfrak{B}(\mathbb{R})\} = \{B, B \cup \{\infty\}, B \cup \{-\infty\}, B \cup \{\infty, -\infty\} \mid B \in \mathfrak{B}(\mathbb{R})\}$ eine σ -Algebra (analog $\mathfrak{B}((-\infty, \infty))$) und $\bar{\lambda}(B) = \lambda(B) \forall B \in \mathfrak{B}(\mathbb{R})$ und $\bar{\lambda}(\{\infty\}) = \bar{\lambda}(\{-\infty\}) = 0$

λ ist nicht endlich, da $\lambda((-\infty, a]) = \sum_{n=1}^{\infty} \underbrace{\lambda((a-n, a-n+1])}_{=1} = \infty$, aber

σ -endlich, da $\bigcup_{n=1}^{\infty} (-n, n] = \mathbb{R}$, $\lambda((-n, n]) < \infty \forall n \in \mathbb{N}$.

- d) Seien μ_n Maße, $n \in \mathbb{N}$, so ist

$$\mu := \sum_{n=1}^{\infty} b_n \mu_n$$

wieder ein Maß.

Konvention: $a \cdot \infty = \infty \cdot a = \infty, a > 0, 0 \cdot \infty = 0$

Spezialfall: $\mu_n = \delta_{\omega_n} (\omega_n \in \Omega), b \geq 0, \sum_{n=1}^{\infty} b_n = 1$

$$\mu = \sum_{n=1}^{\infty} b_n \delta_{\omega_n}$$

ist dann ein diskretes, auf $\{\omega_1, \omega_2, \dots\}$ konzentriertes Wahrscheinlichkeitsmaß.

- e) Sei $G : \mathbb{R} \rightarrow \mathbb{R}$ wachsend und rechtsseitig stetig (Eine Funktion mit diesen Eigenschaften heißt **maßdefinierende Funktion**. Gilt zusätzlich $\lim_{x \rightarrow \infty} G(x) = 1, \lim_{x \rightarrow -\infty} G(x) = 0$, dann ist G eine Verteilungsfunktion.)

$$\mu_G((a, b]) := G(b) - G(a)$$

für $a, b \in \mathbb{R}, a < b$ definiert μ_G ein Maß auf $(\mathbb{R}, \mathfrak{B}(\mathbb{R}))$, das sogenannte **Lebesgue-Stieltjes-Maß** zu G . (Fortsetzungsproblem analog zu c))

Ist G eine Verteilungsfunktion mit $G(x) = \int_{-\infty}^x f(y)dy$ mit

$$f \geq 0 : \int_{-\infty}^{\infty} f(y)dy = 1,$$

so ist $\mu_G((a, b]) = \int_a^b f(y)dy$ ein Wahrscheinlichkeitsmaß mit Dichte f .

Bemerkung

Viele der in Stochastik I für Wahrscheinlichkeitsmaße besprochene Eigenschaften gelten auch für allgemeine Maße μ , z.B. μ ist stetig von unten, d.h.

$$\underbrace{A_n \uparrow}_{A_n \subset A_{n+1}} \text{ mit } \bigcup_{i=1}^{\infty} A_i = A \implies \mu(A) = \lim_{n \rightarrow \infty} \mu(A_n)$$

Bei der Stetigkeit von oben brauchen wir eine Zusatzbedingung:

$$\underbrace{A_n \downarrow}_{A_n \supset A_{n+1}} \text{ mit } \bigcap_{k=1}^{\infty} A_k = A, \underline{\mu(A_n) < \infty} \implies \mu(A) = \lim_{n \rightarrow \infty} \mu(A_n)$$

Beispiel

Lebesgue-Maß: $A_n = (-\infty, -n] \downarrow, \emptyset = \bigcap_{n=1}^{\infty} (-\infty, -n], \lim_{n \rightarrow \infty} \lambda((-\infty, -n]) = \infty \neq 0 = \lambda(\emptyset)$

Definition

Seien (Ω, \mathcal{A}) und (Ω', \mathcal{A}') zwei meßbare Räume. Eine Abbildung $f : \Omega \rightarrow \Omega'$ heißt $(\mathcal{A}, \mathcal{A}')$ -**messbar**, falls

$$f^{-1}(A') \in \mathcal{A}, \quad \forall A' \in \mathcal{A}'$$

f mit dieser Eigenschaft heißt **Zufallsgröße**. Ist $\Omega' = \mathbb{R}$, dann **Zufallsvariable**.

Im Folgenden sei $(\Omega, \mathcal{A}, \mu)$ ein Maßraum. Ziel ist es, möglichst vielen Funktionen $f : \Omega \rightarrow \mathbb{R}$ ein Integral bezüglich μ zuzuordnen. Die Konstruktion erfolgt in drei Schritten:

- 1.) Sei $\mathcal{E} := \{f : \Omega \rightarrow \mathbb{R} | f \geq 0, f \text{ ist } \mathcal{A}\text{-messbar}, f(\Omega) \text{ endlich}\}$ die Menge der **Elementarfunktionen** auf Ω .

Ist $f(\Omega) = \{\alpha_1, \dots, \alpha_n\}, \alpha_j \geq 0$, so gilt:

$$f = \sum_{j=1}^n \alpha_j \mathbf{1}_{A_j}$$

mit $A_j := f^{-1}(\{\alpha_j\})$ und $\Omega = \sum_{j=1}^n A_j$. Eine Darstellung von f mit dieser Eigenschaft heißt „Normaldarstellung“ von f .

Normaldarstellung ist nicht eindeutig.

Definition

Ist f eine Elementarfunktion mit Normaldarstellung $f = \sum_{j=1}^n \alpha_j \mathbf{1}_{A_j}$, so heißt $\int f d\mu := \sum_{j=1}^n \alpha_j \mu(A_j)$ das **μ -Integral** von f . Schreibweise $\int f d\mu = \mu(f)$.

Lemma 1.1 (Unabhängigkeit des Integrals von der Normaldarstellung)

Für zwei Normaldarstellungen

$$f = \sum_{j=1}^n \alpha_j \mathbf{1}_{A_j} = \sum_{i=1}^m \beta_i \mathbf{1}_{B_i}$$

einer Funktion $f \in \mathcal{E}$ gilt:

$$\sum_{j=1}^n \alpha_j \mu(A_j) = \sum_{i=1}^m \beta_i \mu(B_i)$$

Beweis

$$\text{Voraussetzung} \implies \Omega = \sum_{j=1}^n A_j = \sum_{i=1}^m B_i$$

$$\begin{aligned} \implies \mu(A_j) &\stackrel{\sigma\text{-Add.}}{=} \sum_{i=1}^m \mu(A_j \cap B_i) \\ \mu(B_i) &= \sum_{j=1}^n \mu(A_j \cap B_i) \end{aligned}$$

$$\mu(A_j \cap B_i) \neq 0 \implies A_j \cap B_i \neq \emptyset \implies \alpha_j = \beta_i$$

Insgesamt:

$$\begin{aligned} \sum_{j=1}^n \alpha_j \mu(A_j) &= \sum_{j=1}^n \sum_{i=1}^m \underbrace{\alpha_j}_{\beta_i} \mu(A_j \cap B_i) \\ &= \sum_{i=1}^m \beta_i \mu(B_i) \end{aligned} \quad \blacksquare$$

Lemma 1.2 (Eigenschaften des μ -Integrals)

- a) $\int \mathbf{1}_A d\mu = \mu(A)$ für $A \in \mathcal{A}$
- b) $\int (\alpha f) d\mu = \alpha \int f d\mu$ für $f \in \mathcal{E}, \alpha \geq 0$
- c) $\int (f + g) d\mu = \int f d\mu + \int g d\mu$ für $f, g \in \mathcal{E}$
- d) $f \leq g \implies \int f d\mu \leq \int g d\mu$ für $f, g \in \mathcal{E}$

Beweis

a), b) klar

c) Sei $f = \sum_{j=1}^n \alpha_j \mathbf{1}_{A_j}$, $g = \sum_{i=1}^m \beta_i \mathbf{1}_{B_i}$

$$\begin{aligned}
 \Rightarrow f &= \sum_{j=1}^n \sum_{i=1}^m \alpha_j \mathbf{1}_{A_j \cap B_i} \\
 g &= \sum_{i=1}^m \sum_{j=1}^n \beta_i \mathbf{1}_{B_i \cap A_j} \\
 \text{also } f + g &= \sum_{j=1}^n \sum_{i=1}^m (\alpha_j + \beta_i) \mathbf{1}_{A_j \cap B_i} \\
 \Rightarrow \mu(f + g) &= \sum_{j=1}^n \sum_{i=1}^m (\alpha_j + \beta_i) \mu(A_j \cap B_i) \\
 &= \sum_{j=1}^n \alpha_j \sum_{i=1}^m \mu(A_j \cap B_i) + \sum_{i=1}^m \beta_i \underbrace{\sum_{j=1}^n \mu(A_j \cap B_i)}_{=\mu(B_i)} \\
 &= \mu(f) + \mu(g)
 \end{aligned}$$

d) folgt mit gleicher Darstellung wie in c) ■

Bemerkung

- a) Ist $f = \sum_{j=1}^n \alpha_j \mathbf{1}_{A_j} \in \mathcal{E}$, aber nicht notwendig eine Normaldarstellung, so folgt aus Lemma 1.2 c) $\int f d\mu = \sum_{j=1}^n \alpha_j \mu(A_j)$
- b) Ist (Ω, \mathcal{A}, P) ein Wahrscheinlichkeitsraum und $X : \Omega \rightarrow \mathbb{R}_+$ eine Zufallsvariable mit endlich vielen Werten $\{x_1, \dots, x_n\}$, so gilt:

$$\begin{aligned}
 \int X dP &= \sum_{j=1}^n x_j P(X^{-1}(\{x_j\})) \\
 &= \sum_{j=1}^n x_j P^X(\{x_j\})
 \end{aligned}$$

$$\begin{aligned}
 (A_j &= X^{-1}(\{x_j\})) \\
 \text{Also: } \int X dP &= EX
 \end{aligned}$$

- 2.) Sei $\mathcal{E}^+ := \{f : \Omega \rightarrow \bar{\mathbb{R}} \mid f \geq 0, f \text{ ist } \mathcal{A}\text{-messbar}\}$. Wichtig: Elemente von \mathcal{E}^+ kann man beliebig gut durch Elemente aus \mathcal{E} approximieren.

Satz 1.1

Zu jedem $f \in \mathcal{E}^+$ gibt es eine wachsende Folge $(u_n)_{n \in \mathbb{N}}$ aus \mathcal{E} mit $u_n \uparrow f$, d.h. $u_n \leq u_{n+1}$ und $\lim_{n \rightarrow \infty} u_n = f$ (jeweils punktweise).

Beweis

Sei $\alpha_n : \mathbb{R} \rightarrow [0, \infty]$ gegeben durch:

$$\alpha_n(x) := \begin{cases} 0, & \text{falls } x < 0 \\ \frac{j}{2^n}, & \text{falls } \frac{j}{2^n} \leq x < \frac{j+1}{2^n}, j = 0, 1, \dots, n2^n - 1 \\ n, & \text{falls } x \geq n \end{cases}$$

(Hier fehlt ein Bild)

α_n ist \mathfrak{B} -messbar. $\alpha_n \uparrow$ und $\lim_{n \rightarrow \infty} \alpha_n(x) = x$ für $n \rightarrow \infty$. Sei $u_n := \alpha_n \circ f$. Dann gilt $u_n \in \mathcal{E}$ und $u_n \uparrow f$. ■

Bemerkung

Ist f beschränkt, so konvergiert die Folge (u_n) gleichmäßig gegen f , d.h. $\lim_{n \rightarrow \infty} \sup_{\omega \in \Omega} |f(\omega) - u_n(\omega)| = 0$.

Definition

Sei $f \in \mathcal{E}^+$ und (u_n) eine wachsende Folge aus \mathcal{E} mit $\lim_{n \rightarrow \infty} u_n = f$. Dann heißt

$$\int f d\mu := \lim_{n \rightarrow \infty} \int u_n d\mu$$

das μ -Integral von f . Wir zeigen, dass $\int f d\mu$ wohldefiniert ist.

Lemma 1.3

Sind (u_n) und (v_n) wachsende Folgen aus \mathcal{E} mit $\lim_{n \rightarrow \infty} u_n = \lim_{n \rightarrow \infty} v_n$, so gilt:

$$\lim_{n \rightarrow \infty} \int u_n d\mu = \lim_{n \rightarrow \infty} \int v_n d\mu$$

Beweis

Wir zeigen zunächst: $\lim_{n \rightarrow \infty} u_n \geq v$ mit $v \in \mathcal{E} \implies \mu(v) \leq \lim_{n \rightarrow \infty} \mu(u_n)$

Denn: Sei $v = \sum_{j=1}^m \alpha_j \mathbf{1}_{A_j}$ ($\alpha_j \geq 0, A_j \in \mathcal{A}$) und $0 < c < 1$ beliebig. Sei $B_n := \{\omega | u_n(\omega) \geq cv(\omega)\} \in \mathcal{A}$. Da $u_n \geq cv \mathbf{1}_{B_n}$ folgt:

$$\mu(u_n) \geq c\mu(v \mathbf{1}_{B_n}) \quad (*)$$

Nach Voraussetzung: $v \leq \lim_{n \rightarrow \infty} u_n, u_n \uparrow \implies B_n \uparrow \Omega, A_j \cap B_n \uparrow A_j$

$$\begin{aligned} \implies \mu(v) &= \sum_{j=1}^m \alpha_j \mu(A_j) = \lim_{n \rightarrow \infty} \sum_{j=1}^m \alpha_j \mu(A_j \cap B_n) \\ &= \lim_{n \rightarrow \infty} \mu(v \mathbf{1}_{B_n}) \end{aligned}$$

Nehme $\lim_{n \rightarrow \infty}$ in $(*)$: $\lim_{n \rightarrow \infty} \mu(u_n) \geq c\mu(v)$. Da $c < 1$ beliebig war, folgt die Behauptung.

Jetzt zur eigentlichen Aussage: Es gilt: $v_k \leq \lim_{n \rightarrow \infty} u_n, u_k \leq \lim_{n \rightarrow \infty} v_n \xrightarrow{\text{Hilfsaussage}} \mu(v_k) \leq \lim_{n \rightarrow \infty} \mu(u_n), \mu(u_k) \leq \lim_{n \rightarrow \infty} \mu(v_n), \forall k \in \mathbb{N}$.

$\lim_{k \rightarrow \infty}$ bei beiden Ungleichungen \implies Behauptung. ■

Bemerkung

- a) Die letzten beiden Definitionen sind verträglich
 - b) Die Eigenschaften von Lemma 1.2 gelten weiter.
- 3.) $f : \Omega \rightarrow \bar{\mathbb{R}}$ ist \mathcal{A} -messbar (ohne Vorzeichenbeschränkung). $f^+ := \max\{0, f\}$, $f^- := -\min\{0, f\}$, $f = f^+ - f^-$, $|f| = f^+ + f^-$

Definition

Eine \mathcal{A} -messbare Funktion $f : \Omega \rightarrow \bar{\mathbb{R}}$ heißt μ -integrierbar, falls $\int f^+ d\mu < \infty$, $\int f^- d\mu < \infty$. In diesem Fall heißt $\int f d\mu = \mu(f) = \int f^+ d\mu - \int f^- d\mu$ das **μ -Integral von f** .

Schreibweise: $\int f d\mu = \int f(\omega) \mu(d\omega) = \int_{\Omega} f d\mu$; $\int_A f d\mu := \int f \cdot \mathbf{1}_A d\mu$

Bemerkung a) Die letzten beiden Definitionen sind verträglich

- b) Falls mindestens einer der Werte $\int f^+ d\mu$, $\int f^- d\mu$ endlich ist, so heißt f **quasi-integrierbar**.
- c) Ist (Ω, \mathcal{A}, P) ein Wahrscheinlichkeitsraum, $X : \Omega \rightarrow \mathbb{R}$ eine Zufallsvariable, so gilt: EX existiert $\iff X$ ist P -integrierbar. In diesem Fall: $EX = \int X dP$
- d) Offenbar gilt: f ist integrierbar $\iff |f|$ ist integrierbar

Satz 1.2 (Eigenschaften des μ -Integrals)

Es seien $f, g : \Omega \rightarrow \bar{\mathbb{R}}$ μ -integrierbar und $c \in \mathbb{R}$. Dann gilt:

- a) cf und $f + g$ sind μ -integrierbar und

$$\begin{aligned} \int cf d\mu &= c \int f d\mu \\ \int (f + g) d\mu &= \int f d\mu + \int g d\mu \end{aligned}$$

- b) $f \leq g \implies \int f d\mu \leq \int g d\mu$

- c) $|\int f d\mu| \leq \int |f| d\mu$

Beweis a) α) Sei $c \geq 0$ (analog $c \leq 0$): $(cf)^+ = cf^+$, $(cf)^- = cf^-$

Also ist cf integrierbar: $\xrightarrow{\text{Satz 1.1}} \exists u_n^+ \uparrow f^+, u_n^+ \in \mathcal{E}$

$$\begin{aligned} \int cf^+ d\mu &= \lim_{n \rightarrow \infty} \int cu_n^+ d\mu \\ &= c \lim_{n \rightarrow \infty} \int u_n^+ d\mu \\ &= c \int f^+ d\mu \end{aligned}$$

Analog f^- .

$\beta)$ $|f + g| \leq |f| + |g| \implies f + g$ μ -integrierbar.

Sei zunächst $f, g \in \mathcal{E}^+ \xrightarrow{\text{Satz 1.1}} \exists u_n \uparrow f, v_n \uparrow g, u_n, v_n \in \mathcal{E} \implies u_n + v_n \uparrow f + g, u_n + v_n \in \mathcal{E}$

Mit Lemma 1.2 folgt:

$$\begin{aligned} \int (f + g) d\mu &= \lim_{n \rightarrow \infty} \int (u_n + v_n) d\mu \\ &= \lim_{n \rightarrow \infty} \left(\int u_n d\mu + \int v_n d\mu \right) \\ &= \lim_{n \rightarrow \infty} \int u_n d\mu + \lim_{n \rightarrow \infty} \int v_n d\mu \\ &= \int f d\mu + \int g d\mu \end{aligned}$$

Sei jetzt f, g beliebig

$$\begin{aligned} (f + g)^+ - (f + g)^- &= f + g = f^+ - f^- + g^+ - g^- \implies (f + g)^+ + f^- + g^- = (f + g)^- + f^+ + g^+ \xrightarrow{\text{s.o.}} \int (f + g)^+ d\mu + \int f^- d\mu + \int g^- d\mu = \\ &= \int (f + g)^- d\mu + \int f^+ d\mu + \int g^+ d\mu \\ \implies \int (f + g) d\mu &= \int (f + g)^+ d\mu - \int (f + g)^- d\mu = \int f^+ d\mu - \int f^- d\mu + \int g^+ d\mu - \int g^- d\mu = \int f d\mu + \int g d\mu \end{aligned}$$

b) vergleiche Übung

c) $f \leq |f|, -f \leq |f| \xrightarrow{\text{b) mit } g = |f|}$ Behauptung ■

Bemerkung Ist $\mu = \lambda$ das Lebesgue-Maß, so heißt $\int f d\mu = \int f d\lambda$ Lebesgue-Integral.

Beispiel 1.2 a) Sei δ_ω das Dirac-Maß, $f : \Omega \rightarrow \bar{\mathbb{R}}$ ist δ_ω -integrierbar falls $f(\omega) < \infty$ und dann gilt

$$\int f d\delta_\omega = f(\omega)$$

Denn: Sei $f \in \mathcal{E} \implies f = \sum_{j=1}^n \alpha_j \mathbf{1}_{A_j} \implies \int f d\delta_\omega = \sum_{j=1}^n \alpha_j \delta_\omega(A_j) = \alpha_k \cdot 1 = f(\omega)$

$f \in \mathcal{E}^+ : u_n \uparrow f, \int u_n d\delta_\omega = u_n(\omega) \uparrow f(\omega)$

f allgemein $\implies f = f^+ - f^-$

b) Sei (μ_n) eine Folge von Maßen und $\mu = \sum_{n=1}^\infty \mu_n$. Für $f : \Omega \rightarrow \bar{\mathbb{R}}$ gilt:

$$\begin{aligned} f \text{ ist } \mu\text{-integrierbar} &\iff \sum_{n=1}^\infty \int |f| d\mu_n < \infty \\ \int f d\mu &= \sum_{n=1}^\infty \int f d\mu_n \text{ (vergleiche Übung)} \end{aligned}$$

Spezialfall: $(\Omega, \mathcal{A}) = (\mathbb{N}, \mathcal{P}(\mathbb{N})), \mu = \sum_{n=1}^\infty \delta_n$ (Zählmaß auf \mathbb{N})

f ist μ -integrierbar $\iff \sum_{n=1}^\infty |f(n)| < \infty$, dann $\int f d\mu = \sum_{n=1}^\infty f(n)$.

Summation ist ein Spezialfall von Integration. Sei $\Omega = \{\omega_1, \omega_2, \dots\}, \mathcal{A} =$

$\mathcal{P}(\Omega) \cdot \mu = P := \sum_{n=1}^{\infty} p_n \delta_{\omega_n}$ mit $p_n \geq 0, \sum_{n=1}^{\infty} p_n = 1$ (Wahrscheinlichkeitsmaß).

Sei $X : \Omega \rightarrow \mathbb{R}$ eine Zufallsvariable:

$$EX \text{ existiert} \iff \sum_{n=1}^{\infty} |X(\omega_n)| p_n < \infty \iff X \text{ ist } P\text{-integrierbar}$$

$$EX = \sum_{n=1}^{\infty} X(\omega_n) P_n = \sum_{n=1}^{\infty} X(\omega_n) P(\{\omega_n\}) = \int X dP$$

- c) Sei $\Omega = [a, b]$ und $\mathcal{A} = \mathfrak{B}_{[a,b]} = \{A \cap [a, b] \mid A \in \mathfrak{B}\}$ (Spur von \mathfrak{B} auf $[a, b]$)
 $\mu(A) := \lambda(A) \forall A \in \mathcal{A}$. Ist $f : \Omega \rightarrow \mathbb{R}$ messbar und f Riemann-integrierbar, so ist f auch μ -integrierbar und es gilt:

$$\int f d\mu = \int f(x) dx$$

(Hier fehlt ein Bild zur Veranschaulichung)

Das Lebesgue-Integral ist eine Erweiterung des Riemann-Integrals:

Sei $f = \mathbf{1}_{\mathbb{Q} \cap [0,1]}$. f ist nicht Riemann-integrierbar. Da $f \in \mathcal{E}$ gilt:

$$\int f d\lambda = 0 \cdot \lambda(\mathbb{Q}^c \cap [0, 1]) + 1 \cdot \lambda(\mathbb{Q} \cap [0, 1]) = 0$$

Das letzte Gleichheitszeichen gilt wegen:

- (i) $\lambda(\{a\}) = 0$, da $\{a\} = \cap_{n=1}^{\infty} [a, a + \frac{1}{n})$
- (ii) $\lambda(\sum_{i=1}^{\infty} \{a_i\}) = \sum_{i=1}^{\infty} \lambda(\{a_i\}) = 0$

Vorsicht bei uneigentlichen Riemann-Integralen! $\int_0^{\infty} \frac{\sin x}{x} dx$ ist Riemann-integrierbar, aber nicht Lebesgue-integrierbar.

2 Eigenschaften des Maß-Integrals

2.1 Konvergenzsätze

Im Folgenden sei $(\Omega, \mathcal{A}, \mu)$ ein Maßraum und $f, f_1, f_2, \dots : \Omega \rightarrow \bar{\mathbb{R}}$ messbare Funktionen.

Satz 2.1 (Satz von Beppo Levi, Satz von der monotonen Konvergenz)

Sind $f, f_1, f_2, \dots \geq 0$ mit $f_n \uparrow f$, so gilt

$$\lim_{n \rightarrow \infty} \int f_n d\mu = \int f d\mu.$$

Beweis $\forall f_n \exists (u_{nm})_{m \in \mathbb{N}} \subset \mathcal{E}$ mit $u_{nm} \uparrow f_n$ für $m \rightarrow \infty$. Sei $h_m := \max\{u_{1m}, \dots, u_{mm}\} \implies h_m \uparrow$ und $(h_m) \subset \mathcal{E}$. Außerdem: $u_{nm} \leq h_m$ für $n \leq m$.

Also: $f_n = \sup_{m \in \mathbb{N}} u_{nm} = \sup_{m \geq n} u_{nm} \leq \sup_{m \in \mathbb{N}} h_m$ und $h_m \leq f_m \leq f$. Insgesamt: $h_m \uparrow f$ und $\lim_{m \rightarrow \infty} \int h_m d\mu = \int f d\mu$. Mit $\int h_m d\mu \leq \int f_m d\mu \leq \int f d\mu$ folgt die Behauptung. ■

Im Folgenden sei $(\Omega, \mathcal{A}, \mu)$ ein Maßraum und $f_1, f_2, f_3, \dots : \Omega \rightarrow \bar{\mathbb{R}}$ messbare Funktionen.

Satz 2.2 (Lemma von Fatou)

Gilt $f_n \geq 0, n \in \mathbb{N}$, so folgt

$$\int \liminf_{n \rightarrow \infty} f_n d\mu \leq \liminf_{n \rightarrow \infty} \int f_n d\mu$$

Beweis Sei $g_n := \inf_{m \geq n} f_m, f := \liminf_{n \rightarrow \infty} f_n$, so gilt $g_n \uparrow f$ und mit Satz 2.1 $\int \liminf_{n \rightarrow \infty} f_n d\mu = \lim_{n \rightarrow \infty} \int g_n d\mu = \liminf_{n \rightarrow \infty} \int g_n d\mu \leq \liminf_{n \rightarrow \infty} \int f_n d\mu$ ■

Satz 2.3 (Satz von Lebesgue oder Satz von der majorisierten Konvergenz)

Es gelte $\lim_{n \rightarrow \infty} f_n(\omega) = f(\omega) \forall \omega \in \Omega$. Existiert eine μ -integrierbare Funktion $g : \Omega \rightarrow \mathbb{R}$ mit der Eigenschaft $|f_n(\omega)| \leq g(\omega) \forall \omega \in \Omega, \forall n \in \mathbb{N}$, so folgt:

$$\lim_{n \rightarrow \infty} \int f_n d\mu = \int f d\mu$$

Beweis Sei $g_n := |f_n - f|, h := |f| + g$. Wegen $|h| \leq 2g$ ist h μ -integrierbar. Außerdem gilt

$$\begin{aligned} h - g_n &= |f| + g - |f_n - f| \geq |f| + g - |f_n| - |f| \\ &= g - |f_n| \geq 0 \end{aligned}$$

wegen $g_n \rightarrow 0$ gilt $h - g_n \rightarrow h$, also folgt mit Satz 2.2

$$\begin{aligned} \int h d\mu &= \int \liminf_{n \rightarrow \infty} (h - g_n) d\mu \\ &\leq \liminf_{n \rightarrow \infty} \int (h - g_n) d\mu \\ &= \underbrace{\int h d\mu}_{< \infty} - \limsup_{n \rightarrow \infty} \int g_n d\mu \end{aligned} \quad \blacksquare$$

$\Rightarrow \limsup_{n \rightarrow \infty} \int g_n d\mu \leq 0$ Wegen $g_n \geq 0$ bedeutet dies:

$$\lim_{n \rightarrow \infty} \int |f_n - f| d\mu = \lim_{n \rightarrow \infty} \int g_n d\mu = 0$$

und damit

$$\left| \int f_n d\mu - \int f d\mu \right| = \left| \int (f_n - f) d\mu \right| \leq \int |f_n - f| d\mu \rightarrow 0$$

Bemerkung 2.1 Für Wahrscheinlichkeitsmaße lautet Satz 2.3:

Ist $(X_n)_{n \in \mathbb{N}}$ eine Folge von Zufallsvariablen, so dass $X_n \xrightarrow{f.s.} X$ (X ist dann automatisch wieder eine Zufallsvariable) und es gibt eine Zufallsvariable Y mit $|X_n| \leq Y \forall n \in \mathbb{N}$ und $EY < \infty$, so gilt $\lim_{n \rightarrow \infty} EX_n = EX$.

Oft kommt man mit einer Majorante der Form $Y \equiv c, c \in \mathbb{R}$ zum Ziel.

2.2 Verhalten bei Transformationen

Es sei $(\Omega, \mathcal{A}, \mu)$ ein Maßraum und (Ω', \mathcal{A}') ein messbarer Raum und $T : \Omega \rightarrow \Omega'$ eine $(\mathcal{A}, \mathcal{A}')$ -messbare Abbildung. Aus Stochastik 1 ist bekannt (vgl. §5.2, Verteilung), dass durch

$$\mu^T : \mathcal{A}' \rightarrow [0, \infty], \mu^T(A') := \mu(\underbrace{T^{-1}(A')}_{\in \mathcal{A}}) = \mu(\{\omega \in \Omega \mid T(\omega) \in A'\})$$

ein Maß auf (Ω', \mathcal{A}') definiert wird (Maßtransport). μ^T heißt **Bildmaß** von μ unter der Transformation T .

Ist $X = T$ eine Zufallsgröße auf einem Wahrscheinlichkeitsraum (Ω, \mathcal{A}, P) mit Werten in (Ω', \mathcal{A}') , so nennt man $\mu^T = P^X$ die Verteilung von X . Sei nun weiter $f : \Omega' \rightarrow \mathbb{R}$ messbar.

$$\begin{array}{ccc} \text{Skizze: } (\Omega, \mathcal{A}) & \xrightarrow{T} & (\Omega', \mathcal{A}') \\ & \searrow f \circ T & \downarrow f \\ & & (\mathbb{R}, \mathfrak{B}) \end{array}$$

Satz 2.4 (Integration bezüglich des Bildmaßes, Transformationssatz)

Mit den obigen Bezeichnungen und Voraussetzungen gilt: f ist genau dann μ^T -integrierbar, wenn $f \circ T$ μ -integrierbar ist.

Dann gilt:

$$\int f d\mu^T = \int (f \circ T) d\mu$$

Beweis

(i) Falls $f = \mathbf{1}_A, (A \in \mathcal{A})$ gilt

$$\begin{aligned} \int f d\mu^T &= \mu^T(A) \\ &= \mu(T^{-1}(A)) \\ &= \int \mathbf{1}_{T^{-1}(A)} d\mu \\ &= \int \mathbf{1}_A \circ T d\mu \\ &= \int f \circ T d\mu \end{aligned}$$

wegen Satz 1.2(a) folgt damit die Aussage für $f \in \mathcal{E}$

(ii) Sei jetzt $f \geq 0 \implies \exists (u_n)_{n \in \mathbb{N}} \subset \mathcal{E}$ mit $u_n \uparrow f$ und $\int f d\mu^T = \lim_{n \rightarrow \infty} \int u_n d\mu^T$.
Offenbar gilt $u_n \circ T \in \mathcal{E}, (u_n \circ T) \uparrow (f \circ T)$

Also folgt:

$$\begin{aligned} \int f d\mu^T &= \lim_{n \rightarrow \infty} \int u_n d\mu^T \\ &\stackrel{(i)}{=} \lim_{n \rightarrow \infty} \int (u_n \circ T) d\mu \\ &= \int (f \circ T) d\mu \end{aligned}$$

(iii) Ist $f : \Omega' \rightarrow \mathbb{R}$ eine beliebige $(\mathcal{A}', \mathfrak{B})$ -messbare Abbildung so gilt

$$\begin{aligned} \int f^+ d\mu^T < \infty &\iff \int f^+ \circ T d\mu < \infty \\ \int f^- d\mu^T < \infty &\iff \int f^- \circ T d\mu < \infty \end{aligned}$$

Da $(f \circ T)^+ = f^+ \circ T, (f \circ T)^- = f^- \circ T$, folgt f μ^T -integrierbar $\iff f \circ T$

μ -integrierbar

$$\begin{aligned}
 \int f d\mu^T &= \int f^+ d\mu^T - \int f^- d\mu^T \\
 &\stackrel{(ii)}{=} \int f^+ \circ T d\mu - \int f^- \circ T d\mu \\
 &= \int (f \circ T)^+ d\mu - \int (f \circ T)^- d\mu \\
 &= \int f \circ T d\mu. \quad \blacksquare
 \end{aligned}$$

Bemerkung 2.2 Das Beweisverfahren (zuerst für $f \in \mathcal{E}$ (bzw. $f = \mathbf{1}_A$), dann für $f \in \mathcal{E}^+$, dann für f beliebig) heißt **algebraische Induktion** und wird häufig verwendet.

2.3 Nullmengen und Maße mit Dichten

Im Folgenden sei $(\Omega, \mathcal{A}, \mu)$ ein Maßraum.

Definition 2.1 $N \in \mathcal{A}$ heißt μ -Nullmenge, falls $\mu(N) = 0$.

Definition 2.2 Ist (A) eine Aussage, die von $\omega \in \Omega$ abhängt, so sagen wir, dass (A) μ -**fast überall** (μ -f.ü.) gilt, wenn (A) wahr ist $\forall \omega$ außerhalb einer μ -Nullmenge. Ist $\mu = P$ ein Wahrscheinlichkeitsmaß, so sagt man P -fast-überall oder P -fast sicher (P -f.s.)

Satz 2.5

$f, g : \Omega \rightarrow \mathbb{R}$ seien $(\mathcal{A}, \mathfrak{B})$ messbar.

- a) Sei $f \geq 0$. Dann gilt: $\int f d\mu = 0 \iff f = 0, \mu$ -f.ü.
- b) Ist f μ -integrierbar und gilt $f = g$ μ -f.ü., so ist auch g μ -integrierbar mit $\int f d\mu = \int g d\mu$.

Beweis

- a) Sei $N := \{\omega \in \Omega \mid f(\omega) \neq 0\}$. $N \in \mathcal{A}$, da f messbar.
 - (i) Annahme: $\int f d\mu = 0$.
 Sei $A_n := \{\omega \in \Omega \mid f(\omega) \geq \frac{1}{n}\} \implies A_n \uparrow N$ und $\mu(N) = \lim_{n \rightarrow \infty} (\mu(A_n))$.
 Außerdem gilt $0 = \int f d\mu \geq \int \frac{1}{n} \cdot \mathbf{1}_{A_n} d\mu = \frac{1}{n} \cdot \mu(A_n) \geq 0$
 $\implies \mu(A_n) = 0 \forall n \in \mathbb{N} \implies \mu(N) = 0$, also $f = 0$ μ -f.ü.
 - (ii) Annahme: N ist μ -Nullmenge.
 Sei $g \in \mathcal{E}$, $g(\Omega) = \{\alpha_1, \dots, \alpha_n\}$, $g \leq f$.
 $\implies g = \sum_{j=1}^n \alpha_j \circ \mathbf{1}_{A_j}$.
 Falls $\alpha_j > 0 \implies A_j \subset N \implies \int g d\mu = 0 \xrightarrow{\text{L.1.3}} \int f d\mu = 0$.

b) Seien zunächst $f, g \geq 0$, $N := \{f \neq g\} \xrightarrow{a)}$

$$\begin{aligned} \int f d\mu &= \int_N f d\mu + \int_{N^c} f d\mu \\ &= 0 + \int_{N^c} g d\mu \\ &= \int_N g d\mu + \int_{N^c} g d\mu \\ &= \int g d\mu \end{aligned}$$

Insbesondere: $\int f d\mu < \infty \iff \int g d\mu < \infty$.

Seien nun f, g beliebig. Wegen $\{f^+ = g^+\} \supset \{f = g\} \subset \{f^- = g^-\}$ gilt auch $f^+ = g^+$ und $f^- = g^-$ μ -f.ü. und mit dem vorigen Teil folgt die Behauptung. ■

Bemerkung 2.3 Im Folgenden sei $L^1(\Omega, \mathcal{A}, \mu) := \{f : \Omega \rightarrow \mathbb{R} \mid f \text{ ist messbar und } \mu\text{-integrierbar}\}$ (ist ein Vektorraum) und wir definieren

$f \sim_\mu g : \iff f = g$ μ -f.ü. und \sim_μ ist Äquivalenzrelation auf $\{f : \Omega \rightarrow \mathbb{R} \mid f \text{ ist messbar}\}$. Sei $f^{[\mu]}$ die Äquivalenzklasse zu f .

Mit Satz 2.5: Entweder alle oder keines der Elemente in $f^{[\mu]}$ ist μ -integrierbar und die Integrale sind ggfs. gleich. Außerdem gilt:

$$f_1 \in f^{[\mu]}, g_1 \in g^{[\mu]} \implies f_1 + g_1 \in (f + g)^{[\mu]}.$$

\implies Man kann zum Raum der Äquivalenzklassen übergehen: $L^1(\Omega, \mathcal{A}, \mu) / \sim_\mu$

Mit $\|f^{[\mu]}\|_1 := \int |f| d\mu$ ist eine Norm definiert; sie ist wohldefiniert, da $\int f_1 d\mu = \int f_2 d\mu \forall f_1, f_2 \in f^{[\mu]}$.

Wichtig: $f \mapsto \int |f| d\mu =: \|f\|$ ist auf $L^1(\Omega, \mathcal{A}, \mu)$ keine Norm, da $\|f\| = 0 \implies f \equiv 0$ im Allgemeinen falsch ist!

Satz 2.6 $(L^1(\Omega, \mathcal{A}, \mu) / \sim_\mu, \|\cdot\|_1)$ ist ein Banachraum.

Definition 2.3 Es seien μ, ν Maße auf dem messbaren Raum (Ω, \mathcal{A}) . Gilt dann $\mu(A) = 0 \implies \nu(A) = 0 \forall A \in \mathcal{A}$, so heißt ν μ -**stetig**, in Zeichen $\nu \ll \mu$. Man sagt auch, dass μ das Maß ν dominiert.

Satz 2.7 und Definition

Sei $(\Omega, \mathcal{A}, \mu)$ ein Maßraum und $f : \Omega \rightarrow \mathbb{R}_+$ $(\mathcal{A}, \mathfrak{B})$ -messbar. Dann wird durch $\nu : \mathcal{A} \rightarrow \mathbb{R}_+ \cup \{\infty\}$, $\nu(A) := \int_A f d\mu$ ein Maß auf (Ω, \mathcal{A}) definiert. Man nennt ν das **Maß mit der Dichte** f bzgl. μ und f eine μ -**Dichte** von ν . Schreibweise: $f = \frac{d\nu}{d\mu}$

Beweis Wir weisen nach, dass ν ein Maß ist:

$\nu \geq 0$ ist klar, da f nach \mathbb{R}_+ abbildet;

$$(i) \quad \nu(\emptyset) = \int f \cdot \mathbf{1}_\emptyset d\mu = 0.$$

- (ii) Seien A_1, A_2, \dots paarweise disjunkt und $A = \sum_{n=1}^{\infty} A_n$.
 Wegen $f \cdot \mathbf{1}_{\sum_{k=1}^n A_k} \uparrow f \cdot \mathbf{1}_A$ folgt mit Satz 2.1:

$$\begin{aligned}
 \nu\left(\sum_{n=1}^{\infty} A_n\right) &= \int f \cdot \mathbf{1}_A d\mu \\
 &= \lim_{n \rightarrow \infty} \left(\int f \cdot \underbrace{\mathbf{1}_{\sum_{k=1}^n A_k}}_{=\sum_{k=1}^n \mathbf{1}_{A_k}} d\mu \right) \\
 &= \lim_{n \rightarrow \infty} \left(\int \sum_{k=1}^n f \cdot \mathbf{1}_{A_k} d\mu \right) \\
 &= \lim_{n \rightarrow \infty} \left(\sum_{k=1}^n \underbrace{\left(\int f \cdot \mathbf{1}_{A_k} d\mu \right)}_{=\nu(A_k)} \right) \\
 &= \sum_{k=1}^{\infty} \nu(A_k)
 \end{aligned}$$

Satz 2.8 (Satz von Radon-Nikodym)

Seien μ, ν Maße auf dem messbaren Raum (Ω, \mathcal{A}) , μ sei σ -endlich. Dann gilt:
 ν ist genau dann μ -stetig, wenn ν eine Dichte bzgl. μ hat.

Beweis ν hat Dichte bzgl. $\mu \implies \nu(A) = \int_A f d\mu = \int f \cdot \mathbf{1}_A d\mu \xrightarrow{\text{S.2.5a}} \nu \ll \mu$.
 Die andere Richtung siehe z.B. Henze, Stochastik II. ■

Satz 2.9 Seien μ und ν Maße auf (Ω, \mathcal{A}) , ν habe μ -Dichte f . Dann gilt für alle $(\mathcal{A}, \mathfrak{B})$ -messbaren Abbildungen $g : \Omega \rightarrow \mathbb{R}$:

g ist genau dann ν -integrierbar, wenn $g \cdot f$ μ -integrierbar ist und in diesem Fall ist $\int g d\nu = \int g \cdot f d\mu$.

Beweis Übung. ■

Bemerkung 2.4 Merkgel: $\int g d\nu = \int g \cdot \frac{d\nu}{d\mu} d\mu$.

Beispiel 2.1 Sei $\mu = \lambda$ das Lebesgue-Maß und $\nu = P^X$ die Verteilung einer Zufallsvariablen X . Ist X absolutstetig, so gilt (Stochastik I):

$$P^X(B) = \int_B f_X(x) dx$$

mit $f_X : \mathbb{R} \rightarrow \mathbb{R}_+ \cup \{\infty\}$ und

$$EX = \int_{\Omega} X dP = \int_{\mathbb{R}} x P^X(dx) = \int_{\mathbb{R}} x \cdot f_X(x) dx.$$

mit den Sätzen 2.4 und 2.9.

2.4 Ungleichungen und Räume integrierbarer Funktionen

Hier stellen wir einige Hilfsmittel für später zusammen. Der folgende Satz behandelt den Spezialfall von Wahrscheinlichkeitsmaßen.

Satz 2.10 *Es sei (Ω, \mathcal{A}, P) ein Wahrscheinlichkeitsraum, $X : \Omega \rightarrow \mathbb{R}$ eine Zufallsvariable und $\gamma > 0$. Dann gilt:*

$$P(|X| \geq a) \leq \frac{1}{a^\gamma} \cdot E|X|^\gamma \quad \forall a > 0.$$

Existiert die Varianz von X , so gilt:

$$P(|X - EX| \geq a) \leq \frac{1}{a^2} \cdot \text{Var}(X) \quad \forall a > 0.$$

(Ungleichung von Tschebyschef, siehe Abschnitt 7.6, Stochastik I)

Beweis

Sei $Y : \Omega \rightarrow \mathbb{R}$ definiert durch:

$$Y(\omega) = \begin{cases} a, & \text{falls } |X(\omega)| \geq a \\ 0, & \text{sonst} \end{cases}$$

$$\implies |Y| \leq |X|$$

$$\implies |Y|^\gamma \leq |X|^\gamma \quad \forall \gamma > 0$$

$$\implies a^\gamma P(|X| \geq a) = a^\gamma P(|Y| \geq a) = E|Y|^\gamma \leq E|X|^\gamma$$

Für Teil 2 setze $\tilde{X} := X - EX$ und $\gamma = 2$. ■

Sei $I \subset \mathbb{R}$ ein offenes Intervall und $\Phi : I \rightarrow \mathbb{R}$ eine konvexe Funktion, d.h.

$$\Phi(\alpha x + (1 - \alpha)y) \leq \alpha\Phi(x) + (1 - \alpha)\Phi(y) \quad \forall x, y \in I, \forall \alpha \in [0, 1]$$

Außerdem gilt $\forall y \in I, \exists m \in \mathbb{R}$, mit

$$\Phi(x) \geq \Phi(y) + m(x - y)$$

Satz 2.11 (Jensensche Ungleichung)

Es seien $I \subset \mathbb{R}$ ein offenes Intervall, $\Phi : I \rightarrow \mathbb{R}$ konvex und X eine Zufallsvariable mit $E|X| < \infty, E|\Phi(X)| < \infty$ und $P(X \in I) = 1$. Dann gilt:

$$EX \in I \text{ und } \Phi(EX) \leq E\Phi(X)$$

Beweis

Falls $I = (-\infty, \infty)$ ist automatisch $EX \in I$. Ist $X < a$ P-f.s. so gilt: $EX \leq Ea = a$.

Falls $E(a - X) = 0$ folgt, da $a - X \geq 0 \xrightarrow{\text{Satz 2.5}} X = a$ P-f.s. Widerspruch!

D.h., falls $I = (\cdot, a) \subset (-\infty, a) \implies EX < a$. Analog untere Schranke $\implies EX \in I$.

Mit der Vorüberlegung folgt ($y = EX, x = X(\omega)$)

$$\Phi(X) \geq \Phi(EX) + m(X - EX) \quad \text{P-f.s.}$$

für ein $m \in \mathbb{R}$. Erwartungswert auf beiden Seiten führt zur Behauptung (Nullmengen können wir vernachlässigen). ■

Beispiel 2.2

Für $\Phi(x) = |x|$, $\Phi(x) = x^2$ folgt: $|EX| \leq E|X|$, $(EX)^2 \leq EX^2$. ($\implies EX^2 - (EX)^2 = \text{Var } X \geq 0$)

Im Folgenden sei $(\Omega, \mathcal{A}, \mu)$ wieder ein Maßraum.

Definition

Eine messbare Funktion $f : \Omega \rightarrow \mathbb{R}$ heißt **p -fach μ -integrierbar**, wenn $\int |f|^p d\mu < \infty$ mit $p > 0$.

$$L^p(\Omega, \mathcal{A}, \mu) := \{f : \Omega \rightarrow \mathbb{R} \mid \int |f|^p d\mu < \infty\}$$

$$\|f\|_p = \left(\int |f|^p d\mu \right)^{\frac{1}{p}}$$

Wie im vorigen Abschnitt ist L^p bzw. $L^p(\Omega, \mathcal{A}, \mu) / \sim_\mu$ ein Vektorraum über \mathbb{R} und $\|f\|_p$ auf den Äquivalenzklassen eine Norm.

Satz 2.12

- a) (Höldersche Ungleichung) Es seien $p > 1$, $f \in L^p(\Omega, \mathcal{A}, \mu)$, $g \in L^q(\Omega, \mathcal{A}, \mu)$, wobei $\frac{1}{p} + \frac{1}{q} = 1$. Dann folgt: $f \cdot g \in L^1(\Omega, \mathcal{A}, \mu)$ und es gilt:

$$\|f \cdot g\|_1 \leq \|f\|_p \cdot \|g\|_q$$

- b) (Minkowskische Ungleichung) Es seien $p \geq 1$ und $f, g \in L^p(\Omega, \mathcal{A}, \mu)$. Dann folgt $f + g \in L^p(\Omega, \mathcal{A}, \mu)$ und es gilt:

$$\|f + g\|_p \leq \|f\|_p + \|g\|_p$$

Beweis

- a) Falls $\int |f|^p d\mu = 0 \xrightarrow{\text{Satz 2.5}} f = 0 \text{ } \mu\text{-f.s.}$ und die Ungleichung ist richtig. Sei also $\|f\|_p > 0$ und $\|g\|_q > 0$ (gleiches Argument). $x \mapsto \log x$ ist konkav, d.h. es gilt: $\alpha \log(a) + (1 - \alpha) \log(b) \leq \log(\alpha a + (1 - \alpha)b) \quad \forall a, b > 0, 0 < \alpha < 1$. $\exp(\cdot)$ auf beiden Seiten:

$$a^\alpha b^{1-\alpha} \leq \alpha a + (1 - \alpha)b \quad \forall a, b \geq 0, 0 < \alpha < 1$$

Setze $a := \frac{|f(\omega)|^p}{\|f\|_p^p}$, $b := \frac{|g(\omega)|^q}{\|g\|_q^q}$, $\alpha = \frac{1}{p}$ (ω beliebig)

$$\implies \frac{|f(\omega)| \cdot |g(\omega)|}{\|f\|_p \cdot \|g\|_q} \leq \frac{1}{p} \frac{|f(\omega)|^p}{\|f\|_p^p} + \frac{1}{q} \frac{|g(\omega)|^q}{\|g\|_q^q}$$

$$\implies |f(\omega)| \cdot |g(\omega)| \leq \frac{1}{p} |f(\omega)|^p \|f\|_p^{1-p} \|g\|_q + \frac{1}{q} |g(\omega)|^q \|g\|_q^{1-q} \|f\|_p$$

$$\begin{aligned} \xrightarrow{\text{Int. über } \omega} \|f \cdot g\|_1 &\leq \frac{1}{p} \|f\|_p^p \|f\|_p^{1-p} \|g\|_q + \frac{1}{q} \|g\|_q^q \|g\|_q^{1-q} \|f\|_p \\ &= \frac{1}{p} \|f\|_p \|g\|_q + \frac{1}{q} \|g\|_q \|f\|_p \end{aligned}$$

\implies Behauptung

- b) Wegen $|f + g| \leq |f| + |g|$ gilt $\|f + g\|_p \leq \|f\|_p + \|g\|_p$. Also genügt es die Ungleichung für $f + g \geq 0$ zu beweisen. Falls $p = 1$ folgt $\|f + g\|_1 = \int (f + g) d\mu = \int f d\mu + \int g d\mu = \|f\|_1 + \|g\|_1$. Sei also $p > 1$. Mit $(f + g)^p \leq (2 \cdot \max\{f, g\})^p \leq 2^p(|f|^p + |g|^p) \implies (f + g) \in L^p$, also $\|f + g\|_p < \infty$. Sei $q := \frac{1}{1-\frac{1}{p}}$. Anwendung von Teil a) liefert:

$$\begin{aligned} \|f + g\|_p^p &= \int f(f + g)^{p-1} d\mu + \int g(f + g)^{p-1} d\mu \\ &\stackrel{\text{a)}}{\leq} (\|f\|_p + \|g\|_p) \|(f + g)^{p-1}\|_q \quad (*) \end{aligned}$$

Wegen $(p - 1)q = p$ gilt:

$$\|(f + g)^{p-1}\|_q = \left(\int (f + g)^{(p-1)q} d\mu \right)^{\frac{1}{q}} = \|f + g\|_p^{\frac{p}{q}} = \|f + g\|_p^{p-1}$$

Falls $\|f + g\|_p = 0$ ist die Ungleichung richtig. Sei also $\|f + g\|_p > 0$. Nehme (*) und teile durch $\|f + g\|_p^{p-1}$ auf beiden Seiten \implies Behauptung. ■

Bemerkung

Falls $p = q = 2, \Omega = \{1, \dots, n\}, \mathcal{A} = \mathcal{P}(\Omega), \mu = \sum_{k=1}^n \delta_k, f(i) = a_i, g(i) = b_i$, bekommt man:

$$\sum_{i=1}^n a_i b_i \leq \left(\sum_{i=1}^n a_i^2 \right)^{\frac{1}{2}} \cdot \left(\sum_{i=1}^n b_i^2 \right)^{\frac{1}{2}}$$

In diesem Fall ist Satz 2.12 a) die Cauchy-Schwarz-Ungleichung.

Lineare Algebra: $|\langle a, b \rangle| \leq \|a\| \cdot \|b\| \quad \forall a, b \in \mathbb{R}^n$. Das motiviert

Satz 2.13

Es sei $(\Omega, \mathcal{A}, \mu)$ ein Maßraum und $L^2(\Omega, \mathcal{A}, \mu) / \sim_\mu$ der Raum der \sim_μ -Äquivalenzklassen quadratisch μ -integrierbarer Funktion $f : \Omega \rightarrow \mathbb{R}$.

Dann ist $\langle f, g \rangle := \int f \cdot g d\mu$ hierauf ein Skalarprodukt, durch den $L^2(\Omega, \mathcal{A}, \mu) / \sim_\mu$ zu einem Hilbertraum wird.

Beweis siehe Henze, Stochastik II ■

Bemerkung

- a) $(L^p(\Omega, \mathcal{A}, \mu) / \sim_\mu, \|\cdot\|_p)$ ist ein Banachraum für $p \geq 1$.
- b) Ist $\Phi : L^p(\Omega, \mathcal{A}, \mu) \rightarrow \mathbb{R}$ stetig und linear, so existiert ein $g \in L^q(\Omega, \mathcal{A}, \mu)$ mit $\Phi(f) = \int f \cdot g d\mu \quad \forall f \in L^p(\Omega, \mathcal{A}, \mu)$.

3 Produktmaße und Unabhängigkeit

3.1 Der allgemeine Fall

Im Folgenden sei $I \neq \emptyset$ eine beliebige Indexmenge. $\forall i \in I$ sei $(\Omega_i, \mathcal{A}_i)$ ein messbarer Raum. Weiter sei $\Omega := \times_{i \in I} \Omega_i$ ein neuer Ergebnisraum. Wir definieren die **Projektion** auf die i -te Koordinate $\Pi_i : \Omega \rightarrow \Omega_i$ durch $\Pi_i(\omega) = \omega_i$.

Definition Die **Produkt- σ -Algebra** $\mathcal{A} := \bigotimes_{i \in I} \mathcal{A}_i$ ist die kleinste σ -Algebra mit der Eigenschaft, dass für alle $i \in I$ die Abbildung Π_i $(\mathcal{A}, \mathcal{A}_i)$ -messbar ist. Genauer:

$$\mathcal{A} := \sigma \left(\bigcup_{i \in I} \{ \Pi_i^{-1}(A_i) \mid A_i \in \mathcal{A}_i \} \right)$$

Bemerkung Sei $J \subset I$, $\Pi_J : \Omega \rightarrow \times_{i \in J} \Omega_i$, $\Pi_J(\omega)(j) = \omega_j$ ($j \in J$) die Projektion auf die J -Koordinaten, so bildet

$$\left\{ \Pi_J^{-1}(A_J) \mid A_J \in \bigotimes_{i \in J} \mathcal{A}_i, J \subset I, J \text{ endlich} \right\}$$

ein durchschnittstabiles Erzeugendensystem von \mathcal{A} . Man nennt diese Mengen auch **Zylindermengen** mit endlicher Basis.

$$\left(A_J = A_{i_1} \times \cdots \times A_{i_{|J|}}, \Pi_J^{-1}(A_J) = \bigcap_{k=1}^{|J|} \Pi_{i_k}^{-1}(A_{i_k}) \right)$$

Beispiel 3.1 Ist $I = \{1, \dots, n\}$ endlich, so ist (vgl. Stochastik I, §8):

$$\mathcal{A} = \bigotimes_{i=1}^n \mathcal{A}_i = \sigma(\{A_1 \times \cdots \times A_n \mid A_i \in \mathcal{A}_i, i \in \{1, \dots, n\}\})$$

Wir betrachten zunächst den Fall $|I| = 2$. Gegeben seien zwei Maßräume $(\Omega_1, \mathcal{A}_1, \mu_1)$ und $(\Omega_2, \mathcal{A}_2, \mu_2)$. Weiter sei $\Omega = \Omega_1 \times \Omega_2$, $\mathcal{A} = \mathcal{A}_1 \otimes \mathcal{A}_2$. Wir müssen nun ein Produktmaß konstruieren.

Lemma 3.1 Für alle $A \in \mathcal{A}$, $\omega_1 \in \Omega_1$, $\omega_2 \in \Omega_2$ gilt:

$$\begin{aligned} A_{\omega_1} &:= \{ \omega_2 \in \Omega_2 \mid (\omega_1, \omega_2) \in A \} \in \mathcal{A}_2 \text{ und} \\ A_{\omega_2} &:= \{ \omega_1 \in \Omega_1 \mid (\omega_1, \omega_2) \in A \} \in \mathcal{A}_1. \end{aligned}$$

A_{ω_i} heißt ω_i -Schnitt von A für $i = 1, 2$.

- hier fehlt eine Skizze -

Beweis Sei $\omega_1 \in \Omega_1$. Dann ist $\mathcal{A}' := \{A \in \mathcal{A} \mid A_{\omega_1} \in \mathcal{A}_2\} \subset \mathcal{A}$, also die Menge der Mengen, für die das Lemma gilt, eine σ -Algebra, denn:

(i)

$$\Omega_{\omega_1} = \Omega_2 \in \mathcal{A}_2 \implies \Omega \in \mathcal{A}'$$

(ii)

$$\begin{aligned} (\Omega \setminus A)_{\omega_1} &= \{\omega_2 \mid (\omega_1, \omega_2) \notin A\} \\ &= \{\omega_2 \mid (\omega_1, \omega_2) \in A\}^C \\ &= \Omega_2 \setminus \underbrace{A_{\omega_1}}_{\in \mathcal{A}_2} \in \mathcal{A}_2 \end{aligned}$$

$$\implies (\Omega \setminus A)_{\omega_1} \in \mathcal{A}'.$$

(iii)

$$\left(\bigcup_{n=1}^{\infty} A_n \right)_{\omega_1} = \bigcup_{n=1}^{\infty} (A_n)_{\omega_1} \in \mathcal{A}_2 \implies \left(\bigcup_{n=1}^{\infty} A_n \right)_{\omega_1} \in \mathcal{A}'$$

$$\text{Wegen } (A_1 \times A_2)_{\omega_1} = \begin{cases} A_2 & , \omega_1 \in A_1 \\ \emptyset & , \omega_1 \notin A_1 \end{cases} \in \mathcal{A}_2 \text{ gilt:}$$

$$\sigma(\{A_1 \times A_2 \mid A_1 \in \mathcal{A}_1, A_2 \in \mathcal{A}_2\}) \subset \mathcal{A}', \text{ also gilt } \mathcal{A} = \mathcal{A}'$$

mit der Voraussetzung von oben. Aus Symmetriegründen gilt die entsprechende Aussage auch für A_{ω_2} , $\omega_2 \in \Omega_2$. ■

Lemma 3.2 Die Maße μ_1, μ_2 seien σ -endlich. Dann gilt für alle $A \in \mathcal{A}$:

$$\begin{aligned} \omega_1 &\mapsto \mu_2(A_{\omega_1}) \text{ ist } (\mathcal{A}_1, \mathfrak{B}_{(-\infty, \infty]})\text{-messbar,} \\ \omega_2 &\mapsto \mu_1(A_{\omega_2}) \text{ ist } (\mathcal{A}_2, \mathfrak{B}_{(-\infty, \infty]})\text{-messbar.} \end{aligned}$$

Beweis μ_2 σ -endlich $\implies \exists (B_n)_{n \in \mathbb{N}} \subset \mathcal{A}_2$ mit $B_n \uparrow \Omega_2$ und $\mu_2(B_n) < \infty \quad \forall n \in \mathbb{N}$.

Setze $f_A(\omega_1) := \mu_2(A_{\omega_1})$, $f_{A,n}(\omega_1) := \mu_2(A_{\omega_1} \cap B_n)$. Sei $\mathcal{D} := \{D \in \mathcal{A} \mid f_{D,n} \text{ ist } (\mathcal{A}_1, \mathfrak{B})\text{-messbar}\}$ für ein festes n . Dann gilt:

- (i) $f_{\Omega,n} = \mu_2(\Omega_2 \cap B_n) = \mu_2(B_n)$
- (ii) $f_{D^C,n} = \mu_2(B_n) - f_{D,n}$, also $D \in \mathcal{D} \implies D^C \in \mathcal{D}$
- (iii) $f_{\sum_{i=1}^{\infty} D_i,n} = \sum_{i=1}^{\infty} f_{D_i,n}$, also $D_i \in \mathcal{D} \implies \sum_{i=1}^{\infty} D_i \in \mathcal{D}$

Damit ist \mathcal{D} ein Dynkin-System (vgl. Stochastik 1).

Wegen $f_{A_1 \times A_2,n}(\omega_1) = \mu_2(A_2 \cap B_n) \cdot \mathbf{1}_{A_1}(\omega_1)$ ist $f_{A_1 \times A_2,n}$ für $A_1 \in \mathcal{A}_1$, $A_2 \in \mathcal{A}_2$ messbar und daher $A_1 \times A_2 \in \mathcal{D}$.

\mathcal{D} enthält also das durchschnittstabile Erzeugendensystem von \mathcal{A} .

$\xrightarrow{\text{St.1, S.4.3}} \mathcal{D} = \mathcal{A} \implies f_{A,n}$ ist $(\mathcal{A}_1, \mathfrak{B})$ -messbar $\forall A \in \mathcal{A}$, $n \in \mathbb{N}$.

Wegen $f_A = \sup_{n \in \mathbb{N}} \{f_{A,n}\}$ folgt die Behauptung. ■

Definition 3.1 und Satz:

Sind μ_1, μ_2 σ -endlich, so existiert genau ein Maß μ auf $\mathcal{A}_1 \otimes \mathcal{A}_2$ mit $\mu(A_1 \times A_2) = \mu_1(A_1) \cdot \mu_2(A_2) \forall A_1 \in \mathcal{A}_1, \forall A_2 \in \mathcal{A}_2$. μ heißt **Produktmaß** von μ_1 und μ_2 , Schreibweise: $\mu = \mu_1 \otimes \mu_2$. Für μ gilt¹:

$$\mu(A) = \int \mu_2(A_{\omega_1}) \mu_1(d\omega_1) = \int \mu_1(A_{\omega_2}) \mu_2(d\omega_2) \quad \forall A \in \mathcal{A}$$

Schließlich ist μ auch σ -endlich.

Beweis Es seien wieder $f_A(\omega_1) = \mu_2(A_{\omega_1})$. Seien $A_n \in \mathcal{A}, n \in \mathbb{N}, A_n$ paarweise disjunkt und $\sum_{n=1}^{\infty} A_n = A$. Es folgt:

$$\begin{aligned} \int f_A d\mu_1 & \stackrel{\text{stetig von unten}}{=} \int \lim_{n \rightarrow \infty} \left(f_{\sum_{i=1}^n A_i} \right) d\mu_1 \\ & \stackrel{\text{monotone Konvergenz}}{=} \lim_{n \rightarrow \infty} \left(\int f_{\sum_{i=1}^n A_i} d\mu_1 \right) \\ & = \lim_{n \rightarrow \infty} \left(\sum_{i=1}^n \left(\int f_{A_i} d\mu_1 \right) \right) \\ & = \sum_{i=1}^{\infty} \left(\int f_{A_i} d\mu_1 \right) \end{aligned}$$

Außerdem ist $\int f_{\emptyset} d\mu_1 = \int 0 d\mu_1 = 0$.

Also ist $\Pi : \mathcal{A} \rightarrow [0, \infty]$, $\Pi(A) := \int f_A d\mu_1$ ein Maß auf \mathcal{A} . Nach Konstruktion gilt:

$$\Pi(A_1 \times A_2) = \int \mu_2(A_2) \cdot \mathbf{1}_{A_1} d\mu_1 = \mu_2(A_2) \cdot \mu_1(A_1).$$

Analog ist $\Pi'(A) := \int \mu_1(A_{\omega_2}) \cdot \mu_2(d\omega_2)$ ein Maß mit $\Pi'(A_1 \times A_2) = \mu_1(A_1) \cdot \mu_2(A_2)$, d.h. Π und Π' stimmen auf dem durchschnittstabilen Erzeuger $\{A_1 \times A_2 | A_i \in \mathcal{A}_i\}$ überein. Der Eindeigkeitsatz für Maße (vgl. Übung) liefert $\Pi = \Pi' =: \mu$ auf ganz \mathcal{A} . σ -Endlichkeit ist klar. ■

¹Anmerkung: $\int_{\Omega} f d\mu = \int f(\omega) \mu(d\omega)$

Wie integriert man bzgl. $\mu_1 \otimes \mu_2$?

Ist $f : \Omega \rightarrow \mathbb{R}$ eine Abbildung, so sei

$$\begin{aligned} f_{\omega_1} : \Omega_2 &\rightarrow \mathbb{R}, & f_{\omega_1}(\omega_2) &:= f(\omega_1, \omega_2), \\ f_{\omega_2} : \Omega_1 &\rightarrow \mathbb{R}, & f_{\omega_2}(\omega_1) &:= f(\omega_1, \omega_2). \end{aligned}$$

Lemma 3.3 *Ist $f(\mathcal{A}, \mathfrak{B})$ -messbar, so ist $f_{\omega_1}(\mathcal{A}_2, \mathfrak{B})$ -messbar $\forall \omega_1 \in \Omega_1$ und f_{ω_2} ist $(\mathcal{A}_1, \mathfrak{B})$ -messbar $\forall \omega_2 \in \Omega_2$.*

Beweis

$$\begin{aligned} f_{\omega_1}^{-1}(B) &= \{\omega_2 \in \Omega_2 \mid f(\omega_1, \omega_2) \in B\} \\ &= (\{\omega \in \Omega \mid f(\omega) \in B\})_{\omega_1} \\ &= \left(\underbrace{f^{-1}(B)}_{\in \mathcal{A}} \right)_{\omega_1} \in \mathcal{A}_2 \quad \forall B \in \mathfrak{B}. \quad \blacksquare \end{aligned}$$

Satz 3.1 (Satz von Fubini, Teil I, auch: Satz von Tonelli)

Es seien μ_1 und μ_2 σ -endlich sowie $f : \Omega \rightarrow \mathbb{R}_+$ $(\mathcal{A}, \mathfrak{B})$ -messbar². Dann ist

$$\begin{aligned} \omega_1 &\mapsto \int f_{\omega_1} d\mu_2 \quad (\mathcal{A}_1, \mathfrak{B}_{(-\infty, \infty]})\text{-messbar und} \\ \omega_2 &\mapsto \int f_{\omega_2} d\mu_1 \quad (\mathcal{A}_2, \mathfrak{B}_{(-\infty, \infty]})\text{-messbar und es gilt:} \end{aligned}$$

$$\int f d(\mu_1 \otimes \mu_2) = \int \left(\int f_{\omega_2} d\mu_1 \right) \mu_2(d\omega_2) = \int \left(\int f_{\omega_1} d\mu_2 \right) \mu_1(d\omega_1).$$

Beweis mit algebraischer Induktion.

(1) Falls $f = \sum_{i=1}^n \alpha_i \mathbf{1}_{A_i}$ erhält man mit $(\mathbf{1}_A)_{\omega_2}(\omega_1) = \mathbf{1}_{A_{\omega_2}}(\omega_1)$ die Beziehung

$$\int f_{\omega_2} d\mu_1 \stackrel{\text{lin.}}{=} \sum_{i=1}^n \alpha_i \int \mathbf{1}_{(A_i)_{\omega_2}} d\mu_1 = \sum_{i=1}^n \alpha_i \mu_1((A_i)_{\omega_2})$$

$$\stackrel{\text{L.3.2}}{\implies} \omega_2 \mapsto \int f_{\omega_2} d\mu_1 \text{ ist messbar.}$$

$$\implies \int \left(\int f_{\omega_2} d\mu_1 \right) \mu_2(d\omega_2) = \sum_{i=1}^n \alpha_i \int \mu_1((A_i)_{\omega_2}) \mu_2(d\omega_2)$$

$$\stackrel{\text{D.3.1}}{=} \sum_{i=1}^n \alpha_i \cdot \mu_1 \otimes \mu_2(A_i) = \int f d(\mu_1 \otimes \mu_2).$$

²Dass hier $f \geq 0$ gilt, ist wesentlich für Fubini I; den allgemeinen Fall behandelt Fubini II.

(2) $f \geq 0$, f $(\mathcal{A}, \mathfrak{B})$ -messbar.

$\implies \exists (u_n)_{n \in \mathbb{N}} \subset \mathcal{E}$ mit $u_n \uparrow f$ und $\int f d\mu = \lim_{n \rightarrow \infty} (\int u_n d\mu)$.

Wegen $(u_n)_{\omega_2} \uparrow f_{\omega_2}$ und $g_n(\omega_2) := \int (u_n)_{\omega_2} d\mu_1 \uparrow \int f_{\omega_2} d\mu_1 \forall \omega_2 \in \Omega_2$ ist nach Schritt 1 $\int g_n(\omega_2) \mu_2(d\omega_2) = \int u_n d(\mu_1 \otimes \mu_2)$. Mit dem Satz von der monotonen Konvergenz folgt:

$$\begin{aligned} \int \left(\int f_{\omega_2} d\mu_1 \right) \mu_2(d\omega_2) &= \lim_{n \rightarrow \infty} \left(\int g_n d\mu_2 \right) \\ &= \lim_{n \rightarrow \infty} \left(\int u_n d(\mu_1 \otimes \mu_2) \right) \\ &= \int f d(\mu_1 \otimes \mu_2). \end{aligned}$$

Wiederhole die Schritte mit ω_2 statt mit ω_1 und erhalte den Rest der Behauptung. ■

Bevor wir den Satz von Fubini für allgemeine f beweisen, benötigen wir folgende Überlegung:

Bemerkung 3.1 Ist $(\Omega, \mathcal{A}, \mu)$ Maßraum, $A \in \mathcal{A}$ mit $\mu(A^C) = 0$, $f : A \rightarrow \mathbb{R}$, so nennen wir f $(\mathcal{A}, \mathfrak{B})$ -messbar, μ -integrierbar, etc., wenn dies auf die folgende Fortsetzung \bar{f} von f zutrifft:

$$\bar{f} : \Omega \rightarrow \mathbb{R}, \quad \bar{f}(\omega) := \begin{cases} f(\omega) & \omega \in A \\ 0 & \text{sonst} \end{cases} \quad \text{und schreiben dann } \int f d\mu \text{ statt } \int \bar{f} d\mu.$$

Satz 3.2 (Satz von Fubini, Teil II)

Es seien μ_1 und μ_2 σ -endlich, $f : \Omega \rightarrow \mathbb{R}$ $(\mu_1 \otimes \mu_2)$ -integrierbar.

Dann sind μ_1 -fast alle f_{ω_1} μ_2 -integrierbar und μ_2 -fast alle f_{ω_2} μ_1 -integrierbar.

Weiter sind die Integrale

$$\omega_1 \mapsto \int f_{\omega_1} d\mu_2$$

und

$$\omega_2 \mapsto \int f_{\omega_2} d\mu_1$$

als Funktionen von ω_1 bzw. ω_2 im obigen Sinne μ_1 - bzw. μ_2 -integrierbar und es gilt:

$$\int f d(\mu_1 \otimes \mu_2) = \int \left(\int f_{\omega_2} d\mu_1 \right) \mu_2(d\omega_2) = \int \left(\int f_{\omega_1} d\mu_2 \right) \mu_1(d\omega_1)$$

Beweis

Es gilt $|f|_{\omega_1} = |f_{\omega_1}|$, $f_{\omega_1}^+ = (f_{\omega_1})^+$ und $f_{\omega_1}^- = (f_{\omega_1})^-$.

Also folgt aus Satz 3.1.:

$$\begin{aligned} \int |f| d\mu &= \int \left(\int |f_{\omega_1}| d\mu_2 \right) \mu_1(d\omega_1) < \infty \quad (\text{das ist die Voraussetzung}) \\ \implies \mu_1 \left(\left\{ \omega_1 \mid \int |f_{\omega_1}| d\mu_2 = \infty \right\} \right) &= 0 \\ \implies f_{\omega_1} &\text{ ist } \mu_1\text{-f.ü. } \mu_2\text{-integrierbar.} \end{aligned}$$

Satz 3.1. angewandt auf $f_{\omega_1}^+$ und $f_{\omega_1}^-$ ergibt, dass

$$\omega_1 \mapsto \int f_{\omega_1} d\omega_2 = \left(\int f_{\omega_1}^+ d\mu_2 - \int f_{\omega_1}^- d\mu_2 \right)$$

$(\mathcal{A}, \mathfrak{B})$ -messbar ist (auf einer μ_1 -Nullmenge könnte “ $\infty - \infty$ ” stehen und die Funktion wäre dort nicht definiert, siehe hierzu aber die vorstehende Bemerkung) und

$$\begin{aligned} \int \left(\int f_{\omega_1} d\mu_2 \right) \mu_1(d\omega_1) &= \int \left(\int f_{\omega_1}^+ d\mu_2 - \int f_{\omega_1}^- d\mu_2 \right) \mu_1(d\omega_1) \\ &= \int f^+ d\mu - \int f^- d\mu \\ &= \int f d\mu. \end{aligned}$$

Der Rest folgt mit dem Symmetrieargument. ■

Bemerkung 3.2

a) Der Satz von Fubini läßt sich wie folgt schreiben:

$$\begin{aligned} \int f d(\mu_1 \otimes \mu_2) &= \int \int f(\omega_1, \omega_2) \mu_1(d\omega_1) \mu_2(d\omega_2) \\ &= \int \int f(\omega_1, \omega_2) \mu_2(d\omega_2) \mu_1(d\omega_1) \end{aligned}$$

Die Integrationsreihenfolge spielt also keine Rolle.

b) Sind messbare Räume $(\Omega_i, \mathcal{A}_i)$ ($i \in I$) gegeben mit $|I|$ endlich und $|I| > 2$, so erhält man ein Maß $\mu := \bigotimes_{i \in I} \mu_i$ auf der Produkt- σ -Algebra durch schrittweises Ausführen von Produkten mit 2 Faktoren. Insbesondere gilt auf Rechteckmengen $A_1 \times \cdots \times A_n$ mit $A_i \in \mathcal{A}_i$ ($i = 1, \dots, n$):

$$\mu(A_1 \times \cdots \times A_n) = \prod_{i=1}^n \mu_i(A_i).$$

Da die Rechteckmengen ein durchschnittstabiler Erzeuger von \mathcal{A} sind, folgt wegen der Eindeutigkeit von μ :

$$(\mu_1 \otimes \mu_2) \otimes \mu_3 = \mu_1 \otimes (\mu_2 \otimes \mu_3) \quad (\text{Assoziativität des Maßprodukts})$$

Satz 3.3

Auf (Ω, \mathcal{A}) existiert genau ein Wahrscheinlichkeitsmaß $P := \bigotimes_{i \in I} P_i$ mit

$$P^{\Pi_J} = \bigotimes_{i \in J} P_i \quad \forall J \subset I, J \text{ endlich.}$$

Beweis Siehe z.B. Bauer, Henze, Stochastik II S.8.13. ■

$$\begin{array}{ccc}
\mu & & \mu^T \\
(\Omega, \mathcal{A}) & \xrightarrow{T} & (\Omega', \mathcal{A}') \\
P & & P^{\Pi_J} \\
(\Omega, \mathcal{A}) & \xrightarrow{\Pi_J} & (\times_{i \in J} \Omega_i, \otimes_{i \in J} \mathcal{A}_i)
\end{array}$$

z.B. $P((\times_{i \in J} \mathcal{A}_i) \times (\times_{j \notin J} \Omega_j)) = \prod_{i \in J} P_i(\mathcal{A}_i)$, $A = \times_{i \in J} A_i$

Definition Sei (Ω, \mathcal{A}, P) ein Wahrscheinlichkeitsraum und $(\Omega'_i, \mathcal{A}'_i)$ ein messbarer Raum $\forall i \in I$. $X_i : \Omega \rightarrow \Omega'_i$ seien Zufallsgrößen. Die Familie $(X_i)_{i \in I}$ heißt **stochastisch unabhängig** genau dann, wenn $\forall J \subset I, J$ endlich und $\forall A'_j \in \mathcal{A}'_j, j \in J$

$$\underbrace{P(\cap_{j \in J} \{X_j \in A'_j\})}_{P^X(\times_{j \in J} A'_j \times \times_{i \notin J} \Omega_i)} = \prod_{j \in J} \underbrace{P(X_j \in A'_j)}_{P^{X_j}(A'_j)}$$

Bemerkung Bei der Überprüfung der Bedingung kann man sich auf $A_j \in \mathcal{E}_j$ beschränken, wobei \mathcal{E}_j ein durchschnittsstabiler Erzeuger von \mathcal{A}_j ist.

In der Situation der vorigen Definition gilt für $\Omega' := \times_{i \in I} \Omega_i, \mathcal{A}' := \otimes_{i \in I} \mathcal{A}_i$:

$$X : \Omega \rightarrow \Omega', (X(\omega))(i) := X_i(\omega), \forall i \in I, \omega \in \Omega$$

ist $(\mathcal{A}, \mathcal{A}')$ -messbar (vgl. Ü 2.1), d.h. X transportiert P zu einem Wahrscheinlichkeitsmaß P^X auf (Ω', \mathcal{A}') . P^X nennt man auch **gemeinsame Verteilung** der Zufallsgrößen $X_i, i \in I$.

Satz 3.4

Die Familie $X = (X_i)_{i \in I}$ ist genau dann unabhängig, wenn

$$P^X = \otimes_{i \in I} P^{X_i}$$

Beweis Folgt aus der Definition und S.3.3. ■

Bemerkung

- (i) Unabhängigkeit der $(X_i)_{i \in I}$ ist äquivalent dazu, dass jede endliche Teilfamilie $(X_i)_{i \in J}, J \subset I, (J \text{ endlich})$, unabhängig ist.
- (ii) Sei $\Omega'_i = \mathbb{R}, X = (X_1, \dots, X_d)$ ein Zufallsvektor und $x = (x_1, \dots, x_d) \in \mathbb{R}^d$. $F_X(x_1, \dots, x_d) = P^X((-\infty, x_1] \times \dots \times (-\infty, x_d]) = P(X_1 \leq x_1, \dots, X_d \leq x_d)$ ist die gemeinsame Verteilungsfunktion. Da $\mathcal{E} = \{(-\infty, x] : x \in \mathbb{R}^d\}$ durchschnittsstabiler Erzeuger von \mathfrak{B}^d ist, sind
 X_1, \dots, X_d unabhängig $\iff F_X(x_1, \dots, x_d) = F_{X_1}(x_1) \cdots F_{X_d}(x_d) \forall x \in \mathbb{R}^d$.
 Falls Dichten existieren:
 X_1, \dots, X_d unabhängig $\iff f_X(x_1, \dots, x_d) = f_{X_1}(x_1) \cdots f_{X_d}(x_d) \forall x \in \mathbb{R}^d$

- (iii) Als Wahrscheinlichkeitsraum für das Experiment “ ∞ -oft Münze werfen” kann man z.B. $\Omega = \{0, 1\}^{\mathbb{N}}$, $\mathcal{A} = \otimes_{i \in \mathbb{N}} \mathcal{P}(\{0, 1\})$, $P = \otimes_{i \in \mathbb{N}} (\frac{1}{2}(\delta_0 + \delta_1))$ wählen. S.3.3 impliziert, dass es zu jedem vorgegebenen Wahrscheinlichkeitsmaß eine Folge von unabhängigen und identisch verteilten Zufallsvektoren gibt. Man kann beim Münzexperiment auch $([0, 1], \mathfrak{B}_{[0,1]}, \lambda_{[0,1]})$, $X_n(\omega) = \lfloor 2^n \cdot \omega \rfloor \bmod 2$ wählen. (vgl. Bsp 13.2 St I)

3.2 Reellwertige Abbildungen, Rechnen mit Verteilungen

Wir betrachten den Spezialfall $(\Omega_i, \mathcal{A}_i, \mu_i) = (\mathbb{R}, \mathfrak{B}, \lambda)$ für $i = 1, \dots, d$. Hier folgt: $\Omega = \mathbb{R}^d$, $\mathcal{A} = \otimes_{i=1}^d \mathcal{A}_i = \sigma(\{(a_1, b_1] \times \dots \times (a_d, b_d] : a_i \leq b_i, a_i, b_i \in \mathbb{R}, i = 1, \dots, d\}) = \mathfrak{B}^d$.

$P = \lambda^d, \lambda^d((a_1, b_1] \times \dots \times (a_d, b_d]) = \prod_{i=1}^d (b_i - a_i) \hat{=} \text{Volumen}$. Was passiert, wenn $(a, b]$ mit einer Abbildung Ψ transformiert wird?

Satz 3.5 (Transformationssatz für das d -dimensionale Lebesgue-Maß)

Es seien $U, V \subset \mathbb{R}^d$ offen und $\Psi : U \rightarrow V$ eine bijektive, stetig differenzierbare Abbildung. Gilt dann $\det(\Psi'(x)) \neq 0 \forall x \in U$, so hat das Bildmaß der Einschränkung von λ^d auf U unter Ψ bzgl. der Einschränkung von λ^d auf V die Dichte

$$\frac{d(\lambda_U^d)^\Psi}{d\lambda_V^d}(y) = \frac{1}{|\det \Psi'(\Psi^{-1}(y))|} \quad \forall y \in V.$$

Beweis Henze, Stochastik II. ■

Bemerkung

- (a) Unter den Voraussetzungen von S.3.5 ist auch Ψ^{-1} stetig differenzierbar und die Kettenregel liefert:

$$\det(\Psi'(\Psi^{-1}(y))) \cdot \det((\Psi^{-1})'(y)) = 1.$$

Es gilt also

$$\frac{d(\lambda_U^d)^\Psi}{d\lambda_V^d}(y) = |\det(\Psi^{-1})'(y)| \quad \forall y \in V.$$

- (b) Mit S.2.4 gilt:

$$\int_U f(\Psi(x)) dx \stackrel{\text{S.2.4}}{=} \int_V f(y) d(\lambda_U^d)^\Psi = \int_V f(y) |\det(\Psi^{-1})'(y)| dy$$

bzw.

$$\int_U g(x) dx = \int_V g(\Psi^{-1}(y)) |\det(\Psi^{-1})'(y)| dy$$

Beispiel 3.2 Transformation auf Polarkoordinaten

Hier: $d=2$. $U = \{(x_1, x_2) \in \mathbb{R}^2 : x_1 > 0 \text{ oder } x_2 \neq 0\}$, $V = (0, \infty) \times (-\pi, \pi)$, $\Psi : U \rightarrow V, (x_1, x_2) \xrightarrow{\Psi} (r, \Phi)$ bijektiv. $(\Psi^{-1})_1(r, \Phi) = r \cos \Phi$, $(\Psi^{-1})_2(r, \Phi) = r \sin \Phi$.

$$\implies (\Psi^{-1})'(r, \Phi) = \begin{pmatrix} \cos \Phi & -r \sin \Phi \\ \sin \Phi & r \cos \Phi \end{pmatrix}$$

$$\implies \frac{d(\lambda_U^d)^\Psi}{d(\lambda_V^d)} = r \cos^2 \Phi + r \sin^2 \Phi = r \quad \forall (r, \Phi) \in V.$$

Wir bekommen:

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x_1, x_2) dx_1 dx_2 = \int_{-\pi}^{\pi} \int_0^{\infty} r \cdot g(r \cos \Phi, r \sin \Phi) dr d\Phi$$

Im Folgenden sei $X = (X_1, \dots, X_d) : \Omega \rightarrow \mathbb{R}^d$ ein Zufallsvektor.

Satz 3.6 (Transformationssatz für Wahrscheinlichkeitsdichten)

Es seien U und V offene Teilmengen von \mathbb{R}^d und $\Psi : U \rightarrow V$ eine bijektive, stetige und differenzierbare Abbildung mit der Eigenschaft

$$\det \Psi'(x) \neq 0 \quad \forall x \in U.$$

Ist dann X ein Zufallsvektor auf (Ω, \mathcal{A}, P) mit $P(X \in U) = 1$ und Dichte f_X , so ist auch $Y := \Psi(X)$ absolutstetig und eine Dichte f_Y von Y auf V ist gegeben durch

$$f_Y(y) = |\det(\Psi^{-1})'(y)| f_X(\Psi^{-1}(y)) \quad \forall y \in V$$

Beweis Seien $A \subset V, A \in \mathfrak{B}^d$. Mit Satz 3.5 folgt:

$$\begin{aligned} P(Y \in A) &= P(X \in \Psi^{-1}(A)) \\ &= \int_U \mathbf{1}_{\Psi^{-1}(A)}(x) f_X(x) dx \\ &= \int_V \mathbf{1}_{\Psi^{-1}(A)}(\Psi^{-1}(y)) f_X(\Psi^{-1}(y)) \cdot |\det(\Psi^{-1})'(y)| dy \\ &= \int_A |\det(\Psi^{-1})'(y)| f_X(\Psi^{-1}(y)) dy \end{aligned}$$

■

Beispiel 3.3 (Box-Muller-Algorithmus zur Erzeugung von $N(0, 1)$ -verteilten Zufallsvariablen)

Seien $U_1, U_2 \sim U(0, 1)$ und unabhängig. Definiere:

$$X_1 := \sqrt{-2 \log(U_1)} \cos(2\pi U_2) = \Psi_1(U_1, U_2)$$

$$X_2 := \sqrt{-2 \log(U_1)} \sin(2\pi U_2) = \Psi_2(U_1, U_2)$$

Dann sind $X_1, X_2 \sim N(0, 1)$ und unabhängig. Beweis mit Satz 3.6. Sei $U = (0, 1)^2$

$$\begin{aligned}
 V &= \{(X_1, X_2) \in \mathbb{R}^2 \mid X_1 < 0 \text{ oder } X_2 \neq 0\} \\
 \Psi'(u) &= \begin{pmatrix} -(-2 \log(u_1))^{-\frac{1}{2}} \frac{\cos(2\pi u_2)}{u_1} & -(-2 \log u_1)^{\frac{1}{2}} 2\pi \sin(2\pi u_2) \\ -(-2 \log(u_1))^{-\frac{1}{2}} \frac{\sin(2\pi u_2)}{u_1} & (-2 \log u_1)^{\frac{1}{2}} 2\pi \cos(2\pi u_2) \end{pmatrix} \\
 \Rightarrow \det \Psi' &= -\frac{2\pi}{u_1} \text{ und} \\
 u_1 &= e^{-\frac{1}{2}(x_1^2 + x_2^2)} \\
 \Rightarrow f_X(x) &= \frac{1}{|\det \Psi'(\Psi^{-1}(x))|} \cdot 1 \\
 &= \frac{1}{2\pi} e^{-\frac{1}{2}(x_1^2 + x_2^2)} \\
 &= \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x_1^2} \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x_2^2} \\
 \Rightarrow &\text{ Behauptung}
 \end{aligned}$$

Satz 3.7

Sind X und Y unabhängige Zufallsvariablen mit Dichten f_X und f_Y , so ist auch die Zufallsvariable $Z := X + Y$ absolutstetig und eine zugehörige Dichte ist gegeben durch:

$$f_Z(z) = \int f_X(x) \cdot f_Y(z - x) dx \quad \text{„Faltung“}$$

Beweis Verwende Satz 3.6 mit $\Psi : \mathbb{R}^2 \rightarrow \mathbb{R}^2, \Psi(x, y) = (x, x + y)$ ($\Psi^{-1}(x, z) = (x, z - x)$)

$$\Rightarrow f_{X,Z}(x, z) = f_{X,Y}(x, z - x) = f_X(x) \cdot f_Y(z - x)$$

Die „Randdichte“ f_Z bekommt man durch Integration über x . ■

Beispiel 3.4 a) Sind die Zufallsvariablen X_1, \dots, X_d unabhängig und $X_i \sim \exp(\lambda), i = 1, \dots, d, \lambda > 0$, so hat $X_1 + \dots + X_d$ die Dichte

$$f_{X_1 + \dots + X_d}(z) = \frac{\lambda^d}{(d-1)!} z^{d-1} e^{-\lambda z} \mathbf{1}_{[0, \infty)}(z)$$

(\rightarrow Gamma-Verteilung bzw. Erlang-Verteilung)

b) Sind X_1, \dots, X_d unabhängig und $X_i \sim N(\mu_i, \sigma_i^2), a_i \in \mathbb{R}, i = 1, \dots, d$ so gilt falls $\sum a_i^2 \neq 0$

$$\sum_{i=1}^d a_i X_i \sim N\left(\sum_{i=1}^d a_i \mu_i, \sum_{i=1}^d a_i^2 \sigma_i^2\right)$$

Beispiel 3.5 (Gemeinsame Verteilung der Ordnungsstatistiken)

Es seien X_1, \dots, X_d unabhängige und identisch verteilte Zufallsvariablen mit Dichte f . Weiter sei $(X_{1:d}, \dots, X_{d:d})$ eine Permutation von X_1, \dots, X_d , so dass

$$X_{1:d} < \dots < X_{d:d}$$

$X_{r:d}$ heißt **r -te Ordnungsstatistik** von X .

Sei S_d die Menge der Permutationen der Zahlen $1, \dots, d$. Dann gilt für $\pi \in S_d$:

$$(X_{1:d}, \dots, X_{d:d}) = (X_{\pi(1)}, \dots, X_{\pi(d)}), \text{ falls } X_{\pi(1)} < \dots < X_{\pi(d)}$$

Für jede messbare Funktion $g: \mathbb{R}^d \rightarrow \mathbb{R}$ gilt:

$$g(X_{1:d}, \dots, X_{d:d}) = \sum_{\pi \in S_d} g(X_{\pi(1)}, \dots, X_{\pi(d)}) \cdot \mathbf{1}_{[X_{\pi(1)} < \dots < X_{\pi(d)}]}$$

Es gilt:

$$f_{X_{\pi(1)}, \dots, X_{\pi(d)}}(x_1, \dots, x_d) = \prod_{i=1}^d f(x_i) = f_X(x)$$

Also folgt:

$$\begin{aligned} Eg(X_{1:d}, \dots, X_{d:d}) &= \sum_{\pi \in S_d} \int_{x_1 < \dots < x_d} g(x) \prod_{i=1}^d f(x_i) dx_1 \dots dx_d \\ &= d! \int_{\mathbb{R}^d} g(x) \prod_{i=1}^d f(x_i) \mathbf{1}_{[x_1 < \dots < x_d]}(x) dx_1 \dots dx_d \end{aligned}$$

Sei $g(x) = \mathbf{1}_B(x)$ mit $B \in \mathfrak{B}^d$, dann folgt:

$$f_{X_{1:d}, \dots, X_{d:d}}(x_1, \dots, x_d) = d! \prod_{i=1}^d f(x_i) \mathbf{1}_{[x_1 < \dots < x_d]}(x)$$

Konkrete Anwendung:

Gegeben 12 Trinkgläser. Lebensdauer unabhängig $\exp(\lambda)$ -verteilt. Nach der vorigen Überlegung gilt

$$\begin{aligned} f_{(X_{1:d}, \dots, X_{d:d})}(x) &= \begin{cases} d! \lambda^d e^{-\lambda(x_1 + \dots + x_d)} & , \text{ falls } x_1 < \dots < x_d \\ 0 & , \text{ sonst} \end{cases} \\ \Rightarrow f_{(X_{1:d}, X_{2:d})}(x) &= \begin{cases} d(d-1) \lambda^2 e^{-(d-2)\lambda x_2} e^{-\lambda(x_1 + x_2)} & , \text{ falls } x_1 < x_2 \\ 0 & , \text{ sonst} \end{cases} \\ \xRightarrow{\text{Satz 3.6}} f_{(X_{2:d} - X_{1:d}, X_{1:d})}(y_1, y_2) &= \begin{cases} d(d-1) \lambda^2 e^{-d\lambda y_2} e^{-(d-1)\lambda y_1} & , \text{ falls } y_1, y_2 > 0 \\ 0 & , \text{ sonst} \end{cases} \\ \Rightarrow f_{X_{2:d} - X_{1:d}}(y_1) &= \begin{cases} (d-1) \lambda e^{-(d-1)\lambda y_1} & , \text{ falls } y_1 > 0 \\ 0 & , \text{ sonst} \end{cases} \\ f_{X_{1:d}}(y_2) &= \begin{cases} d \lambda e^{-d\lambda y_2} & , \text{ falls } y_2 > 0 \\ 0 & , \text{ sonst} \end{cases} \end{aligned}$$

also $X_{1:d} \sim \exp(\lambda d)$, $X_{2:d} - X_{1:d} \sim \exp(\lambda(d-1))$ und unabhängig.

$$\Rightarrow X_{k:d} - X_{(k-1):d} \sim \exp((d-k+1)\lambda)$$

Es folgt:

$$\begin{aligned}
 E[X_{k:d} - X_{(k-1):d}] &= \frac{1}{(d-k+1)\lambda} \\
 \Rightarrow \frac{E[X_{d:d} - X_{(d-1):d}]}{EX_{d:d}} &= \frac{\frac{1}{\lambda}}{\sum_{k=1}^d \frac{1}{(d-k+1)\lambda}} \\
 &= \left(\sum_{k=1}^d \frac{1}{k} \right)^{-1} \\
 &= (\log d)^{-1} + O(1)
 \end{aligned}$$

Für $d = 12$: 0.32

4 Das starke Gesetz der großen Zahlen

Satz 4.1 (Borel-Cantelli Lemma) Sei (Ω, \mathcal{A}, P) ein Wahrscheinlichkeitsraum und $(A_n)_{n \in \mathbb{N}} \subset \mathcal{A}$ eine Folge von Ereignissen.

$$\limsup_{n \rightarrow \infty} A_n := \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k$$

ist das Ereignis, dass unendlich viele der A_n 's eintreten.

a) Dann gilt:

$$\sum_{n=1}^{\infty} P(A_n) < \infty \implies P(\limsup_{n \rightarrow \infty} A_n) = 0.$$

b) Sind die Ereignisse A_n , $n \in \mathbb{N}$ stochastisch unabhängig, so gilt:

$$\sum_{n=1}^{\infty} P(A_n) = \infty \implies P(\limsup_{n \rightarrow \infty} A_n) = 1.$$

Beweis

a) Sei $B_n := \bigcup_{k=n}^{\infty} A_k$, $n \in \mathbb{N} \Rightarrow P(B_n) \leq \sum_{k=n}^{\infty} P(A_k) \xrightarrow{n \rightarrow \infty} 0$.
Da $B_n \downarrow \bigcap_{n=1}^{\infty} B_n$ folgt:

$$P(\limsup_{n \rightarrow \infty} A_n) = P\left(\bigcap_{n=1}^{\infty} B_n\right) = \lim_{n \rightarrow \infty} P(B_n) = 0.$$

b) Sei $P_n := P(A_n)$, $n \in \mathbb{N}$. (A_n) stoch. unabh $\Rightarrow (A_n^c)$ stoch unabh. Es gilt:

$$\begin{aligned} 0 \leq P\left(\bigcap_{n=1}^{\infty} A_n^c\right) &\stackrel{\text{stetig von oben}}{=} \lim_{N \rightarrow \infty} P\left(\bigcap_{n=1}^N A_n^c\right) \\ &\stackrel{\text{unabh.}}{=} \lim_{N \rightarrow \infty} \prod_{k=1}^N (1 - P_k) \\ &\leq \lim_{N \rightarrow \infty} \exp\left(-\sum_{k=1}^N P_k\right) \stackrel{\text{nach Vor.}}{=} 0 \end{aligned}$$

Somit:

$$0 \leq P((\limsup_{n \rightarrow \infty} A_n)^c) = P\left(\bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} A_k^c\right) \leq \sum_{n=1}^{\infty} P\left(\bigcap_{k=n}^{\infty} A_k^c\right) = 0$$

■

Definition Es seien X, X_1, X_2, \dots ZV auf einem W-Raum (Ω, \mathcal{A}, P) .

X_n konvergiert P -fast sicher gegen X , $(X_n \xrightarrow{f.s.} X)$ wenn gilt:

$$P\left(\left\{\omega \in \Omega \mid \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\right\}\right) = 1.$$

Bemerkung $\{\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\} \in \mathcal{A}$, denn:

(i) $\sup_{n \geq 1} X_n$ ist \mathcal{A} -messbar, da $\{\sup_{n \geq 1} X_n \leq a\} = \bigcap_{n=1}^{\infty} \underbrace{\{X_n \leq a\}}_{\in \mathcal{A}} \in \mathcal{A}$.

$\inf_{n \geq 1} X_n = -\sup_{n \geq 1} (-X_n)$ ist \mathcal{A} -mb. $\Rightarrow \limsup_{n \rightarrow \infty} X_n = \inf_{n \geq 1} \sup_{k \geq n} X_k, \liminf_{n \rightarrow \infty} X_n$ \mathcal{A} -messbar.

(ii) $\{\lim_{n \rightarrow \infty} X_n = X\} = (\liminf_{n \rightarrow \infty} (X_n - X))^{-1}(\{0\}) \cap (\limsup_{n \rightarrow \infty} (X_n - X))^{-1}(\{0\}) \in \mathcal{A}$

Im Folgenden sei $(X_n)_{n \in \mathbb{N}}$ eine Folge von ZV auf einem W-Raum (Ω, \mathcal{A}, P) . Starke Gesetz der großen Zahlen sind Resultate der Form

$$\frac{1}{a_n} \left(\sum_{i=1}^n X_i - b_n \right) \xrightarrow{f.s.} 0$$

wobei $(a_n)_{n \in \mathbb{N}}, (b_n)_{n \in \mathbb{N}} \subset \mathbb{R}$. Der wichtigste Satz ist hier:

Satz 4.2 (Starkes Gesetz der großen Zahlen) Ist $(X_n)_{n \in \mathbb{N}}$ eine Folge von u.i.v. ZV mit $E|X_1| < \infty$, so gilt:

$$\frac{1}{n} \underbrace{\sum_{i=1}^n X_i}_{=s_n} \xrightarrow{f.s.} EX_1.$$

Beweis Sei zunächst $X_k \geq 0 \forall k \in \mathbb{N}$ und $Y_k := X_k \cdot \mathbf{1}_{[X_k \leq k]}$ (Y_k entsteht aus X_k durch Abschneiden bei k). Sei $S_n^* := \sum_{k=1}^n Y_k$ $EY_k = E[X_k \cdot \mathbf{1}_{[X_k \leq k]}] = E[X_1 \cdot \mathbf{1}_{[X_1 \leq k]}] \xrightarrow{k \rightarrow \infty} EX_1$ mit S.2.1 (Monotone Konvergenz).
Aus der Analysis: Sei $(a_n)_{n \in \mathbb{N}} \subset \mathbb{R}$

$$\lim_{n \rightarrow \infty} a_n = a \Rightarrow \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=1}^n a_k = a.$$

Damit folgt:

$$\lim_{n \rightarrow \infty} \frac{1}{n} ES_n^* = \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=1}^n EY_k = EX_1.$$

Die Y_n 's sind wieder unabhängig und es gilt:

$$\text{Var}(S_n^*) = \sum_{k=1}^n \text{Var}(Y_k) \leq \sum_{k=1}^n EY_k^2 \leq \sum_{k=1}^n E[X_k^2 \cdot \mathbf{1}_{[X_k \leq n]}] = n \cdot E[X_1^2 \cdot \mathbf{1}_{[0, n]}(X_1)] \quad (*)$$

Sei $\alpha > 1$ und $m_n := \lfloor \alpha^n \rfloor \forall n \in \mathbb{N}$. Für $x > 0$ sei $\Psi(x) := \sum_{n=N(x)}^{\infty} \frac{1}{m_n}$ mit $N(x) := \min\{n \mid m_n \geq x\}$

Für beliebige $z \geq 1$ gilt: $\lfloor z \rfloor \geq \frac{z}{2}$ und somit $\frac{1}{m_n} = \frac{1}{\lfloor \alpha^n \rfloor} \leq \frac{2}{\alpha^n}$ und $\alpha^{N(x)} \geq \lfloor \alpha^{N(x)} \rfloor = m_{N(x)} \geq x$. Mit $k := \frac{2\alpha}{\alpha-1}$ gilt:

$$\Psi(x) = \sum_{n=N(x)}^{\infty} \frac{1}{m_n} \leq 2 \cdot \sum_{n=N(x)}^{\infty} \frac{1}{\alpha^n} = 2 \cdot \alpha^{-N(x)} \cdot \frac{1}{1 - \frac{1}{\alpha}} \leq \frac{k}{x} \quad (**)$$

Die Ungleichung von Tschebyscheff liefert $\forall \varepsilon > 0$:

$$\begin{aligned} \sum_{n=1}^{\infty} P\left(\frac{1}{m_n} |S_{m_n}^* - ES_{m_n}^*| > \varepsilon\right) &\stackrel{(*)}{\leq} \sum_{n=1}^{\infty} \frac{1}{\varepsilon^2 m_n} E[X_1^2 \cdot \mathbf{1}_{[0, m_n]}(X_1)] \\ &\stackrel{\text{S.2.1}}{=} \frac{1}{\varepsilon^2} E[X_1^2 \sum_{n=1}^{\infty} \frac{1}{m_n} \cdot \mathbf{1}_{[0, m_n]}(X_1)] \\ &= \frac{1}{\varepsilon^2} E[X_1^2 \Psi(X_1)] \stackrel{(**)}{\leq} \frac{k}{\varepsilon^2} EX_1 \end{aligned}$$

$$\stackrel{\text{Üb}}{\implies} \frac{1}{m_n} (S_{m_n}^* - ES_{m_n}^*) \xrightarrow{f.s.} 0 \stackrel{\text{Üb}}{\implies} \frac{1}{m_n} S_{m_n}^* \xrightarrow{f.s.} EX_1.$$

Nächstes Ziel: * weg bekommen.

Es gilt:

$$\begin{aligned} \sum_{n=1}^{\infty} P(X_n \neq Y_n) &= \sum_{n=1}^{\infty} P(X_1 > n) \\ &\leq \int_{[0, \infty]} P(X_1 > x) \mathbf{1}(x) \stackrel{\text{Bsp 3.1}}{=} EX_1 < \infty. \end{aligned}$$

$$\stackrel{\text{S.4.1a)}}{\implies} P(\underbrace{\{\omega \in \Omega \mid X_n(\omega) \neq Y_n(\omega) \text{ für unendlich viele } n\}}_{=: N_0}) = 0$$

$\forall \omega \notin N_0 \exists k(\omega) \in \mathbb{N}$ mit $X_n(\omega) = Y_n(\omega) \forall n \geq k(\omega)$.

Auf N_0^C gilt also:

$$\begin{aligned} \frac{1}{n} (S_n(\omega) - S_n^*(\omega)) &= \frac{1}{n} \left(\sum_{i=1}^{k(\omega)} X_i(\omega) - Y_i(\omega) \right) \xrightarrow{n \rightarrow \infty} 0 \\ \implies \frac{1}{n} (S_n - S_n^*) &\xrightarrow{f.s.} 0 \implies \frac{1}{m_n} S_{m_n} \xrightarrow{f.s.} EX_1 \quad (\Delta) \end{aligned}$$

Jetzt muss die Einschränkung auf die Teilfolge $(m_n)_{n \in \mathbb{N}}$ weg.

Da $S_n \geq 0$, gilt für $m_n \leq k \leq m_{n+1}$:

$$\frac{m_n}{m_{n+1}} \cdot \frac{S_{m_n}}{m_n} \leq \frac{S_k}{k} \leq \frac{m_{n+1}}{m_n} \cdot \frac{S_{m_{n+1}}}{m_{n+1}}$$

Da $\frac{m_{n+1}}{m_n} \xrightarrow{n \rightarrow \infty} \alpha$ folgt mit (Δ) :

$$\frac{1}{\alpha} EX_1 \leq \liminf_{k \rightarrow \infty} \left(\frac{S_k}{k} \right) \leq \limsup_{k \rightarrow \infty} \left(\frac{S_k}{k} \right) \leq \alpha EX_1 \quad P\text{-f.s.}$$

Sei N_α die Ausnahmемenge zu α in der Konvergenz (Δ) . Da $\alpha > 1$ beliebig, gilt auf

$$\underbrace{\left(\bigcup_{j=1}^{\infty} N_{1+\frac{1}{j}}\right)^C}_{P\text{-Nullmenge}}$$

$$EX_1 \leq \liminf_{k \rightarrow \infty} \left(\frac{S_k}{k}\right) \leq \limsup_{k \rightarrow \infty} \left(\frac{S_k}{k}\right) \leq EX_1$$

$$\implies \overline{X_n} := \frac{1}{n} S_n \xrightarrow{f.s.} EX_1$$

Jetzt muss noch die Bedingung $X_k \geq 0$ weg. Es folgt:

$$\overline{X_n} = \frac{1}{n} \sum_{k=1}^n X_k^+ - \frac{1}{n} \sum_{k=1}^n X_k^- \xrightarrow{f.s.} EX_1^+ - EX_1^- = EX_1.$$

■

Beispiel 4.1 (Wiederholte Spiele)

Gegeben 2 Spieler. Spieler A erzielt in Runde n X_n Punkte und Spieler B Y_n Punkte. Die Zufallsvariablen seien alle unabhängig und identisch verteilt. Es sei $D_n := X_n - Y_n$. Spieler A gewinnt Runde n , falls $D_n > 0$.

Sei $p_n = P(\sum_{k=1}^n D_k > 0)$ die Wahrscheinlichkeit, dass Spieler A nach n Runden mehr Punkte hat. Es gilt nach S.4.2:

$$\frac{1}{n} \sum_{k=1}^n \mathbf{1}_{[D_k > 0]} \xrightarrow{f.s.} E[\mathbf{1}_{[D_1 > 0]}] = p_1.$$

Ist $p_1 > \frac{1}{2}$, so gewinnt Spieler A langfristig mehr Runden als B. Dies gilt jedoch nicht, wenn die Punkte addiert werden! Beispiel dazu:

$$X_k := \begin{cases} n+1, & \text{mit Wahrscheinlichkeit } p_1 \\ 0, & \text{mit Wahrscheinlichkeit } 1-p_1 \end{cases}, \quad Y_k \equiv n \text{ mit Wahrscheinlichkeit } 1$$

$$\text{Sei } p_1 = 0,999, \quad n = 1000. \implies p_{1000} = (0,999)^{1000} \approx 0,37$$

5 Zentraler Grenzwertsatz von Lindeberg-Lévy

5.1 Charakteristische Funktionen

Definition

Es sei X Zufallsvariable auf einem Wahrscheinlichkeitsraum (Ω, \mathcal{A}, P) . Dann heißt

$$\phi_X(t) := Ee^{itX} = E \cos(tX) + iE \sin(tX)$$

die **charakteristische Funktion** zu X .

Bemerkung

Ist X diskret mit Werten x_1, x_2, \dots , so gilt:

$$\phi_X(t) = \sum_{k=1}^{\infty} e^{itx_k} \cdot P(X = x_k)$$

Ist X absolutstetig mit Dichte f , so gilt:

$$\phi_X(t) = \int_{-\infty}^{\infty} e^{itx} f(x) dx \quad (\text{Fourier-Transformation})$$

Beispiel 5.1

a) $X \sim B(n, p)$

$$\begin{aligned} \phi_X(t) &= \sum_{k=0}^n e^{itk} \binom{n}{k} p^k (1-p)^{n-k} \\ &= \sum_{k=0}^n \binom{n}{k} (pe^{it})^k (1-p)^{n-k} = (1-p + pe^{it})^n \end{aligned}$$

b) $X \sim U(0, 1)$

$\phi_X(0) = 1$ und für $t \neq 0$:

$$\begin{aligned} \phi_X(t) &= \int_0^1 e^{itx} \cdot 1 dx = \int_0^1 \cos(tx) dx + i \int_0^1 \sin(tx) dx \\ &= \frac{1}{t} \sin(t) - \frac{i}{t} \cos(t) + \frac{i}{t} = \frac{1}{it} (e^{it} - 1) \end{aligned}$$

c) $X \sim N(0, 1)$

$$\phi_X(t) = e^{-\frac{t^2}{2}} \quad \text{vgl. Stochastik 1}$$

Satz 5.1 Sind X, Y unabhängige Zufallsvariablen mit charakteristischen Funktionen ϕ_X und ϕ_Y , so gilt für die charakteristische Funktion ϕ_{X+Y} der Faltung:

$$\phi_{X+Y}(t) = \phi_X(t) \cdot \phi_Y(t) \quad \forall t \in \mathbb{R}$$

Beweis vgl. Stochastik 1, Satz 12.2. ■

Lemma 5.1 Für alle $m \in \mathbb{N}, t \in \mathbb{R}$ gilt:

$$\left| e^{it} - \sum_{k=0}^{m-1} \frac{(it)^k}{k!} \right| \leq \min \left\{ \frac{|t|^m}{m!}, \frac{2|t|^{m-1}}{(m-1)!} \right\}$$

Beweis vgl. Stochastik 1, Satz 13.2. ■

5.2 Umkehrsätze

Wir werden sehen, dass eine Verteilung eindeutig durch ihre charakteristische Funktion festgelegt ist. Hat man z.B. gezeigt, dass X die charakteristische Funktion $(1 - p + pe^{it})^n$ hat, so ist $X \sim B(n, p)$.

Aus der Analysis ist die Integralsinusfunktion bekannt:

$$Si : \mathbb{R}_+ \rightarrow \mathbb{R}_+, \quad Si(x) := \int_0^x \frac{\sin(y)}{y} dy \quad \forall x > 0$$

Es gilt: $\lim_{x \rightarrow \infty} (Si(x)) = \frac{\pi}{2}$

Satz 5.2

Es sei X Zufallsvariable mit charakteristischer Funktion ϕ_X . Dann gilt für alle $-\infty < a < b < \infty$:

$$\frac{1}{2}P(X = a) + P(a < X < b) + \frac{1}{2}P(X = b) = \lim_{T \rightarrow \infty} \left(\frac{1}{2\pi} \int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} \phi_X(t) dt \right)$$

Beweis

Sei $I(T) := \frac{1}{2\pi} \int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} \phi_X(t) dt$. Definiere $\psi : \mathbb{R} \times [-T, T] \rightarrow \mathbb{C}$ durch

$$\psi(t, x) := \begin{cases} \frac{e^{-it(a-x)} - e^{-it(b-x)}}{it}, & t \neq 0 \\ b - a, & t = 0 \end{cases}$$

Mit Lemma 5.1 folgt, dass ψ stetig ist und wegen

$$\left| \frac{e^{-ita} - e^{-itb}}{it} \right| = \left| \int_a^b e^{ity} dy \right| \leq b - a$$

ist $|\psi| \leq b - a$, also ist $\psi P^X \otimes \lambda_{[-T,T]}$ -integrierbar. Mit Satz 3.1 (Fubini I) folgt:

$$\begin{aligned} I(T) &= \frac{1}{2\pi} \int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} \left(\int e^{itx} P^X(dx) \right) dt \\ &= \frac{1}{2\pi} \int \underbrace{\int_{-T}^T \frac{1}{it} (e^{-it(a-x)} - e^{-it(b-x)}) dt}_{=: \psi_{a,b,T}(x)} P^X(dx) \end{aligned}$$

Inneres Integral:

Da $t \mapsto \frac{\cos(t(x-a))}{it}$ punktsymmetrisch ist, gilt:

$$\psi_{a,b,T}(x) = 2 \cdot \int_0^T \frac{1}{t} \sin((x-a)t) dt - 2 \cdot \int_0^T \frac{1}{t} \sin((x-b)t) dt$$

Es gilt weiterhin:

$$c \cdot \int_0^T \frac{1}{c \cdot t} \sin(ct) dt = \operatorname{sgn}(c) \cdot Si(T|c|) \quad \text{mit } \operatorname{sgn}(c) = \begin{cases} 1, & c > 0 \\ 0, & c = 0 \\ -1, & c < 0 \end{cases}$$

$$\Rightarrow \psi_{a,b,T}(x) = 2 \cdot \operatorname{sgn}(x-a) Si(T|x-a|) - 2 \cdot \operatorname{sgn}(x-b) Si(T|x-b|)$$

$$\Rightarrow \psi_{a,b}(x) := \lim_{T \rightarrow \infty} (\psi_{a,b,T}(x)) = \begin{cases} 0, & x < a \text{ oder } x > b \\ \pi, & x = a \text{ oder } x = b \\ 2\pi, & a < x < b \end{cases}$$

$\Rightarrow (\psi_{a,b,T})_{T \geq 0}$ besitzt eine (konstante) integrierbare Majorante. Mit dem Satz über die majorisierte Konvergenz gilt:

$$\begin{aligned} \lim_{T \rightarrow \infty} I(T) &= \frac{1}{2\pi} \int \psi_{a,b}(x) P^X(dx) \\ &= \frac{1}{2} P(X = a) + \frac{1}{2} P(X = b) + P(a < X < b) \end{aligned}$$

■

Korollar 5.1

Sind X und Y Zufallsvariablen mit derselben charakteristischen Funktion, so haben X und Y dieselbe Verteilung.

Beweis Sei $D = A(X) \cup A(Y)$ mit $A(X) = \{x \in \mathbb{R} | P(X = x) > 0\}$, analog $A(Y)$. $A(X)$ ist abzählbar, da $A(X) = \bigcup_{n=1}^{\infty} \{x \in \mathbb{R} | P(X = x) \geq \frac{1}{n}\}$ und $|\{x \in \mathbb{R} | P(X = x) \geq \frac{1}{n}\}| \leq n \Rightarrow D$ abzählbar

$$\mathcal{D} := \{(a, b) | -\infty < a \leq b < \infty, a, b \notin D\}$$

ist ein durchschnittstabiles Erzeugendensystem von $\mathfrak{B}(\mathbb{R})$. $\xrightarrow{\text{Sa5.2}} P^X$ und P^Y stimmen auf \mathcal{D} überein $\xrightarrow{\text{Eindeutigkeitssatz}}$ Behauptung. ■

Satz 5.3

Sei X eine Zufallsvariable mit charakteristischer Funktion ϕ . Gilt $\int |\phi(t)| dt < \infty$, so hat X eine stetige Dichte f , die gegeben ist durch

$$f(x) = \frac{1}{2\pi} \int e^{-itx} \phi(t) dt \quad \forall x \in \mathbb{R}$$

Beweis Wie in Beweis von Satz 5.2 gilt:

$$\left| \frac{e^{-ita} - e^{-itb}}{it} \right| \leq |b - a| \quad (*)$$

Da ϕ λ -integrierbar ist, ist $|b - a||\phi|$ eine integrierbare Majorante für diesen Ausdruck in Satz 5.2. Es folgt:

$$\frac{1}{2}P(X = a) + P(a < X < b) + \frac{1}{2}P(X = b) = \frac{1}{2\pi} \int \frac{e^{-ita} - e^{-itb}}{it} \phi(t) dt$$

$$\implies P(a < X < b) \leq \frac{1}{2\pi} |b - a| \underbrace{\int |\phi(t)| dt}_{< \infty}$$

$$\begin{aligned} \implies P(X = x) &= \lim_{n \rightarrow \infty} P(x - \frac{1}{n} < X < x + \frac{1}{n}) \\ &= 0 \end{aligned}$$

Ist F die Verteilungsfunktion von X , so gilt:

$$F(b) - F(a) = \frac{1}{2\pi} \int \frac{e^{-ita} - e^{-itb}}{it} \phi(t) dt \quad \forall a < b$$

Wegen (*) kann man den Satz von der majorisierten Konvergenz anwenden und bekommt:

$$\begin{aligned} \lim_{h \downarrow 0} \frac{F(x+h) - F(x)}{h} &= \frac{1}{2\pi} \int e^{-itx} \lim_{h \downarrow 0} \frac{1 - e^{-ith}}{ith} \phi(t) dt \\ &= \frac{1}{2\pi} \int e^{-itx} \phi(t) dt \\ &=: f(x) \end{aligned}$$

Außerdem folgt $x \mapsto f(x)$ ist stetig. ■

5.3 Verteilungskonvergenz

Definition

- a) Gegeben sei der messbare Raum $(\mathbb{R}, \mathfrak{B})$ mit Wahrscheinlichkeitsmaßen P, P_1, P_2, \dots und zugehörigen Verteilungsfunktionen F, F_1, F_2, \dots .
 P_n **konvergiert schwach** gegen P ($P_n \xrightarrow{w} P$), wenn $\lim_{n \rightarrow \infty} F_n(x) = F(x) \forall x \in \mathbb{R}$ an denen F stetig ist.
- b) Seien X, X_1, X_2, \dots Zufallsvariablen auf (unter Umständen verschiedenen) Wahrscheinlichkeitsräumen $(\Omega, \mathcal{A}, P), (\Omega_1, \mathcal{A}_1, P_1), \dots$.
 X_n **konvergiert in Verteilung** gegen X ($X_n \xrightarrow{d} X$), wenn $P^{X_n} \xrightarrow{w} P^X$.

Beispiel 5.2 Konvergenz in Verteilung bzw. schwache Konvergenz ist schwächer als f.s.-Konvergenz.

Sei z.B. $X \sim N(0, 1)$ und $X_{2n} = X, X_{2n+1} = -X \forall n \in \mathbb{N} \implies P^{X_n} \equiv P^X = N(0, 1)$ und (X_n) konvergiert in Verteilung (gegen X) jedoch $X_n \not\xrightarrow{f.s.} X$

Jedoch gilt folgender nützlicher Satz:

Satz 5.4 (Darstellungssatz von Skorohod)

Es seien X, X_1, X_2, \dots Zufallsvariablen mit $X_n \xrightarrow{d} X$. Dann existiert ein Wahrscheinlichkeitsraum (Ω, \mathcal{A}, P) und hierauf Zufallsvariablen X', X'_1, X'_2, \dots mit $X' \stackrel{d}{=} X, X'_n \stackrel{d}{=} X_n \forall n \in \mathbb{N}$ derart, dass $X'_n \xrightarrow{f.s.} X'$.

Beweis Es seien F, F_1, F_2, \dots die Verteilungsfunktionen zu X, X_1, X_2, \dots und $(\Omega, \mathcal{A}, P) = ((0, 1), \mathfrak{B}_{(0,1)}, \lambda_{(0,1)})$. Weiter sei $F^{-1} : (0, 1) \rightarrow \mathbb{R}, F^{-1}(y) := \inf\{x \in \mathbb{R} | F(x) \geq y\}$ die Quantilsfunktion zu F , analog (Quantilsfunktion) $F_n^{-1}, n \in \mathbb{N}$. Setze $X' := F^{-1}, X'_n := F_n^{-1}$.

Satz 5.7 (Stoch 1) $\implies X' \stackrel{d}{=} X, X'_n \stackrel{d}{=} X_n, n \in \mathbb{N} (P(X' \leq x) = P(F^{-1}(\omega) \leq x) = \underbrace{P(\omega \leq F(x))}_{=\lambda_{(0,1)}} = F(x))$

Es bleibt also zu zeigen, dass für P -fast alle $\omega \in \Omega : \lim_{n \rightarrow \infty} X'_n(\omega) = X'(\omega)$.

Sei $\omega \in (0, 1)$. Da X nur abzählbar viele Atome hat (vgl. Beweis von Korollar 5.1) existiert zu $\varepsilon > 0$ ein $x \in \mathbb{R}$ mit $X'(\omega) - \varepsilon < x < X'(\omega)$ und $P(X = x) = 0$.

Es gilt (Lemma 5.6, Stoch 1): $\forall y \in (0, 1), x \in \mathbb{R} :$

$$y \leq F(x) \iff F^{-1}(y) \leq x$$

Hier: $\omega \leq F(x) \iff F^{-1}(\omega) = X'(\omega) \leq x$. Wegen $X'(\omega) > x$ folgt $F(x) < \omega$. Da $F_n(x) \rightarrow F(x)$ für $n \rightarrow \infty$ nach Voraussetzung, $\exists n_0 \in \mathbb{N}$, so dass $\forall n \geq n_0 : F_n(x) < \omega$. Also $X'_n > x$.

Mit $\varepsilon \downarrow 0$ folgt:

$$\liminf_{n \rightarrow \infty} X'_n(\omega) \geq X'(\omega) \quad \forall \omega \in \Omega.$$

Ist $\omega' > \omega$ und $\varepsilon > 0$, so \exists ein x mit $X'(\omega') < x < X'(\omega') + \varepsilon$ und $P(X = x) = 0$. Da F rechtsseitig stetig, folgt $F(F^{-1}(y)) \geq y \forall y \in (0, 1)$, also mit der Monotonie von $F : \omega < \omega' \leq F(X'(\omega')) \leq F(x)$.

Wegen $F_n(x) \rightarrow F(x)$ ($n \rightarrow \infty$), $\exists n_0 \in \mathbb{N}$ sodass $\omega \leq F_n(x)$ (d.h. $X'_n(\omega) \leq x$) $\forall n \geq n_0$ gilt mit $\varepsilon \downarrow 0$ ergibt das

$$\limsup_{n \rightarrow \infty} X'_n(\omega) \leq X'(\omega') \quad \forall \omega' > \omega.$$

Satz 5.5 Es sei $C_b(\mathbb{R})$ die Menge aller stetigen und beschränkten Funktionen, $h : \mathbb{R} \rightarrow \mathbb{R}$. Dann gilt:

$$X_n \xrightarrow{d} X \iff Eh(X_n) \rightarrow Eh(X) \quad \forall h \in C_b(\mathbb{R})$$

Beweis

“ \Rightarrow ”: Nach Satz 5.4 existieren ein Wahrscheinlichkeitsraum (Ω, \mathcal{A}, P) und Zufallsvariablen $X' \stackrel{d}{=} X$, $X'_n \stackrel{d}{=} X_n$ $\forall n \in \mathbb{N}$ mit $X'_n \xrightarrow{f.s.} X'$. Es folgt:

$$\lim_{n \rightarrow \infty} (Eh(X_n)) = \lim_{n \rightarrow \infty} (Eh(X'_n)) \stackrel{h \text{ stetig}, X'_n \xrightarrow{f.s.} X'}{=} Eh(X') = Eh(X).$$

“ \Leftarrow ”: Für $a, b \in \mathbb{R}$, $a < b$ sei $h_{a,b} : \mathbb{R} \rightarrow \mathbb{R}$ definiert durch

$$h_{a,b}(x) := \begin{cases} 1 & , x \leq a \\ \frac{b-x}{b-a} & , a < x < b \\ 0 & , x \geq b \end{cases}$$

$h_{a,b}$ ist stetig und beschränkt. Seien F, F_n die Verteilungsfunktionen zu X, X_n $\forall n \in \mathbb{N}$. Dann gilt $\forall y > x$:

$$\begin{aligned} F_n(x) &= E[\mathbf{1}_{(-\infty, x)}(X_n)] \leq E[h_{x,y}(X_n)] \xrightarrow{n \rightarrow \infty} E[h_{x,y}(X)], \\ E[h_{x,y}(X)] &\leq E[\mathbf{1}_{(-\infty, y)}(X)] = F(y). \end{aligned}$$

Also folgt da F rechtsseitig stetig ist mit $y \downarrow x$:

$$\limsup_{n \rightarrow \infty} (F_n(x)) \leq F(x) \quad \forall x \in \mathbb{R}$$

Analog erhält man für $y < x$:

$$F_n(x) \geq E[h_{y,x}(X_n)] \xrightarrow{n \rightarrow \infty} E[h_{y,x}(X)] \geq F(y)$$

Mit $y \uparrow x$: $\liminf_{n \rightarrow \infty} (F_n(x)) \geq F(x-)$ $\forall x \in \mathbb{R}$.

Ist F in x stetig, so gilt $F(x-) = F(x)$ und somit $F_n(X) \xrightarrow{n \rightarrow \infty} F(x)$. ■

Satz 5.6 (“Continuous Mapping Theorem”)

Es seien X, X_1, X_2, \dots Zufallsvariablen mit $X_n \xrightarrow{d} X$. Weiter sei $f : \mathbb{R} \rightarrow \mathbb{R}$ eine Borel-messbare Funktion mit $P(X \in \{x \in \mathbb{R} \mid f \text{ nicht stetig in } x\}) = 0$.

Dann gilt auch $f(X_n) \xrightarrow{d} f(X)$ für $n \rightarrow \infty$.

Beweis Übung. ■

Satz 5.7 (Satz von Helly¹)

Zu jeder Folge $(F_n)_{n \in \mathbb{N}}$ von Verteilungsfunktionen existieren eine Teilfolge $(F_{n_k})_{k \in \mathbb{N}}$ und eine schwach monoton wachsende, rechtsseitig stetige Funktion $G : \mathbb{R} \rightarrow [0, 1]$, sodass $\lim_{k \rightarrow \infty} (F_{n_k}(x)) = G(x) \quad \forall x \in \mathbb{R}$, an denen G stetig ist.

Beweis (Skizze)

Für $x \in \mathbb{R}$ ist $(F_n(x))_{n \in \mathbb{N}} \subset [0, 1] \xrightarrow{\text{Bolzano-Weierstraß}} \exists \text{ Häufungspunkt. Sei } (r_k)_{k \in \mathbb{N}}$ eine Abzählung von \mathbb{Q} . Wähle Teilfolgen $(F_{n_{k,j}})_{j \in \mathbb{N}}$ mit $F_{n_{k,j}} \xrightarrow{j \rightarrow \infty} G_0(r_k)$, wobei $(n_{k+1,j})_{j \in \mathbb{N}}$ eine Teilfolge von $(n_{k,j})_{j \in \mathbb{N}}$ ist. (Definition der Funktion f_0 auf \mathbb{Q})
Für die Diagonalfolge $(n_{j,j})_{j \in \mathbb{N}}$ gilt dann: $F_{n_{j,j}} \rightarrow G_0$ auf \mathbb{Q} . Sei G_0 auf ganz \mathbb{R} durch $G(x) := \inf\{G_0(r) \mid r \in \mathbb{Q}, r > x\}$ fortgesetzt.
Rest: $\epsilon - \delta$ -Argumente. ■

Bemerkung G aus Satz 5.7 muß keine Verteilungsfunktion sein.

Beispiel: $F_n := \mathbf{1}_{[n, \infty]} \implies G \equiv 0$

Definition Eine Familie \mathcal{P} von Wahrscheinlichkeitsmaßen auf $(\mathbb{R}, \mathfrak{B})$ heißt **straff**, wenn $\forall \epsilon > 0 \exists$ kompaktes Intervall $[a, b] \subset \mathbb{R}$ mit:

$$P([a, b]) \geq 1 - \epsilon \quad \forall P \in \mathcal{P}$$

Bemerkung

- (i) Ist \mathcal{P} straff, so auch jedes $\mathcal{P}' \subset \mathcal{P}$.
- (ii) Sind alle \mathcal{P}_i mit $i \in \{1, \dots, n\}$ straff, so auch $\bigcup_{i=1}^n \mathcal{P}_i$.
- (iii) Ist $|\mathcal{P}| = 1$, so ist \mathcal{P} straff.

Satz 5.8 Ist $\{P_n \mid n \in \mathbb{N}\}$ eine straffe Familie von Wahrscheinlichkeitsmaßen auf $(\mathbb{R}, \mathfrak{B})$, so existieren eine Teilfolge $(P_{n_k})_{k \in \mathbb{N}}$ von $(P_n)_{n \in \mathbb{N}}$ und ein Wahrscheinlichkeitsmaß P derart, dass $P_{n_k} \xrightarrow{w} P$ für $k \rightarrow \infty$.

Beweis Sei F_n die Verteilungsfunktion zu $P_n \quad \forall n \in \mathbb{N}$.

$\xrightarrow{\text{Satz 5.7}} \exists$ Folge $(n_k)_{k \in \mathbb{N}}$ mit $F_{n_k}(x) \rightarrow G(x)$ für $k \rightarrow \infty \quad \forall x \in \mathbb{R}$ mit G stetig in x ; G ist wachsend und rechtsseitig stetig.

Bleibt zu zeigen: G ist Verteilungsfunktion, also $\lim_{x \rightarrow -\infty} (G(x)) = 0$ und $\lim_{x \rightarrow \infty} (G(x)) = 1$. Ist dann P das Wahrscheinlichkeitsmaß zu G , so folgt $P_{n_k} \xrightarrow{w} P$.

Sei also $\epsilon > 0$. Da $\{P_n \mid n \in \mathbb{N}\}$ straff ist $\implies \exists a, b \in \mathbb{R}$ mit $P_n([a, b]) \geq 1 - \epsilon \quad \forall n \in \mathbb{N}$. $\implies F_n(a) \leq \epsilon \quad \forall n \in \mathbb{N}$.

G hat höchstens abzählbar viele Unstetigkeitsstellen. $\implies \exists c < a$, in dem G stetig. $\implies G(c) = \lim_{k \rightarrow \infty} (F_{n_k}(c)) \leq \epsilon \implies G(x) \leq \epsilon \quad \forall x \leq c$.

Also: $\forall \epsilon > 0 \quad \exists c \in \mathbb{R} : \quad \forall x \leq c \text{ gilt } 0 \leq G(x) \leq \epsilon \implies \lim_{x \rightarrow -\infty} (G(x)) = 0$ und $\lim_{x \rightarrow \infty} (G(x)) = 1$. ■

Satz 5.9 (Stetigkeitssatz für charakteristische Funktionen)

Es seien X, X_1, X_2, \dots Zufallsvariablen, $\phi, \phi_1, \phi_2, \dots$ die zugehörigen charakteristischen Funktionen. Dann gilt:

$$X_n \xrightarrow{d} X \iff \phi_n(t) \rightarrow \phi(t) \quad \forall t \in \mathbb{R}$$

Beweis

“ \Rightarrow ”: Sei $t \in \mathbb{R}$. $x \mapsto \cos(tx)$, $x \mapsto \sin(tx)$ sind stetig und beschränkt.

Satz 5.5 $\Rightarrow \phi_n(t) = E \cos(tX_n) + iE \sin(tX_n) \rightarrow E \cos(tX) + iE \sin(tX) = \phi(t)$.

“ \Leftarrow ”: Wir zeigen zunächst: $\{P^{X_n}, n \in \mathbb{N}\}$ ist straff. \mathbb{C} -wertige Version von Fubini II liefert $\forall \delta > 0$.

$$\begin{aligned} \frac{1}{\delta} \int_{-\delta}^{\delta} (1 - \varphi_n(t)) dt &= \int \left(\frac{1}{\delta} \int_{-\delta}^{\delta} (1 - e^{itx}) dt \right) P^{X_n}(dx) \\ &= 2 \int \underbrace{\left(1 - \frac{\sin(\delta x)}{\delta x} \right)}_{\geq 0} P^{X_n}(dx) \\ &\geq 2 \int_{|x| \geq \frac{2}{\delta}} \underbrace{\left(1 - \frac{1}{|\delta x|} \right)}_{\geq \frac{1}{2}} P^{X_n}(dx) \\ &\geq P^{X_n}\left(\left[-\frac{2}{\delta}, \frac{2}{\delta}\right]^C\right) \end{aligned}$$

Sei $\varepsilon > 0$. Da φ in 0 stetig und $\varphi(0) = 1$, $\exists \delta > 0$:

$$|1 - \varphi(t)| \leq \frac{\varepsilon}{4} \quad \forall |t| \leq \delta$$

$\Rightarrow \left| \frac{1}{\delta} \int_{-\delta}^{\delta} (1 - \varphi(t)) dt \right| \leq \frac{1}{\delta} 2\delta \frac{\varepsilon}{4} = \frac{\varepsilon}{2}$. Da $|\varphi_n| \leq 1$ folgt mit majorisierter Konvergenz:

$$\int_{-\delta}^{\delta} (1 - \varphi_n(t)) dt \xrightarrow{n \rightarrow \infty} \int_{-\delta}^{\delta} (1 - \varphi(t)) dt$$

$\Rightarrow \exists n_0 \in \mathbb{N}$, so dass $\frac{1}{\delta} \int_{-\delta}^{\delta} (1 - \varphi_n(t)) dt \leq \varepsilon \quad \forall n \geq n_0$. $\Rightarrow P^{X_n}\left(\left[-\frac{2}{\delta}, \frac{2}{\delta}\right]\right) \geq 1 - \varepsilon \quad \forall n \geq n_0$.

Außerdem: $\forall n \in \{1, \dots, n_0 - 1\} \exists a_n > 0$ mit $P^{X_n}([-a_n, a_n]) \geq 1 - \varepsilon$ da $P^{X_n}([-m, m]) \rightarrow 1$ für $m \rightarrow \infty$.

Insgesamt: Sei $a := \max\{a_1, \dots, a_{n_0-1}, \frac{2}{\delta}\} \Rightarrow P^{X_n}([-a, a]) \geq 1 - \varepsilon \quad \forall n \in \mathbb{N} \Rightarrow \{P^{X_n}, n \in \mathbb{N}\}$ ist straff.

Annahme: $X_n \xrightarrow{d} X$ gilt nicht.

$\Rightarrow \exists x \in \mathbb{R}$ mit $P(X = x) = 0$ und $P(X_n \leq x) \not\rightarrow P(X \leq x), n \rightarrow \infty$.

d.h. $\exists \varepsilon > 0$ und eine Teilfolge $(X_{n_k})_{k \in \mathbb{N}}$ mit $|P(X_{n_k} \leq x) - P(X \leq x)| \geq \varepsilon \quad \forall k \in \mathbb{N} (*)$.

$\{P^{X_{n_k}}, k \in \mathbb{N}\}$ ist ebenfalls straff $\xrightarrow{S.5.8} \exists$ Teilfolge $(X_{n_{k_j}})_{j \in \mathbb{N}}$ und ein W'maß P_0 mit $P^{X_{n_{k_j}}} \xrightarrow{w} P_0$.

Sei φ_0 charakteristische Funktion zu P_0 . Also folgt mit der Hinrichtung: $\varphi_{n_{k_j}}(t) \rightarrow \varphi_0(t) = \varphi(t) \xrightarrow{Kor. 5.1} P_0 = P^X$, also $X_{n_{k_j}} \xrightarrow{d} X$ und damit $P(X_{n_{k_j}} \leq x) \rightarrow P(X \leq x)$.
Wid zu (*). \blacksquare

Wir benötigen noch folgendes technisches Hilfslemma:

Lemma 5.2

Für alle $z_1, \dots, z_n, w_1, \dots, w_n \in \{z \in \mathbb{C} \mid |z| \leq 1\}$ gilt:

$$\left| \prod_{k=1}^n z_k - \prod_{k=1}^n w_k \right| \leq \sum_{k=1}^n |z_k - w_k|$$

Beweis

$$\begin{aligned} \left| \prod_{k=1}^n z_k - \prod_{k=1}^n w_k \right| &\leq \left| \prod_{k=1}^n z_k - w_1 \prod_{k=2}^n z_k \right| + \left| w_1 \prod_{k=2}^n z_k - w_1 w_2 \prod_{k=3}^n z_k \right| + \dots + \left| w_1 \dots w_{n-1} z_n - \prod_{k=1}^n w_k \right| \\ &= |z_1 - w_1| \underbrace{\left| \prod_{k=2}^n z_k \right|}_{\leq 1} + |z_2 - w_2| \underbrace{|w_1| \left| \prod_{k=3}^n z_k \right|}_{\leq 1} + \dots + |z_n - w_n| \underbrace{\left| \prod_{k=1}^{n-1} w_k \right|}_{\leq 1} \end{aligned} \quad \blacksquare$$

Hauptsatz des Abschnitts:

Satz 5.10 (Zentraler Grenzwertsatz von Lindeberg-Lévy)

Für jedes $n \in \mathbb{N}$ seien $X_{nk}, k = 1, \dots, r_n$ unabhängige Zufallsvariablen (nicht notwendig identisch verteilt) auf einem Wahrscheinlichkeitsraum $(\Omega_n, \mathcal{A}_n, P_n)$ mit $\text{Var}(X_{nk}) = \sigma_{nk}^2 < \infty$ und $EX_{nk} = \mu_{nk} < \infty$. Es sei $s_n^2 := \sum_{k=1}^{r_n} \sigma_{nk}^2 > 0$. Ist dann für alle $\varepsilon > 0$ die **Lindeberg-Bedingung**

$$(L) \quad \lim_{n \rightarrow \infty} \frac{1}{s_n^2} \sum_{k=1}^{r_n} \int_{|X_{nk} - \mu_{nk}| > \varepsilon s_n} (X_{nk} - \mu_{nk})^2 dP_n = 0$$

erfüllt, so gilt mit $n \rightarrow \infty$:

$$\frac{1}{s_n} \sum_{k=1}^{r_n} (X_{nk} - \mu_{nk}) \xrightarrow{d} Z, \quad Z \sim N(0, 1)$$

Bemerkung 5.1 1. Die Lindeberg-Bedingung schließt einen dominierenden Einfluss eines einzelnen Summanden X_{nk} auf die $X_{n1} + \dots + X_{nr_n}$ aus. Insbesondere gilt:

$$\max\{\sigma_{nk}^2 \mid 1 \leq k \leq r_n\} = o(s_n^2) \text{ für } n \rightarrow \infty$$

2. Der ZGWS hat eine lange „Verbesserungsgeschichte“ hinter sich. Gelegentlich ist die Lyapunov-Bedingung einfacher zu verwenden:

$$\lim_{n \rightarrow \infty} \frac{1}{s_n^{2+\delta}} \sum_{k=1}^{r_n} E(|X_{nk} - \mu_{nk}|^{2+\delta}) = 0 \text{ für ein } \delta > 0$$

3. Der Satz liefert eine Begründung für die „Allgegenwart“ der Normalverteilung.

Ein wichtiger Spezialfall ist

Satz 5.11 (ZGWS St. I)

Es seien Y_1, Y_2, \dots u.i.v. ZV mit $EY_1 = \mu < \infty$ und $0 < \text{Var}(Y_1) = \sigma^2 < \infty$. Dann gilt:

$$\frac{Y_1 + \dots + Y_n - n\mu}{\sqrt{n}\sigma} \xrightarrow{d} Z \sim N(0, 1)$$

Beweis Sei $X_{nk} := Y_k, r_n = n, (\Omega_n, \mathcal{A}_n, P_n) = (\Omega, \mathcal{A}, P)$. Es gilt: $s_n^2 = n\sigma^2$ und

$$\frac{1}{s_n^2} \sum_{k=1}^{r_n} \int_{|X_{nk} - \mu_{nk}| > \varepsilon s_n} (X_{nk} - \mu_{nk})^2 dP_n = \frac{1}{\sigma^2} \int_{|Y_1 - \mu_1| > \varepsilon \sqrt{n}\sigma} (Y_1 - \mu_1)^2 dP =: I_n$$

Da $z_n := \mathbf{1}_{(\varepsilon\sqrt{n}\sigma, \infty)}(|Y_1 - \mu_1|)(Y_1 - \mu_1)^2 \leq (Y_1 - \mu_1)^2$ und $\lim_{n \rightarrow \infty} z_n = 0$ folgt mit majorisierter Konvergenz, dass $\lim_{n \rightarrow \infty} I_n = 0$. Also ist die Lindeberg-Bedingung erfüllt und die Behauptung folgt mit Satz 5.10. ■

Beweis Beweis von Satz 5.10

O.B.d.A: $\mu_{nk} = 0$ und $s_n = 1$. Anderfalls ersetze X_{nk} durch $\frac{X_{nk} - \mu_{nk}}{s_n}$.

Idee: Verwende S.5.9: Sei φ_{nk} die charakteristische Funktion von X_{nk} und φ_{s_n} die von $\sum_{k=1}^{r_n} X_{nk}$: $\varphi_{s_n}(t) = \prod_{k=1}^{r_n} \varphi_{nk}(t) \rightarrow \varphi_z(t) = e^{-\frac{t^2}{2}}$

Zu zeigen:

$$\prod_{k=1}^{r_n} \varphi_{nk}(t) \rightarrow \phi_z(t) = e^{-\frac{t^2}{2}} \quad \forall t \in \mathbb{R}$$

Mit Lemma 5.1 ($m = 3$):

$$\begin{aligned} \left| e^{itx} - \left(1 + itx - \frac{1}{2}t^2x^2\right) \right| &\leq \min\left\{\frac{|tx|^3}{3!}, |tx|^2\right\} \quad \forall x \in \mathbb{R} \\ &\leq \min\{|tx|^3, |tx|^2\} \end{aligned}$$

Integral über x liefert (beachte: $EX = 0$)

$$\left| \phi_{n_k}(t) - \left(1 - \frac{1}{2}t^2\sigma_{n_k}^2\right) \right| \leq E \min\{|tX_{n_k}|^2, |tX_{n_k}|^3\} =: M_{n_k}$$

Sei $\varepsilon > 0$ beliebig. Es gilt

$$\begin{aligned} M_{n_k} &\leq \int_{|X_{n_k}| \leq \varepsilon} |tX_{n_k}|^3 dP_n + \int_{|X_{n_k}| > \varepsilon} |tX_{n_k}|^2 dP_n \\ &\leq |t|^3 \varepsilon \sigma_{n_k}^2 + t^2 \int_{|X_{n_k}| > \varepsilon} X_{n_k}^2 dP_n \\ \Rightarrow \sum_{k=1}^{r_n} M_{n_k} &\leq |t|^3 \varepsilon + t^2 \sum_{k=1}^{r_n} \int_{|X_{n_k}| > \varepsilon} X_{n_k}^2 dP_n \xrightarrow{n \rightarrow \infty} \varepsilon |t|^3 + 0 \quad \text{folgt mit (L)} \end{aligned}$$

Mit $\varepsilon \downarrow 0$ folgt:

$$\lim_{n \rightarrow \infty} \sum_{k=1}^{r_n} \left| \phi_{n_k}(t) - \left(1 - \frac{1}{2}t^2\sigma_{n_k}^2\right) \right| = 0 \quad \forall t \in \mathbb{R} \quad (1)$$

Behauptung: $\lim_{n \rightarrow \infty} \left| \prod_{k=1}^{r_n} \phi_{n_k}(t) - \prod_{k=1}^{r_n} \left(1 - \frac{1}{2}t^2\sigma_{n_k}^2\right) \right| = 0 \quad \forall t \in \mathbb{R} \quad (2)$

Beweis: $\forall \varepsilon > 0$ gilt:

$$\begin{aligned} \sigma_{n_k}^2 &\leq \int_{|X_{n_k}| > \varepsilon} X_{n_k}^2 dP_n + \varepsilon^2 \\ \implies \limsup_{n \rightarrow \infty} \max\{\sigma_{n_k}^2 | 1 \leq k \leq r_n\} \\ &\leq \lim_{n \rightarrow \infty} \left(\varepsilon^2 + \sum_{k=1}^{r_n} \int_{|X_{n_k}| > \varepsilon} X_{n_k}^2 dP_n \right) \\ &\stackrel{(L)}{=} \varepsilon^2 + 0 \end{aligned}$$

Mit $\varepsilon \downarrow 0$:

$$\lim_{n \rightarrow \infty} \max\{\sigma_{n_k}^2 | 1 \leq k \leq r_n\} = 0 \quad (3)$$

$$\implies \forall t \in \mathbb{R}, \exists n_0 \in \mathbb{N}, \text{ so dass } \forall n \geq n_0 : |1 - \frac{1}{2}t^2\sigma_{n_k}^2| \leq 1 \quad \forall k \in \{1, \dots, r_n\}$$

$$\implies \text{Für } n \geq n_0 \text{ läßt sich das } \prod \text{ in (2) nach Lemma 5.2 durch die Summe in (1) abschätzen, d.h. (1) } \implies (2)$$

Es bleibt zu zeigen:

$$\lim_{n \rightarrow \infty} \left| \underbrace{\prod_{k=1}^{r_n} \exp\left(-\frac{1}{2}t^2\sigma_{n_k}^2\right)}_{=e^{-\frac{1}{2}t^2}} - \prod_{k=1}^{r_n} \left(1 - \frac{1}{2}t^2\sigma_{n_k}^2\right) \right| = 0 \quad \forall t \in \mathbb{R}$$

Behauptung folgt mit Lemma 5.2 falls

$$\lim_{n \rightarrow \infty} \sum_{k=1}^{r_n} \left| \exp\left(-\frac{1}{2}t^2\sigma_{n_k}^2\right) - 1 + \frac{1}{2}t^2\sigma_{n_k}^2 \right| = 0 \quad (4)$$

Für $x \in \mathbb{R}$ mit $|x| \leq \frac{1}{2}$ gilt $|e^x - 1 - x| \leq \frac{1}{2} \sum_{j=2}^{\infty} |x|^j \leq x^2$

$$\implies \sum_{k=1}^{r_n} \left| \underbrace{\exp\left(-\frac{1}{2}t^2\sigma_{n_k}^2\right) - 1 + \frac{1}{2}t^2\sigma_{n_k}^2}_{=x} \right| \leq \frac{1}{4}t^4 \sum_{k=1}^{r_n} \sigma_{n_k}^4$$

Wegen $\sum_{k=1}^{r_n} \sigma_{n_k}^4 \leq \max\{\sigma_{n_k}^2 | 1 \leq k \leq r_n\} \cdot \underbrace{\sum_{k=1}^{r_n} \sigma_{n_k}^2}_{=1} \xrightarrow{n \rightarrow \infty, (3)} 0$

Also (3) \implies (4) ■

Beispiel 5.3 (Rekorde)

Sei (Ω, \mathcal{A}, P) ein Wahrscheinlichkeitsraum und X_1, X_2, \dots eine Folge von unabhängigen identisch verteilten Zufallsvariablen darauf mit absolutstetiger Verteilungsfunktion F . Setze:

$$R_n := \begin{cases} 1, & \text{falls } X_n > X_i, i = 1, \dots, n-1 \\ 0, & \text{sonst} \end{cases}$$

$R_n = 1 \iff n\text{-ter Versuch ist ein Rekord. } F \text{ stetig} \implies P(X_i = X_j) = 0 \forall i \neq j$

$$\begin{aligned} \implies A &:= \{\omega \in \Omega \mid \exists i \neq j, X_i(\omega) = X_j(\omega)\} \\ &= \bigcup_{i,j \in \mathbb{N}, i \neq j} \{X_i = X_j\} \\ \implies P(A) &= 0 \end{aligned}$$

Sei S_n die Menge der Permutationen der Zahlen $1, \dots, n$. Sei $\Psi_n : \Omega \rightarrow S_n$ gegeben durch

$$\Psi_n = \pi \iff X_{\pi(1)} < X_{\pi(2)} < \dots < X_{\pi(n)}$$

Ψ_n ist messbar, da $\Psi^{-1}(\{\pi\}) = \bigcap_{i=1}^n \underbrace{\{X_{\pi(i)} < X_{\pi(i+1)}\}}_{\in \mathcal{A}}$. Beispiel 3.5 $\implies (X_{\pi(1)}, \dots, X_{\pi(n)}) \stackrel{d}{=}$

$(X_1, \dots, X_n) \forall \pi \in S_n$.

Ist $B := \{(x_1, \dots, x_n) \in \mathbb{R}^n \mid x_1 < \dots < x_n\}$ so gilt:

$$\begin{aligned} P(\Psi_n = \pi) &= P((X_{\pi(1)}, \dots, X_{\pi(n)}) \in B) \\ &= P((X_1, \dots, X_n) \in B) \\ &= P(\Psi_n = \text{id}) \quad \text{unabhängig von } \pi \end{aligned}$$

$$\begin{aligned} \implies P(\Psi_n = \pi) &= \frac{1}{n!} \quad \forall \pi \in S_n \text{ und} \\ P(R_n = 1) &= P(\Psi_n \in \{\pi \in S_n \mid \pi(n) = n\}) = \frac{1}{n} \\ \implies R_n &\sim B(1, \frac{1}{n}) \text{ sind also nicht identisch verteilt} \end{aligned}$$

Wegen $\{R_{n+1} = 1\} \cap \{\Psi_n = \pi\} = \{\Psi_{n+1} = \tilde{\pi}\}$ mit

$$\tilde{\pi}(i) = \begin{cases} \pi(i) & , i \leq n \\ n+1 & , i = n+1 \end{cases}$$

folgt:

$$P(\Psi_n = \pi, R_{n+1} = 1) = \frac{1}{(n+1)!} = \underbrace{P(\Psi_n = \pi)}_{=\frac{1}{n!}} \underbrace{P(R_{n+1} = 1)}_{=\frac{1}{n+1}} \quad \forall \pi \in S_n$$

$$\begin{aligned} \implies \Psi_n \text{ und } R_{n+1} &\text{ sind unabhängig} \\ \implies \text{Da } (R_1, \dots, R_n) &= G(\Psi_n) \text{ sind } R_{n+1} \text{ und } (R_1, \dots, R_n) \text{ unabhängig} \\ \implies P(R_{i_1} = j_1, \dots, R_{i_n} = j_n) &= \\ P(R_{i_1} = j_1, \dots, R_{i_{n-1}} = j_{n-1}) \cdot P(R_{i_n} = j_n) &= \dots \\ P(R_{i_1} = j_1) \cdot \dots \cdot P(R_{i_n} = j_n) &\text{ für } i_1 < i_2 < \dots < i_n, j_1, \dots, j_n \in \{0, 1\}. \\ \implies \text{die Zufallsvariablen } (R_n)_{n \in \mathbb{N}} &\text{ sind unabhängig} \end{aligned}$$

Wie viele Rekorde gibt es unter den ersten n Versuchen?

$$S_n := \sum_{i=1}^n R_i$$

Es gilt:

$$ES_n = \sum_{k=1}^n ER_k = \sum_{k=1}^n \frac{1}{k}$$

$$\text{Var}(S_n) = \sum_{k=1}^n \text{Var}(R_k) = \sum_{k=1}^n \frac{1}{k} \left(1 - \frac{1}{k}\right) = \sum_{k=1}^n \frac{1}{k} - \sum_{k=1}^n \frac{1}{k^2}$$

Insbesondere:

$$\frac{ES_n}{\log n} \xrightarrow{n \rightarrow \infty} 1, \quad \frac{\text{Var}(S_n)}{\log n} \xrightarrow{n \rightarrow \infty} 1$$

Mit dem zentralen Grenzwertsatz (ZGWS) bekommen wir genauere Aussagen: Sei

$$X_{n_k} = R_k, r_n = n \implies s_n = (\text{Var}(S_n))^{\frac{1}{2}}$$

Überprüfen der Lyapunov-Bedingung ($\delta = 1$):

$$E|R_k - \underbrace{ER_k}_{=\frac{1}{k}}|^3 = \underbrace{P(R_k=1)}_{=\frac{1}{k}} \left(1 - \frac{1}{k}\right)^3 + \underbrace{P(R_k=0)}_{=\frac{k-1}{k}} \left(\frac{1}{k}\right)^3 \leq \frac{2}{k}$$

$$\implies 0 \leq \frac{1}{s_n^3} \sum_{k=1}^n E|R_k - ER_k|^3 \leq \frac{1}{s_n^3} \sum_{k=1}^n \frac{2}{k} \rightarrow 0 \text{ für } n \rightarrow \infty$$

Der Zentrale Grenzwertsatz (Satz 5.10) liefert

$$\frac{S_n - ES_n}{\sqrt{\text{Var}(S_n)}} \xrightarrow{d} Z \sim N(0, 1)$$

bzw.

$$\frac{S_n - \log(n)}{\sqrt{\log(n)}} \xrightarrow{d} Z \sim N(0, 1)$$

Also für große n : $P(\log(n) - 1,96\sqrt{\log(n)} \leq S_n \leq \log(n) + 1,96\sqrt{\log(n)}) \approx P(-1,96 \leq Z \leq 1,96) = 0,9$.

Beispiel 5.4 (G. Polya, 1930: Eine Wahrscheinlichkeitsaufgabe zur Kundenwerbung, oder: "Coupon Collector's Problem")

Urne mit n verschiedenen Kugeln, Ziehen mit Zurücklegen

S_n = Anzahl der Züge, bis $r_n = [\phi \cdot n]$, $0 < \phi < 1$ verschiedene Kugeln gezogen werden. Es sei X_{nk} = Anzahl der bis zum Erhalt einer neuen Kugel nötigen Züge, wenn bereits $k-1$ verschiedene Kugeln gezogen (und zurückgelegt) wurden. $X_{n1} := 1$.

$X_{nk} \sim \text{Geo}(\frac{n-k+1}{n})$, d.h. $P(X_{nk} = j) = (\frac{k-1}{n})^{j-1} \cdot \frac{n-k+1}{n}$, $j = 1, 2, \dots$

Falls $Y \sim \text{Geo}(p)$, $p \in (0, 1]$ mit $Y \equiv 1$ bei $p = 1$, gilt:

$$EY = \frac{1}{p}, \quad \text{Var}(Y) = \frac{1-p}{p^2}, \quad EY^4 \leq \frac{24}{p^4}$$

Für $S_n = X_{n1} + \dots + X_{nr_n}$ erhalten wir $\mu_n := ES_n = \sum_{k=1}^{r_n} \frac{n}{n-k+1}$ und $s_n^2 =$

$$\text{Var}(S_n) = \sum_{k=1}^{r_n} \frac{\frac{k-1}{n}}{(\frac{n-k+1}{n})^2} = n \sum_{k=1}^{r_n} \frac{k-1}{(n-k+1)^2}.$$

Wir prüfen die Lyapunov-Bedingung mit $\delta = 2$: Für $Y \sim \text{Geo}(p)$ gilt:

$$E(Y - \frac{1}{p})^4 \leq E(\max\{Y, \frac{1}{p}\})^4 \leq EY^4 + \frac{1}{p^4} \leq \frac{25}{p^4}.$$

Insbesondere ist damit

$$\sum_{k=1}^{r_n} E|X_{nk} - \mu_{nk}|^4 \leq 25 \cdot \sum_{k=1}^{r_n} \frac{1}{(1 - \frac{k-1}{n})^4} \leq 25 \cdot [\phi \cdot n] \cdot \frac{1}{(1 - \phi)^4} = O(n).$$

Wegen $s_n^2 \geq n \cdot \frac{1}{n^2} \sum_{k=1}^{r_n} (k-1) = \frac{1}{n} \cdot \frac{1}{2} (r_n - 1) \cdot r_n \geq \frac{1}{2n} (\phi n - 1) \phi n = \Theta(n)$ folgt damit

$$\lim_{n \rightarrow \infty} \left(\frac{1}{s_n^{2+2}} \sum_{k=1}^{r_n} E|X_{nk} - \mu_{nk}|^{2+2} \right) = 0.$$

Also folgt mit dem Zentralen Grenzwertsatz:

$$\frac{S_n - ES_n}{\sqrt{\text{Var}(S_n)}} \xrightarrow{d} Z \sim N(0, 1)$$

Weiter gilt: $\frac{1}{n} ES_n = \sum_{k=1}^{r_n} \frac{1}{n} \cdot \frac{1}{1 - \frac{k-1}{n}} = \int_0^{\frac{r_n}{n}} \frac{1}{1-x} dx + O(\frac{1}{n}) = \int_0^{\frac{r_n}{n}} \frac{1}{1-x} dx + O(\frac{1}{n}) = \int_0^{\phi} \frac{1}{1-x} dx + O(\frac{1}{n}) = -\log(1 - \phi) + O(\frac{1}{n}).$

Analog: $\lim_{n \rightarrow \infty} (\frac{1}{n} \text{Var}(S_n^2)) = \int_0^{\phi} \frac{x}{(1-x)^2} dx = \frac{\phi}{1-\phi} + \log(1 - \phi).$

Mit $a(\phi) = -\log(1 - \phi)$, $b(\phi) := \sqrt{\frac{\phi}{1-\phi} + \log(1 - \phi)}$ folgt:

$$\frac{S_n - a(\phi)n}{b(\phi)\sqrt{n}} \xrightarrow{d} Z \sim N(0, 1)$$

Beispiel (Numerisches Beispiel)

Wie groß muss ihr Bekanntenkreis sein, damit mit einer Wahrscheinlichkeit von mindestens 0,95 an 180 Tagen im Jahr Geburtstag gefeiert werden kann?

$$\text{Also: } n = 365, \phi = \frac{180}{365}, S_n \leq k \iff \underbrace{\frac{S_n - a(\phi)n}{b(\phi)\sqrt{n}}}_{\approx Z} \leq \frac{k - a(\phi)n}{b(\phi)\sqrt{n}}$$

$$\underbrace{\Phi\left(\frac{k - a(\phi)n}{b(\phi)\sqrt{n}}\right)}_{=1,645} \geq 0,95 \iff k \geq a(\phi)n + 1,645 \cdot b(\phi)\sqrt{n} \implies k \geq 266.$$

Für $\phi = 1$ kann man den Zentralen Grenzwertsatz nicht mehr anwenden:

$$r_n = n, \text{Var}(S_n) = n \sum_{k=1}^n \frac{k-1}{(n-k+1)^2} = n \sum_{k=1}^n \frac{n-k}{k^2} = n^2 \sum_{k=1}^n \frac{1}{k^2} - n \sum_{k=1}^n \frac{1}{k} = n^2 \cdot \frac{\pi^2}{6} + o(n^2).$$

$\text{Var}(X_{n,n}) = \frac{1 - \frac{1}{n}}{\frac{1}{n^2}} = n^2 + o(n^2) \implies$ bei großem n steckt etwa $\frac{6}{\pi^2} \approx 0,61$ der Variabilität der Summe im letzten Summanden. Wir können jetzt eine andere Skalierung finden, allerdings ist die Grenzverteilung dann keine Normalverteilung mehr!

Sei $A_{m,i}$ das Ereignis, dass die Kugel i in den ersten m Ziehungen nicht auftaucht

$$\Rightarrow \{S_n > m\} = \bigcup_{i=1}^n A_{m,i}.$$

(S_n ist die Anzahl der Züge, bis alle n verschiedenen Kugeln mindestens einmal gezogen worden sind)

Mit der Siebformel:

$$P(S_n > m) = \sum_{k=1}^n (-1)^{k+1} \sum_{1 \leq i_1 < i_2 < \dots < i_k \leq n} P\left(\bigcap_{l=1}^k A_{m,i_l}\right) = \sum_{k=1}^{n-1} (-1)^{k+1} \binom{n}{k} \left(1 - \frac{k}{n}\right)^m$$

Sei $c \in \mathbb{R}$ fest, $m_n = [n \log(n) + cn]$. Für $x > -1$ gilt $\log(1+x) \leq x$. Damit: $\log\left(\binom{n}{k} \left(1 - \frac{k}{n}\right)^{m_n}\right) \leq k \log(n) - \log(k!) + \log\left(1 - \frac{k}{n}\right) (n \log(n) + cn - 1) \stackrel{\text{s.o.}}{\leq} k \log(n) - \log(k!) - \frac{k}{n} (n \log(n) + cn - 1) \leq -ck + \frac{k}{n} - \log(k!)$

$$\Rightarrow \left| (-1)^{k+1} \binom{n}{k} \left(1 - \frac{k}{n}\right)^{m_n} \right| \leq \frac{1}{k!} \exp\left(\frac{k}{n} - ck\right) \quad \forall c \in \mathbb{R}.$$

$$\text{Ähnlich: } \lim_{n \rightarrow \infty} (-1)^{k+1} \binom{n}{k} \left(1 - \frac{k}{n}\right)^{m_n} = (-1)^{k+1} \frac{1}{k!} e^{-ck} \quad \forall k \in \mathbb{N}.$$

Insgesamt:

$$\begin{aligned} \lim_{n \rightarrow \infty} \left(P\left(\frac{S_n - n \log(n)}{n} > c\right) \right) &= \lim_{n \rightarrow \infty} (P(S_n > m_n)) \\ &= \lim_{n \rightarrow \infty} \left(\sum_{k=1}^{n-1} (-1)^{k+1} \binom{n}{k} \left(1 - \frac{k}{n}\right)^{m_n} \right) \\ &= \lim_{n \rightarrow \infty} \left(\sum_{k=1}^{\infty} (-1)^{k+1} \binom{n}{k} \left(1 - \frac{k}{n}\right)^{m_n} \right) \\ &\stackrel{\text{maj. Konv.}}{=} \sum_{k=1}^{\infty} \lim_{n \rightarrow \infty} \left((-1)^{k+1} \binom{n}{k} \left(1 - \frac{k}{n}\right)^{m_n} \right) \\ &= \sum_{k=1}^{\infty} \frac{(-1)^{k+1}}{k!} (e^{-c})^k \\ &= 1 - e^{-e^{-c}} \end{aligned}$$

Das Wahrscheinlichkeitsmaß auf $(\mathbb{R}, \mathfrak{B})$ mit der Verteilungsfunktion $F(x) = e^{-e^{-x}} \forall x \in \mathbb{R}$ heißt **Gumbel-Verteilung**.

Also gilt:

$$\frac{S_n - n \log(n)}{n} \xrightarrow{d} Z \sim \text{Gumbel}.$$

Beispiel (Variation des numerischen Beispiels von oben)

Der Bekanntenkreis soll jetzt so groß sein, dass mit einer Wahrscheinlichkeit von mindestens 0,95 täglich gefeiert werden kann.

$$\Rightarrow k \geq 365 \cdot \log(365) \cdot 365 \cdot 2,97 \approx 3237,51 \quad (?)$$

6 Zentraler Grenzwertsatz in \mathbb{R}^n

Definition Es sei $X = (X_1, \dots, X_d)^T$ ein Zufallsvektor.

- a) Ist $EX_i < \infty$, $i = 1, \dots, d$, so heißt $EX := (EX_1, \dots, EX_d)$ **Erwartungswert** von X .
- b) Ist $EX_i^2 < \infty$, $i = 1, \dots, d$, so heißt die $d \times d$ -Matrix $Cov(X) = (Cov(X_i, X_j))_{i,j=1,\dots,d}$ **Kovarianzmatrix** von X .
 Beachte: Die Kovarianzmatrix ist symmetrisch, da $Cov(X_i, X_j) = Cov(X_j, X_i)$, und in der Diagonale steht die Varianz, denn $Cov(X_i, X_i) = Var(X_i)$, jeweils für $i, j = 1, \dots, d$.

Bemerkung a) Es gelten folgende Rechenregeln: Sei $A \in \mathbb{R}^{s \times d}$, $b \in \mathbb{R}^s$
 $E(AX + b) = AEX + b$
 $Cov(AX + b) = A \cdot Cov(X) A^T$

- b) Die 2. Rechenregel impliziert, dass Kovarianzmatrizen stets positiv semidefinit sind.

Definition Es sei $X = (X_1, \dots, X_d)^T$ ein Zufallsvektor. Dann ist

$$\phi_X : \mathbb{R}^d \rightarrow \mathbb{C}, \quad \phi_X(t) = Ee^{it^T X}$$

die **charakteristische Funktion** zu X .

Bemerkung

- a) Es gilt für Zufallsvektoren X, Y :

$$X \stackrel{d}{=} Y \iff \phi_X(t) = \phi_Y(t) \quad \forall t \in \mathbb{R}^d \iff t^T X \stackrel{d}{=} t^T Y \quad \forall t \in \mathbb{R}^d$$

- b) Die **Verteilungskonvergenz** für Zufallsvektoren sei definiert durch
 $X_n \xrightarrow{d} X : \iff Eh(X_n) \rightarrow Eh(X) \quad \forall h \in \mathbb{C}_b(\mathbb{R}^d)$. (vgl. Satz 5.5)
 Auch hier gelten
 $X_n \xrightarrow{d} X \iff \phi_n(t) \rightarrow \phi(t) \quad \forall t \in \mathbb{R}^d$. (vgl. Satz 5.9)
 und das "Continuous Mapping Theorem". (vgl. Satz 5.6)

Satz 6.1 (Cramér-Wold-Technik)

Es seien X, X_1, X_2, \dots d -dimensionale Zufallsvektoren. Dann gilt:

$$X_n \xrightarrow{d} X \iff c^T X_n \xrightarrow{d} c^T X \quad \forall c \in \mathbb{R}^d$$

Beweis

“ \Rightarrow ”: folgt aus dem “Continuous Mapping Theorem” mit $h(x) := c^T x$.

“ \Leftarrow ”: $c^T X_n \xrightarrow{d} c^T X \quad \forall c \in \mathbb{R}^d \xrightarrow{\text{S.5.9}} Ee^{itc^T X_n} \rightarrow Ee^{itc^T X} (n \rightarrow \infty) \quad \forall t \in \mathbb{R}, \forall c \in \mathbb{R}^d$.

$\Rightarrow \phi_n(c) \rightarrow \phi(c) \quad \forall c \in \mathbb{R}^d \quad \Rightarrow X_n \xrightarrow{d} X.$ ■

6.1 Mehrdimensionale Normalverteilung**Definition**

Der Zufallsvektor $X = (X_1, \dots, X_n)^T$ besitzt eine **d -dimensionale Normalverteilung**, falls $c^T X$ eine eindimensionale Normalverteilung besitzt $\forall c \in \mathbb{R}^d$

Bemerkung

X habe eine d -dimensionale Normalverteilung.

Setze $c := e_i$ (Einheitsvektor) für ein $i \in \{1, \dots, d\} \Rightarrow X_i$ ist normalverteilt.

$\Rightarrow \exists EX_i = \mu_i; \text{Var}(X_i) < \infty; EX_i^2 < \infty \Rightarrow \text{Cov}(X_i, X_j) \stackrel{\text{C.S.U.}}{<} \infty$.

Sei $\Sigma := \text{Cov}(X)$. Weiter gilt: $E(c^T X) = c^T \mu; \text{Var}(c^T X) = c^T \Sigma c$.

$\Rightarrow c^T X \sim N(c^T \mu, c^T \Sigma c) \xrightarrow{\text{St.1, Bsp.12.3}} \phi_{c^T X}(t) = Ee^{itc^T X} = e^{ic^T \mu t - \frac{1}{2} c^T \Sigma c t^2} \quad \forall t \in \mathbb{R}.$

$\Rightarrow \phi_X(t) = Ee^{it^T X} = \phi_{t^T X}(1) = e^{it^T \mu - \frac{1}{2} t^T \Sigma t}, t \in \mathbb{R}.$

Wegen obiger Bemerkung, Teil a) folgt:

Die Normalverteilung ist durch μ und Σ festgelegt. Schreibweise: $X \sim N_d(\mu, \Sigma)$

Lemma 6.1 Sei $X \sim N_d(\mu, \Sigma)$, $A \in \mathbb{R}^{s \times d}$, $b \in \mathbb{R}^s$. Dann gilt:

$Y := AX + b \sim N_s(A\mu + b, A\Sigma A^T)$

Beweis

$$\begin{aligned} \phi_Y(t) &= Ee^{it^T(AX+b)} \\ &= e^{it^T b} Ee^{it^T AX} \\ &= e^{it^T b} \phi_X(A^T t) \\ &= e^{it^T(b+A\mu) - \frac{1}{2} t^T (A\Sigma A^T) t} \end{aligned}$$

■

Satz 6.2 (Existenzsatz)

Sei $\mu \in \mathbb{R}^d$ und $\Sigma \in \mathbb{R}^{d \times d}$ eine beliebige symmetrische, positiv semidefinite Matrix. Dann existiert ein d -dimensionaler Zufallsvektor X mit $X \sim N_d(\mu, \Sigma)$.

Beweis

Sei $Y = (Y_1, \dots, Y_d)$, wobei Y_1, \dots, Y_d unabhängig und $Y_k \sim N(0, 1)$, $k = 1, \dots, d$. Die Existenz dieser Konstruktion ist mit Satz 3.3 gegeben. Da $c^T Y \sim N(0, c^T c)$, ist $Y \sim N_d(0, I_d)^1$

Σ positiv semidefinit $\Rightarrow \Sigma = AA^T$ mit einem $A \in \mathbb{R}^{d \times d} \xrightarrow{\text{L.6.1}} X := AY + \mu \sim N_d(\mu, \Sigma).$ ■

¹das ist die d -dimensionale Standardnormalverteilung

Satz 6.3 Sei $X \sim N_d(\mu, \Sigma)$ und Σ nicht singulär. Dann besitzt X eine Dichte der Form

$$f(x) = \frac{1}{(2\pi)^{\frac{d}{2}} |\det \Sigma|^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right), \quad x \in \mathbb{R}^d$$

Beweis Sei $\Sigma = AA^T$ und $X = A \cdot Y + \mu$ mit $Y \sim N_d(0, I_d)$.
Dichte von Y :

$$f_Y(y_1, \dots, y_d) = \prod_{j=1}^d \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}y_j^2} = \frac{1}{(2\pi)^{\frac{d}{2}}} \exp\left(-\frac{1}{2}y^T y\right)$$

Sei $\Psi(y) = Ay + \mu$. Ψ ist bijektiv, Σ regulär.

$$\xrightarrow{\text{Satz 3.6}} \Rightarrow f_X(x) = \frac{1}{|\det A|} \cdot f_Y(A^{-1}(x - \mu))$$

Beachte: $\det \Sigma = (\det A)^2$, $\Sigma^{-1} = (A^{-1})^T(A^{-1})$. ■

Bemerkung Ist $\det \Sigma = 0 \Rightarrow \exists a \in \mathbb{R}^d$, $a \neq 0$ mit $a^T \Sigma a = 0 \Rightarrow \text{Var}(a^T X) = 0$.
 $N(\mu, \Sigma)$ ist dann auf $H = \{x \in \mathbb{R}^d \mid a^T x = a^T \mu\}$ konzentriert, d.h. $P^X(H) = 1$.
Wegen $\lambda^d(H) = 0$ folgt mit dem Satz von Radon-Nikodym: \nexists Dichte.

6.2 Zentraler Grenzwertsatz in \mathbb{R}^d

Satz 6.4 Es sei $(X_n)_{n \in \mathbb{N}}$ eine Folge von unabh. u. identisch verteilten d -dim Zufallsvektoren mit Erwartungsvektor μ und Kovarianzmatrix Σ . Dann gilt für $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$:

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} Z, \quad Z \sim N_d(0, \Sigma).$$

Beweis Sei $Z_n := \sqrt{n}(\bar{X}_n - \mu)$.

Nach Satz 6.1 ist z.z. $c^T Z_n \xrightarrow{d} c^T Z \quad \forall c \in \mathbb{R}^d$.

Wegen $\text{Var}(c^T Z_n) = \frac{1}{n} \sum_{i=1}^n \text{Var}(c^T X_i) = c^T \Sigma c$, $E c^T Z_n = 0$ können wir o.B.d.A. $c^T \Sigma c > 0$ annehmen (andernfalls ist $c^T Z_n \equiv 0$).

$$\begin{aligned} 1 - \dim \text{ZGWS} : \quad & \frac{c^T Z_n}{\sqrt{c^T \Sigma c}} = \frac{\sum_{j=1}^n c^T X_j - n c^T \mu}{\sqrt{n c^T \Sigma c}} \xrightarrow{d} Z_0, \quad Z_0 \sim N(0, 1) \\ \Rightarrow \quad & c^T Z_n \xrightarrow{d} \sqrt{c^T \Sigma c} \cdot Z_0 \sim N(0, c^T \Sigma c) \end{aligned} \quad \blacksquare$$

Beispiel 6.1 (χ^2 -Anpassungstest) Es seien X_1, X_2 unabh. u. identisch verteilte, d -dim. Zufallsvektoren mit

$$P(X_1 = e_k) = p_k, \quad k = 1, \dots, d, \quad \sum_{k=1}^d p_k = 1.$$

Dann hat $S_n = \sum_{k=1}^n X_k$ eine Multinomialverteilung (vgl. Sto. I) mit Zähldichte:

$$P(S_n = (k_1, \dots, k_d)) = \frac{n!}{k_1! \dots k_d!} p_1^{k_1} \dots p_d^{k_d}$$

für $k_1, \dots, k_d \in \mathbb{N}_0$, $k_1 + \dots + k_d = n$.

Weiter gilt: $EX_1 = p := (p_1, \dots, p_d)^T$, $\text{Cov}(X_1) = \Sigma$ mit

$$(\Sigma)_{ij} = \begin{cases} p_i(1 - p_i), & i = j \\ -p_i p_j, & i \neq j \end{cases} \Rightarrow \Sigma = \text{diag}(p) - pp^T.$$

ZGWS (Satz 6.4):

$$\frac{1}{\sqrt{n}}(S_n - np) \xrightarrow{d} Z, \quad Z \sim N_d(0, \Sigma)$$

Anmerkung: Wir kennen p_1, \dots, p_d nicht, nur die Realisierungen von X_1, \dots, X_n . Betrachte die Testgröße $T_n := \sum_{i=1}^d \frac{1}{np_i} (S_{n,i} - np_i)^2$.

Aufgabe: Zu (p_1, \dots, p_d) , X, n gegeben, bestimme c_α mit $P(T_n > c_\alpha) = \alpha$. Also: Bestimme Verteilung von T_n .

Lösung: Approximativ. Sei $h: \mathbb{R}^d \rightarrow \mathbb{R}$, $h(x_1, \dots, x_d) := \sum_{j=1}^d \frac{x_j^2}{p_j}$.

$$h \text{ stetig} \xrightarrow{\text{Cont. mapping}} \Rightarrow T_n = h\left(\frac{1}{\sqrt{n}}(S_n - np)\right) \xrightarrow{d} h(Z), \quad Z \sim N_d(0, \Sigma)$$

Welche Verteilung hat $h(Z)$?

Sei $\tilde{Z} = \text{diag}\left(\frac{1}{\sqrt{p_1}}, \dots, \frac{1}{\sqrt{p_d}}\right) \cdot Z$. $\xrightarrow{\text{Lemma 6.1}} \Rightarrow \tilde{Z} \sim N_d(0, \tilde{\Sigma})$ wobei

$$\begin{aligned} \tilde{\Sigma} &= \text{diag}\left(\frac{1}{\sqrt{p_1}}, \dots, \frac{1}{\sqrt{p_d}}\right) \cdot (\text{diag}(p) - pp^T) \cdot \text{diag}\left(\frac{1}{\sqrt{p_1}}, \dots, \frac{1}{\sqrt{p_d}}\right) \\ &= I_d - \underbrace{(\sqrt{p_1}, \dots, \sqrt{p_d})^T \cdot (\sqrt{p_1}, \dots, \sqrt{p_d})}_{=: r} \\ &= I_d - rr^T \end{aligned}$$

Es gilt: $\|r\| = 1 \Rightarrow \exists$ orthogonale Matrix $A = (r, *) \in \mathbb{R}^{d \times d}$. Sei $Y := A^T \tilde{Z} \Rightarrow Y \sim N_d(0, \Sigma_Y)$, wobei $\Sigma_Y = A^T \tilde{\Sigma} A = I_d - \text{diag}(1, 0, \dots, 0) = \text{diag}(0, 1, \dots, 1)$.

$\Rightarrow Y^T Y \stackrel{d}{=} \sum_{i=1}^{d-1} W_i^2$, $W_i \sim N(0, 1)$ unabh. $\Rightarrow h(Z) = \tilde{Z}^T \tilde{Z} = Y^T Y \sim \chi_{d-1}^2$, Chi²-Verteilung mit $d - 1$ Freiheitsgraden.

Zahlenbeispiel:

Würfel wird 189 mal geworfen.

Ergebnis	1	2	3	4	5	6
	30	37	26	29	29	38

Ist der Würfel fair?

D.h. $p_1 = \dots = p_6 = \frac{1}{6}$.

$T_n = 3, 37$, $d - 1 = 5$, $\alpha = 0, 05$, $p = (\frac{1}{6}, \dots, \frac{1}{6})$

$P(T_n > c_\alpha) \stackrel{!}{=} 0, 05 \Leftrightarrow 1 - F_{\chi_5^2}(c_\alpha) \stackrel{!}{=} 0, 05 \Rightarrow c_\alpha = 11, 1$. d.h. Nullhypothese „Würfel fair“ kann nicht abgelehnt werden.

7 Bedingte Erwartungswerte und Bedingte Verteilungen

Sei (Ω, \mathcal{A}, P) ein W'Raum, (Ω', \mathcal{A}') ein Messraum, $Y : \Omega \rightarrow \Omega'$ sei $(\mathcal{A}, \mathcal{A}')$ -messbar und nehme die Werte $y_1, \dots, y_n \in \Omega'$ an. $Y^{-1}(y_k) = \{\omega \in \Omega \mid Y(\omega) = y_k\} =: A_k \Rightarrow \Omega = A_1 + \dots + A_n$ und $\sigma(Y) = \{\sum_{k \in I} A_k \mid I \subset \{1, \dots, n\}\}$.

Definition Sei $X : \Omega \rightarrow \mathbb{R}$ eine ZV mit $E|X| < \infty$. Dann ist der bedingte Erwartungswert von X unter der Bedingung $Y = y_k$ definiert durch:

$$E[X|Y = y_k] := \frac{1}{P(A_k)} \int_{A_k} X dP, \quad k = 1, \dots, n$$

Falls X diskret mit x_1, \dots, x_m :

$$\begin{aligned} E[X|Y = y_k] &= \frac{1}{P(Y = y_k)} \sum_{j=1}^m x_j \cdot P(X = x_j, Y = y_k) \\ &= \sum_{j=1}^m x_j \cdot P(X = x_j | Y = y_k) \end{aligned}$$

Definition Der *bedingte Erwartungswert von X gegeben Y* ist $E[X|Y] : \Omega \rightarrow \mathbb{R}$ mit

$$E[X|Y](\omega) := \sum_{k=1}^n E[X|Y = y_k] \cdot \mathbf{1}_{[Y=y_k]}(\omega)$$

Bemerkung a) Offenbar ist $E[X|Y]$ $(\sigma(Y), \mathfrak{B})$ -messbar.

b) Sei $Z := E[X|Y]$. Dann gilt

$$\begin{aligned} \int_{A_k} Z dP &= \int_{\Omega} \mathbf{1}_{A_k} Z dP \\ &= E[X, Y = y_k] \cdot P(A_k) \\ &= \int_{A_k} X dP \end{aligned}$$

Wegen der Struktur von $\sigma(Y)$ folgt auch

$$\int_A Z dP = \int_A X dP \quad \forall A \in \sigma(Y)$$

c) $E[X|Y] = g(Y)$ mit

$$g(y) = \sum_{k=1}^n E[X|Y = y_k] \cdot \mathbf{1}_{\{y_k\}}(y)$$

- d) Offenbar hängt die Definition von $E[X|Y]$ nur davon ab, auf welchen Mengen A_k Y die verschiedenen Werte annimmt, nicht aber welche Werte das genau sind.

Deshalb schreibt man auch:

$$E[X|Y] = E[X|\sigma(Y)]$$

Beispiel 7.1 Sei $([0, 1), \mathfrak{B}_{[0,1)}, \underbrace{\lambda_{[0,1)}}_{=:P}), X(\omega) = \omega$

- Hier fehlt ein Bild -

$$A_k = \left[\frac{k-1}{n}, \frac{k}{n} \right), k = 1, \dots, n, \quad \mathfrak{F} := \left\{ \sum_{k \in I} A_k \mid I \subset \{1, \dots, n\} \right\}$$

$$\begin{aligned} E[X, A_k] &= \frac{1}{P(A_k)} \int_{A_k} \omega P(d\omega) \\ &= n \int_{\frac{k-1}{n}}^{\frac{k}{n}} \omega d\omega \\ &= \frac{1}{2} \frac{2k-1}{n} \end{aligned}$$

$E[X, \mathfrak{F}]$ ist also eine „Approximation“ oder „Vergröberung“ von X . Bezüglich einer beliebigen Sub- σ -Algebra $\mathfrak{F} \subset \mathcal{A}$ wird der bedingte Erwartungswert wie folgt definiert:

Definition Sei X eine Zufallsvariable mit $E|X| < \infty$ und $\mathfrak{F} \subset \mathcal{A}$ eine Sub- σ -Algebra von \mathcal{A} . Dann heißt $Z : \Omega \rightarrow \mathbb{R}$ **eine Version des bedingten Erwartungswertes $E[X|\mathfrak{F}]$ von X unter \mathfrak{F}** , wenn gilt

(i) Z ist \mathfrak{F} -messbar

(ii) $\int_A Z dP = \int_A X dP \quad \forall A \in \mathfrak{F}$

Satz 7.1

Der bedingte Erwartungswert existiert und ist bis auf Nullmengen eindeutig.

Beweis Sei $X \geq 0$. Durch

$$Q(A) := \int_A X(\omega) P(d\omega) \quad \forall A \in \mathfrak{F}$$

wird ein Maß auf (Ω, \mathfrak{F}) definiert (Satz 2.7).

Sei $P_{\mathfrak{F}}$ die Einschränkung von P auf \mathfrak{F} . Offenbar $Q \ll P_{\mathfrak{F}}$. Satz von Radon-Nikodym $\implies Q$ besitzt eine Dichte Z bzgl. $P_{\mathfrak{F}}$ und Z ist nach Definition \mathfrak{F} -messbar.

Falls X beliebig: $X = X^+ - X^-$

P-f.s. Eindeutigkeit: Seien Z, \tilde{Z} Versionen von $E[X, \mathfrak{F}]$.

$$\implies \int_A (Z - \tilde{Z}) dP = 0 \quad \forall A \in \mathfrak{F}$$

Wegen $\{Z > \tilde{Z}\} \in \mathfrak{F}, \{Z < \tilde{Z}\} \in \mathfrak{F}$ folgt:

$$E|Z - \tilde{Z}| = \int_{\{Z > \tilde{Z}\}} (Z - \tilde{Z}) dP - \int_{\{Z < \tilde{Z}\}} (Z - \tilde{Z}) dP = 0$$

$\implies Z = \tilde{Z}$ P-f.s. ■

Bemerkung Der bedingte Erwartungswert ist also eigentlich die Äquivalenzklasse

$$E[X|\mathfrak{F}] = \left\{ Z \in L^1(\Omega, \mathfrak{F}, P) \mid \int_A Z dP = \int_A X dP \ \forall A \in \mathfrak{F} \right\}$$

Ein Element davon nennt man „Version“. Oft wird $E[X|\mathfrak{F}]$ mit einer Version identifiziert.

Definition Sei $A \in \mathfrak{F}$. Eine Version von $E[\mathbf{1}_A|\mathfrak{F}]$ bezeichnet man als **Version der bedingten Wahrscheinlichkeit** $P(A|\mathfrak{F})$.

Bemerkung Es gilt für $B \in \mathfrak{F}$:

$$\int_B P(A|\mathfrak{F}) dP \stackrel{(ii)}{=} \int_B \mathbf{1}_A dP = P(A \cap B)$$

Satz 7.2

Sei $X \in L^2(\Omega, \mathcal{A}, P)$ mit $\|X\|^2 = EX^2$. Dann gilt:

$$\|X - E[X|\mathfrak{F}]\|^2 = \inf \{ \|X - Y\|^2 \mid Y \in L^2(\Omega, \mathfrak{F}, P) \}$$

Beweis siehe Henze Stochastik II, S.214 ■

Satz 7.3 (Rechenregeln für bedingte Erwartungswerte)

Es seien $X, Y \in L^1(\Omega, \mathcal{A}, P)$, $\mathfrak{F}, \mathfrak{F}_1, \mathfrak{F}_2$ Sub- σ -Algebren von \mathcal{A} . Dann gilt:

a) $E[aX + bY|\mathfrak{F}] = aE[X|\mathfrak{F}] + bE[Y|\mathfrak{F}]$ P-f.s. $a, b \in \mathbb{R}$

b) $E[E[X|Y]] = EX$

c) $X \leq Y \implies E[X|\mathfrak{F}] \leq E[Y|\mathfrak{F}]$ P-f.s.

d) Für $\mathfrak{F}_1 \subset \mathfrak{F}_2$ gilt $E[E[X|\mathfrak{F}_2]|\mathfrak{F}_1] = E[X|\mathfrak{F}_1]$

Für $\mathfrak{F}_1 \supset \mathfrak{F}_2$ gilt $E[E[X|\mathfrak{F}_2]|\mathfrak{F}_1] = E[X|\mathfrak{F}_2]$

e) Falls Y \mathfrak{F} -messbar und $EXY < \infty$ gilt:

$$E[XY|\mathfrak{F}] = YE[X|\mathfrak{F}]$$

f) Falls X von \mathfrak{F} unabhängig ist (d.h. falls die X und $\mathbf{1}_A \ \forall A \in \mathfrak{F}$ unabhängig sind), dann gilt:

$$E[X|\mathfrak{F}] = EX$$

Bemerkung Aus Satz 7.3 bekommt man:

1. $X \equiv c \in \mathbb{R} \xrightarrow{f)} E[c|\mathfrak{F}] = c$
2. $\mathfrak{F} = \{\emptyset, \Omega\} \xrightarrow{f)} E[X|\mathfrak{F}] = EX$
3. $X \text{ } \mathfrak{F}\text{-messbar} \xrightarrow{e)} E[X|\mathfrak{F}] = X$
4. $X \geq 0 \xrightarrow{c)} E[X|\mathfrak{F}] \geq 0 \text{ P-f.s.}$

Beweis von Satz 7.3:

a)

$$\begin{aligned}
 \int_A E[aX + bY|\mathfrak{F}]dP &= \int_A aX + bYdP \\
 &\stackrel{\text{Linearität}}{=} a \int_A XdP + b \int_A YdP \\
 &= a \int_A E[X|\mathfrak{F}]dP + b \int_A E[Y|\mathfrak{F}]dP \\
 &= \int_A (aE[X|\mathfrak{F}] + bE[Y|\mathfrak{F}])dP \quad \forall A \in \mathfrak{F}
 \end{aligned}$$

\implies Behauptung, da $aE[X|\mathfrak{F}] + bE[Y|\mathfrak{F}]$ \mathfrak{F} -messbar und Radon-Nikodym-Dichte P -f.s. eindeutig.

b)

$$E[E[X|\mathfrak{F}]] = \int_{\Omega} E[X|\mathfrak{F}]dP = \int_{\Omega} XdP = EX$$

c)

$$\begin{aligned}
 A &:= \{\omega \in \Omega \mid E[X|\mathfrak{F}](\omega) > E[Y|\mathfrak{F}](\omega)\} \in \mathfrak{F} \\
 &= \bigcup_{n \in \mathbb{N}} \underbrace{\left\{ \omega \in \Omega \mid E[X|\mathfrak{F}](\omega) > E[Y|\mathfrak{F}](\omega) + \frac{1}{n} \right\}}_{A_n}
 \end{aligned}$$

Annahme: $P(A) > 0 \implies \exists n \in \mathbb{N}$ mit $P(A_n) > 0$

$$\begin{aligned}
 \implies 0 &\leq \int_{A_n} (Y - X)dP \\
 &= \int_{A_n} E[Y|\mathfrak{F}]dP - \int_{A_n} E[X|\mathfrak{F}]dP \\
 &= \int_{A_n} (E[Y|\mathfrak{F}] - E[X|\mathfrak{F}])dP \\
 &\leq -\frac{1}{n} \cdot P(A_n) \\
 &< 0 \quad \text{Widerspruch!}
 \end{aligned}$$

d) Z.z. Für $\mathfrak{F}_1 \subset \mathfrak{F}_2$ gilt: $E[E[X|\mathfrak{F}_2]|\mathfrak{F}_1] = E[X|\mathfrak{F}_1]$. Sei $A \in \mathfrak{F}_1 \implies A \in \mathfrak{F}_2$ und

$$\int_A E[X|\mathfrak{F}_1]dP = \int_A XdP = \int_A E[X|\mathfrak{F}_2]dP = \int_A E[E[X|\mathfrak{F}_2]|\mathfrak{F}_1]dP$$

\implies Behauptung, da Radon-Nikodym-Dichte eindeutig.

Für $\mathfrak{F}_1 \supset \mathfrak{F}_2$ ähnlich.

e) Mit algebraischer Induktion:

– Sei $Y = \mathbf{1}_B$, $B \in \mathfrak{F}$ und $A \in \mathfrak{F}$ beliebig.

$$\int_A Y \cdot E[X|\mathfrak{F}]dP = \int_{A \cap B} E[X|\mathfrak{F}]dP = \int_{A \cap B} XdP = \int_A YXdP$$

Außerdem ist $Y \cdot E[X|\mathfrak{F}]$ \mathfrak{F} -messbar \implies Behauptung, da Radon-Nikodym-Dichte P -f.s. eindeutig.

– Linearität des Integrals + Teil a) \implies Aussage für $Y \in \mathcal{E}, Y \geq 0$:
Bedingte Version des Satzes von der monotonen Konvergenz (\rightarrow Übung).

– Dann $Y = Y^+ - Y^-$

f)

$$\begin{aligned} \int_A E[X|\mathfrak{F}]dP &= \int_A XdP \\ &= \int_{\Omega} \mathbf{1}_A XdP \\ &\stackrel{\text{unabh.}}{=} \int \mathbf{1}_A dP \cdot \underbrace{\int XdP}_{=EX} \\ &= \int_A EXdP \end{aligned}$$

\implies Behauptung, da EX \mathfrak{F} -messbar. ■

Satz 7.4 (Faktorisierungssatz)

Es seien $(\Omega, \mathcal{A}), (\Omega', \mathcal{A}')$ Messräume und $Y : \Omega \rightarrow \Omega'$ ein Zufallsgröße. Ist $X : \Omega \rightarrow \mathbb{R}$ eine $(\sigma(Y), \mathfrak{B})$ -messbare Zufallsvariable. Dann gibt es eine \mathfrak{B} -messbare Funktion $g : \Omega' \rightarrow \mathbb{R}$ mit

$$X = g \circ Y.$$

Beweis Algebraische Induktion:

- (i) Sei $X = \sum_{j=1}^n a_j \mathbf{1}_{A_j} \in \mathcal{E}$ mit $a_j \geq 0, A_j \in \sigma(Y)$.
 $\implies A_j = Y^{-1}(A'_j), A'_j \in \mathcal{A}'$. Wähle $g = \sum_{j=1}^n a_j \mathbf{1}_{A'_j}$
 $\implies X = g \circ Y$
 \implies Behauptung

- (ii) Sei $X \geq 0$ und $(\sigma(Y), \mathfrak{B})$ -messbar. $\implies \exists (X_n) \subset \mathcal{E}, 0 \leq X_n \uparrow X$ und wegen
 (i) $\exists (\mathcal{A}', \mathfrak{B})$ -messbare Funktion g_n mit $X_n = g_n \circ Y, n \in \mathbb{N}$.

$$\implies X = \sup_{n \in \mathbb{N}} X_n = \sup_{n \in \mathbb{N}} (g_n \circ Y) = (\sup_{n \in \mathbb{N}} g_n) \circ Y$$

Wähle also $g = \sup_{n \in \mathbb{N}} g_n$

- (iii) $X = X^+ - X^- \xrightarrow{(ii)} X = g_1 \circ Y - g_2 \circ Y$. Wähle $g = g_1 - g_2$. ■

Bemerkung Statt $E[X|\sigma(Y)]$ schreiben wir auch $E[X|Y]$ und wegen Satz 7.4 $\exists g : \Omega' \rightarrow \mathbb{R}$ $(\mathcal{A}', \mathfrak{B})$ -messbar mit $E[X|Y] = g \circ Y$ P -f.s.. Die Funktion g ist P^Y -f.s. eindeutig.

Definition Ist $E[X|Y] = g \circ Y$ wie oben, so heißt $E[X|Y = y] = g(y)$ (ein) **bedingter Erwartungswert von X unter der Bedingung $Y = y$** .

Satz 7.5

Für alle $A' \in \mathcal{A}'$ gilt:

$$\int_{A'} E[X|Y = y] P^Y(dy) = \int_{Y^{-1}(A')} X dP$$

Beweis

$$\int_{A'} E[X|Y = y] P^Y(dy) = \int_{A'} g dP^Y \stackrel{\text{Sa. 2.4}}{=} \int_{Y^{-1}(A')} g \circ Y dP = \int_{Y^{-1}(A')} X dP.$$

Bemerkung Für $A \in \mathcal{A}$ heißt $P(A|Y = y) := E[\mathbf{1}_A|Y = y]$ (eine) **bedingte Wahrscheinlichkeit von A unter der Bedingung $Y = y$** . Bedingte Wahrscheinlichkeiten treten oft bei gekoppelten Zufallsexperimenten auf. Die folgende Sichtweise ist konstruktiver:

Definition Es seien $(\Omega_1, \mathcal{A}_1), (\Omega_2, \mathcal{A}_2)$ messbare Räume. Eine Abbildung $Q : \Omega_1 \times \mathcal{A}_2 \rightarrow [0, 1]$ mit

(i) $\omega_1 \mapsto Q(\omega_1, A_2)$ ist \mathcal{A}_1 -messbar $\forall A_2 \in \mathcal{A}_2$.

(ii) $A_2 \mapsto Q(\omega_1, A_2)$ ist ein Wahrscheinlichkeitsmaß auf $(\Omega_2, \mathcal{A}_2) \forall \omega_1 \in \Omega_1$

nennt man **Übergangskern** oder **Kern** von $(\Omega_1, \mathcal{A}_1)$ nach $(\Omega_2, \mathcal{A}_2)$.

Satz 7.6

Es seien $(\Omega_1, \mathcal{A}_1, P_1)$ ein Wahrscheinlichkeitsraum, $(\Omega_2, \mathcal{A}_2)$ ein Messraum und Q ein Übergangskern von $(\Omega_1, \mathcal{A}_1)$ nach $(\Omega_2, \mathcal{A}_2)$. Dann wird durch

$$P(A) := \int_{\Omega_1} \left(\int_{\Omega_2} \mathbf{1}_A(\omega_1, \omega_2) Q(\omega_1, d\omega_2) \right) P_1(d\omega_1)$$

ein Wahrscheinlichkeitsmaß $P =: P_1 \otimes Q$ auf $\mathcal{A}_1 \otimes \mathcal{A}_2$ definiert. P heißt **Koppelung** und ist das einzige Wahrscheinlichkeitsmaß auf $\mathcal{A}_1 \otimes \mathcal{A}_2$ mit der Eigenschaft

$$P(A_1 \times A_2) = \int_{A_1} Q(\omega_1, A_2) P_1(d\omega_1) \quad (*)$$

Beweis

1. Ähnlich wie in §3 zeigt man: für $f : \Omega_1 \times \Omega_2 \rightarrow \mathbb{R}_+$, f $(\mathcal{A}_1 \otimes \mathcal{A}_2)$ -messbar ist $\omega_1 \mapsto \int_{\Omega_2} f(\omega_1, \omega_2) Q(\omega_1, d\omega_2)$ \mathcal{A}_1 -messbar.
2. Für $A = A_1 \times A_2$ ist $\mathbf{1}_A(\omega_1, \omega_2) = \mathbf{1}_{A_1}(\omega_1) \mathbf{1}_{A_2}(\omega_2) \implies (*)$.
3. $P(\Omega_1 \times \Omega_2) = 1$ wegen $(*)$. $P \geq 0$ ist klar.

$$\begin{aligned}
 P\left(\sum_{n=1}^{\infty} A_n\right) &= \int_{\Omega_1} \left(\int_{\Omega_2} \underbrace{\mathbf{1}_{\sum_{n=1}^{\infty} A_n}(\omega_1, \omega_2)}_{=\sum_{n=1}^{\infty} \mathbf{1}_{A_n}(\omega_1, \omega_2)} Q(\omega_1, d\omega_2) \right) P_1(d\omega_1) \\
 &= \sum_{n=1}^{\infty} \left(\int_{\Omega_1} \left(\int_{\Omega_2} \mathbf{1}_{A_n}(\omega_1, \omega_2) Q(\omega_1, d\omega_2) \right) P_1(d\omega_1) \right) \\
 &= \sum_{n=1}^{\infty} P(A_n).
 \end{aligned}$$

4. Eindeutigkeitssatz für Maße. ■

Satz 7.7 Es seien (Ω, \mathcal{A}, P) ein Wahrscheinlichkeitsraum, $(\Omega_1, \mathcal{A}_1)$ ein messbarer Raum, $Y : \Omega \rightarrow \Omega_1$ $(\mathcal{A}, \mathcal{A}_1)$ -messbar und X ein d -dimensionaler Zufallsvektor. Dann existiert ein Kern Q von $(\Omega_1, \mathcal{A}_1)$ nach $(\mathbb{R}^d, \mathfrak{B}^d)$ derart, dass

$$P^{X,Y} = P^Y \otimes Q.$$

Q ist eine Version der bedingten Verteilung von X unter Y . Schreibweise:

$$Q(y, \cdot) = P^X(\cdot | Y = y).$$

Beweis - ohne Beweis - ■

Bemerkung Für $A \in \mathcal{A}, B \in \mathfrak{B}^d$ gilt:

$$P(X \in B, Y \in A) = \int_A Q(y, B) P^Y dy = \int_A P^X(B | Y = y) P^Y(dy)$$

Satz 7.8

Es seien μ und ν σ -endliche Maße auf \mathcal{A}_1 bzw. \mathfrak{B}^d . $P^{(Y,X)}$ besitze eine Dichte f bezüglich $\mu \otimes \nu$. Es sei $f_Y(y) := \int_{\mathbb{R}^d} f(x, y) \nu(dx)$ die (Rand-)Dichte von P^Y bzgl. μ . Weiterhin sei

$$f(x|y) := \frac{f(x, y)}{f_Y(y)} \quad \text{und} \quad \frac{0}{0} := 0.$$

So wird durch

$$P^X(B | Y = y) := \int_B f(x|y) \nu(dx) \quad \forall B \in \mathfrak{B}^d, y \in \Omega_1$$

eine bedingte Verteilung von X unter der Bedingung $Y = y$ definiert.

$f(\cdot | y)$ heißt **bedingte ν -Dichte von X unter der Bedingung $Y = y$** .

Beweis

$y \mapsto \int_B f(x|y)\nu(dx)$ ist messbar $\forall B \in \mathfrak{B}^d$ (Satz von Tonelli),

$B \mapsto \int_B f(x|y)\nu(dx)$ ist ein Wahrscheinlichkeitsmaß $\forall y \in \Omega_1$.

Für $A \in \mathcal{A}_1, B \in \mathfrak{B}^d$ gilt:

$$\begin{aligned} P^{(Y,X)}(A \times B) &= \int_{A \times B} f d(\mu \otimes \nu) \\ &= \int_A \left(\int_B f(x, y) \nu(dx) \right) \mu(dy) \\ &= \int_A \left(\int_B f(x|y) \nu(dx) \right) f_Y(y) \mu(dy) \\ &\stackrel{!}{=} \int_A P^X(B|Y=y) \underbrace{P^Y(dy)}_{=f_Y(y)\mu(dy)} \end{aligned}$$

■

Satz 7.9

Es seien (Ω, \mathcal{A}, P) ein Wahrscheinlichkeitsraum, $Y : \Omega \rightarrow \mathbb{R}^d$ ein Zufallsvektor und X eine Zufallsvariable mit $E|X| < \infty$. Dann ist

$$h(y) := \int_{\mathbb{R}} x P^X(dx|Y=y)$$

ein bedingter Erwartungswert von X unter der Bedingung $Y = y$.

Beweis Nach 7.5:

$$\int_B E[X|Y=y] P^Y(dy) = \int_{Y^{-1}(B)} X dP.$$

Für $B \in \mathfrak{B}^d$ und $T(Y, X) := X \cdot (\mathbf{1}_B \circ Y)$ gilt:

$$\begin{aligned} \int_{Y^{-1}(B)} X dP &= \int T(Y, X) dP \\ &\stackrel{2.4}{=} \int T(y, x) P^{(Y,X)}(dy, dx) \\ &= \int x \mathbf{1}_B(y) P^{(Y,X)}(dy, dx) \\ &= \int_B \left(\int_{\mathbb{R}} x P^X(dx|Y=y) \right) P^Y(dy) \end{aligned}$$

$\stackrel{7.5}{\implies}$ Beh.

■

Beispiel 7.2

U und V seien unabhängig und $U(0, 1)$ -verteilt und entsprechen den zufälligen Seitenlängen eines Rechtecks. Es sei $X = \text{Flächeninhalt des Rechtecks}$ und $Y = \text{Umfang des Rechtecks}$. Klar: X und Y sind nicht unabhängig.

Weiter ist $f_{U,V}(u, v) = \begin{cases} 1 & 0 < u < 1 \text{ und } 0 < v < 1 \\ 0 & \text{sonst} \end{cases}$ die gemeinsame Dichte von U

und V .

\implies (Transformationssatz für Dichten) $f_{X,Y}(x, y) = \frac{2}{\sqrt{y^2 - 16x}}$ für $0 < x < 1$ und

$4\sqrt{x} < y < 2 + 2x$; $f_X(x) = -\log x$ für $0 < x < 1$.

$\implies f(y|x) = -\frac{2}{\log x \sqrt{y^2 - 16x}}$ für $4\sqrt{x} < y < 2 + 2x$.

$\implies E[Y|X = x] = \int y \cdot f(y|x) dy = -\frac{4(1-x)}{\log x}$.

Beispiel 7.3 (Buffonsches Nadelproblem)

Wir werfen eine Nadel der Länge 1 zufällig auf einen unendlich langen Streifen der Breite 1. Wie groß ist die Wahrscheinlichkeit, dass die Nadel mindestens eine Wand des Korridors schneidet?

X = Abstand der Nadelmitte von der linken Wand

Y = Winkel der Nadel zum Lot

Annahme: $X \sim U(0, 1)$, $Y \sim U(-\frac{\pi}{2}, \frac{\pi}{2})$ und X, Y unabhängig.

A = Nadel schneidet die Wand = $\{\omega \mid (X, Y)(\omega) \in B\}$ mit

$B = \{(x, y) \mid |y| < \frac{\pi}{2}, x \in [0, \frac{1}{2} \cos y] \cup [1 - \frac{1}{2} \cos y, 1]\}$

- hier fehlt eine Skizze -

Es ergibt sich:

$$\begin{aligned} P(A) &= P^{X,Y}(B) \\ &= \int_{-\frac{\pi}{2}}^{\frac{\pi}{2}} \int_0^1 \mathbf{1}_B(x, y) P^X(dx|Y=y) P^Y(dy) \\ &= \int_{-\frac{\pi}{2}}^{\frac{\pi}{2}} P^X\left([0, \frac{\cos y}{2}] \cup [1 - \frac{\cos y}{2}, 1] \mid Y=y\right) P^Y(dy) \\ &= \int_{-\frac{\pi}{2}}^{\frac{\pi}{2}} \cos y \cdot \frac{1}{\pi} dy \\ &= \frac{2}{\pi} \end{aligned}$$

So lässt sich zum Beispiel auch π näherungsweise bestimmen.

8 Martingale und Stoppzeiten

Definition Sei $I \neq \emptyset$ eine beliebige Indexmenge und (Ω, \mathcal{A}, P) ein Wahrscheinlichkeitsraum.

- a) Eine Familie von Zufallsvariablen $(X_t)_{t \in I}$ auf (Ω, \mathcal{A}, P) heißt **stochastischer Prozess** ($I \subset \mathbb{R}$)
- b) Eine Familie von σ -Algebren $(\mathfrak{F}_t)_{t \in I}$, mit $\mathfrak{F}_t \subset \mathcal{A}$ und $\mathfrak{F}_s \subset \mathfrak{F}_t$, für $s \leq t$ heißt **Filtration**. Ein stochastischer Prozess $(X_t)_{t \in I}$ heißt $(\mathfrak{F}_t)_{t \in I}$ -**adaptiert**, falls X_t \mathfrak{F}_t -messbar $\forall t \in I$.

Bemerkung Oft wird $\mathfrak{F}_t := \sigma(\{X_s, s \leq t\})$ gewählt. Dann ist $(\mathfrak{F}_t)_{t \in I}$ eine Filtration und X_t ist \mathfrak{F}_t -messbar.

Definition Gegeben sei ein Wahrscheinlichkeitsraum (Ω, \mathcal{A}, P) , $I \subset \mathbb{R}$, eine Filtration $(\mathfrak{F}_t)_{t \in I}$ und ein dazu adaptierter stochastischer Prozess $(X_t)_{t \in I}$. Ist $E|X_t| < \infty \forall t \in I$, so heißt $(X_t)_{t \in I}$ ein $(\mathfrak{F}_t)_{t \in I}$ -**Martingal**, falls $E[X_t | \mathfrak{F}_s] = X_s \forall s, t \in I, s \leq t$.

Ist $X_s \leq E[X_t | \mathfrak{F}_s]$ bzw. $X_s \geq E[X_t | \mathfrak{F}_s]$, so nennt man $(X_t)_{t \in I}$ ein $(\mathfrak{F}_t)_{t \in I}$ -**Submartingal** bzw. $(\mathfrak{F}_t)_{t \in I}$ -**Supermartingal**.

Bemerkung a) Beim Martingal gilt: $EX_s = E[E[X_t | \mathfrak{F}_s]] = EX_t \forall t \in I$, d.h. der Erwartungswert ist konstant (wachsend beim Submartingal, fallend beim Supermartingal).

- b) Ist $I = \mathbb{N}$, so genügt z.z.:

$$E[X_{t+1} | \mathfrak{F}_t] = X_t \forall t \in \mathbb{N}$$

- c) Ist $(F_t)_{t \in I}$ die natürliche Filtration, so sagt man oft nur $(X_t)_{t \in I}$ ist ein Martingal.

Beispiel 8.1 Sei $I = \mathbb{N}$, $(X_n)_{n \in \mathbb{N}}$ eine Folge von unabhängigen und identisch verteilten Zufallsvariablen mit Erwartungswert μ . Sei $S_n := \sum_{k=1}^n X_k \forall n \in \mathbb{N}$ und $\mathfrak{F}_n := \sigma(S_1, \dots, S_n)$. Dann gilt $\forall n \in \mathbb{N} : E[S_{n+1} | \mathfrak{F}_n] = E[S_n | \mathfrak{F}_n] + E[X_{n+1} | \mathfrak{F}_n] = S_n + \mu$.

Also: $\mu = 0 \implies (S_n)$ ist Martingal
 $\mu \leq 0 \implies (S_n)$ ist Supermartingal
 $\mu \geq 0 \implies (S_n)$ ist Submartingal

Beispiel 8.2 Sei $(\mathfrak{F}_t)_{t \in I}$ eine Filtration und X eine Zufallsvariable mit $E|X| < \infty$. Sei $X_t := E[X | \mathfrak{F}_t]$. dann ist $(X_t)_{t \in I}$ $(\mathfrak{F}_t)_{t \in I}$ -adaptiert und $\forall s, t \in I, s \leq t$:

$$E[X_t | \mathfrak{F}_s] = E[E[X | \mathfrak{F}_t] | \mathfrak{F}_s] \stackrel{S.7.3a)}{=} E[X | \mathfrak{F}_s] = X_s$$

$\implies (X_t)_{t \in I}$ ist ein $(\mathfrak{F}_t)_{t \in I}$ -Martingal.

Satz 8.1

Ist $(X_t)_{t \in I}$ ein $(\mathfrak{F}_t)_{t \in I}$ -Martingal und $\Phi : \mathbb{R} \rightarrow \mathbb{R}$ eine konvexe Funktion mit $E|\Phi(X_t)| < \infty \forall t \in I$, so ist $(\Phi(X_t))_{t \in I}$ ein $(\mathfrak{F}_t)_{t \in I}$ -Submartingal.

Beweis Sei $s, t \in I, s \leq t : E[\Phi(X_t)|\mathfrak{F}_s] \stackrel{\text{Jensen}}{\geq} \Phi(\underbrace{E[X_t|\mathfrak{F}_s]}_{=X_s})$ ■

Im Folgenden: $I = \{1, 2, \dots, n\}$ und $X^* := \max_{1 \leq i \leq n} X_i$

Satz 8.2 (Submartingal-Ungleichung von Doob)

Ist $(X_i)_{i=1, \dots, n}$ ein $(\mathfrak{F}_i)_{i=1, \dots, n}$ -Submartingal, so gilt $\forall c > 0 :$

$$c \cdot P(X^* > c) \leq \int_{\{X^* > c\}} X_n dP \leq EX_n^+$$

Beweis Sei $A := \{X^* > c\}, A_i := \{X_1 \leq c, \dots, X_{i-1} \leq c, X_i > c\}, i = 1, \dots, n$

$$\implies A = A_1 + \dots + A_n, A_i \in \mathfrak{F}_i \text{ und } X_i > c \text{ auf } A_i, i = 1, \dots, n.$$

$$\implies \int_{A_i} X_n dP \stackrel{\text{bed. EW}}{=} \int_{A_i} E[X_n|\mathfrak{F}_i] dP \stackrel{\text{Sub-M.}}{\geq} \int_{A_i} X_i dP \geq cP(A_i), i = 1, \dots, n$$

Summation über $i = 1, \dots, n \implies 1.$ Ungleichung

2. Ungleichung: $X_n \cdot \mathbf{1}_A \leq X_n^+$ ■

Satz 8.3 (L^p -Ungleichung von Doob)

Es sei $p > 1$ und $(X_i)_{i=1, \dots, n}$ ein nicht-negatives $(\mathfrak{F}_i)_{i=1, \dots, n}$ -Submartingal mit der Eigenschaft $\sup_{i=1, \dots, n} EX_i^p < \infty$. Dann gilt:

$$E(X^*)^p \leq \left(\frac{p}{p-1} \right)^p EX_n^p$$

Beweis

$$\begin{aligned} E(X^*)^p &= E \int_0^{X^*} p \cdot y^{p-1} dy \\ &= E \int_0^\infty p \cdot y^{p-1} \mathbf{1}_{[X^* \geq y]} dy \\ &\stackrel{\text{Fubini}}{=} \int_0^\infty p y^{p-1} \cdot P(X^* \geq y) dy \\ &\stackrel{\text{S.8.2}}{\leq} \int_0^\infty p \cdot y^{p-2} E[X_n \cdot \mathbf{1}_{[X^* \geq y]}] dy \\ &\stackrel{\text{Fubini}}{=} E \left[X_n \int_0^{X^*} p y^{p-2} dy \right] \\ &= \frac{p}{p-1} E[X_n (X^*)^{p-1}] \\ &\stackrel{\text{Hölder}}{\leq} \frac{p}{p-1} (EX_n^p)^{\frac{1}{p}} \left(E((X^*)^{p-1})^q \right)^{\frac{1}{q}} \\ &= \frac{p}{p-1} (EX_n^p)^{\frac{1}{p}} \cdot (E(X^*)^p)^{1-\frac{1}{p}} \end{aligned}$$

Teile Ungleichung durch $(E(X^*)^p)^{1-\frac{1}{p}}$ (falls $E(X^*)^p = 0$ ist Aussage richtig) und nehme p -te Potenz \implies Behauptung. ■

Bemerkung a) Ist $\frac{1}{p} + \frac{1}{q} = 1$, so lässt sich Satz 8.3 schreiben als $\|X^*\|_p \leq q \cdot \|X_n\|_p$

b) Ein stochastischer Prozess $(X_t)_{t \in I}$ mit $\sup_{t \in I} \|X_t\|_p < \infty$ heißt L^p -**beschränkt**.

c) Ist $(X_i)_{i=1, \dots, n}$ ein Martingal, so ist $(|X_i|)_{i=1, \dots, n}$ ein nicht negatives Submartingal (Satz 8.1)

Beispiel 8.3 Sei (Ω, \mathcal{A}, P) ein Wahrscheinlichkeitsraum und $(X_n)_{n \in \mathbb{N}_0}$ ein stochastischer Prozess. Interpretation von (X_n) :

$X_0 \equiv$ Anfangskapital des Spielers

$X_n - X_{n-1} \equiv$ Gewinn pro gesetzter Geldeinheit in der n -ten Runde

Wird immer eine Geldeinheit pro Runde gesetzt, so ist also $X_n = X_0 + \sum_{k=1}^n (X_k - X_{k-1})$ das Kapital des Spielers nach n Runden. Es sei

$$\mathfrak{F}_n = \sigma(X_0, X_1 - X_0, \dots, X_n - X_{n-1}) = \sigma(X_0, X_1, \dots, X_n)$$

Das entspricht der Information nach n Runden.

$$\implies E[X_{n+1} - X_n | \mathfrak{F}_n] = E[X_{n+1} | \mathfrak{F}_n] - X_n$$

Das entspricht dem erwarteten Gewinn pro gesetzter Geldeinheit bei Kenntnis des bisherigen Spielverlaufs.

Offenbar gilt:	X Martingal	\iff	Spiel fair
	X Supermartingal	\iff	Spiel nachteilig
	X Submartingal	\iff	Spiel vorteilhaft

Beispiel 8.4

$X_n - X_{n-1}$ sei der Gewinn pro gesetzter Geldeinheit (GE) in der n -ten Runde.

Jetzt: In Runde n werden c_n GE gesetzt mit $c_n \mathfrak{F}_{n-1}$ -messbar.

$\mathfrak{F}_n = \sigma(X_0, X_1 - X_0, \dots, X_n - X_{n-1})$, d.h. $(c_n)_{n \in \mathbb{N}}$ ist vorhersagbar.

Kapital nach n Spielen:

$$X_0 + \sum_{k=1}^n c_k (X_k - X_{k-1})$$

Satz 8.4

Es seien $(c_n)_{n \in \mathbb{N}}$ ein vorhersagbarer Prozess und $X = (X_n)_{n \in \mathbb{N}}$ ein Prozess mit $E|c_n(X_n - X_{n-1})| < \infty \quad \forall n \in \mathbb{N}$. Wir setzen

$$Y_n := X_0 + \sum_{k=1}^n c_k (X_k - X_{k-1}), \quad Y = (Y_n)_{n \in \mathbb{N}}.$$

Dann gilt:

a) Ist X ein Martingal, so auch Y .

- b) Ist X ein Sub- bzw. Supermartingal und $c_n \geq 0 \quad \forall n$, so ist auch Y ein Sub- bzw. Supermartingal.

Beweis

$$E[Y_{n+1} - Y_n | \mathfrak{F}_n] = E[c_{n+1}(X_{n+1} - X_n) | \mathfrak{F}_n] \stackrel{c_{n+1} \mathfrak{F}_n\text{-m.b.}}{=} c_{n+1} \cdot E[X_{n+1} - X_n | \mathfrak{F}_n].$$

Definition

Eine Abbildung $\tau : \Omega \rightarrow \mathbb{N}_0 \cup \{\infty\}$ heißt **Stoppzeit** bezüglich einer Filtration $(\mathfrak{F}_n)_{n \in \mathbb{N}}$, wenn

$$\{\tau \leq n\} \in \mathfrak{F}_n \quad \forall n \in \mathbb{N}_0.$$

Bemerkung

- a) Stoppzeiten kann man analog für $\tau : \Omega \rightarrow \mathbb{R}_+ \cup \{\infty\}$ definieren.
b) $\tau : \Omega \rightarrow \mathbb{N}_0 \cup \{\infty\}$ ist Stoppzeit $\iff \{\tau = n\} \in \mathfrak{F}_n \quad \forall n \in \mathbb{N}_0$. (Übung)

Beispiel 8.5

- a) $\tau \equiv n_0$ ist Stoppzeit, da

$$\{\tau \leq n\} = \begin{cases} \Omega & n \geq n_0 \\ \emptyset & n < n_0 \end{cases} \in \mathfrak{F}_n$$

b) Sei $(X_n)_{n \in \mathbb{N}_0}$ ein zu $(\mathfrak{F}_n)_{n \in \mathbb{N}_0}$ adaptierter rellwertiger Prozess und $A \in \mathfrak{B}$. Sei $\tau_A : \Omega \rightarrow \mathbb{N} \cup \{\infty\}$ definiert durch

$$\tau_A(\omega) := \inf \{n \in \mathbb{N}_0 \mid X_n(\omega) \in A\} \quad (\inf \{\emptyset\} := \infty)$$

τ_A heißt **Eintrittszeit** in A .

τ_A ist Stoppzeit, da

$$\{\tau_A \leq n\} = \bigcup_{i=1}^n \underbrace{\{X_i \in A\}}_{\in \mathfrak{F}_i} \in \mathfrak{F}_n.$$

Lemma 8.1

- a) Für eine Stoppzeit ist

$$\mathfrak{F}_\tau := \{A \in \mathcal{A} \mid A \cap \{\tau \leq n\} \in \mathfrak{F}_n \quad \forall n \in \mathbb{N}_0\}$$

eine σ -Algebra, die σ -**Algebra der τ -Vergangenheit**.

- b) Sind τ_1, τ_2 Stoppzeiten mit $\tau_1 \leq \tau_2$, so gilt $\mathfrak{F}_{\tau_1} \subset \mathfrak{F}_{\tau_2}$.

c) Ist τ eine Stoppzeit, so ist $X_\tau^* : \Omega \rightarrow \mathbb{R}$ mit

$$X_\tau^*(\omega) := \begin{cases} X_{\tau(\omega)}(\omega) & \text{wenn } \tau(\omega) < \infty \\ 0 & \text{sonst} \end{cases} \quad \mathfrak{F}_\tau\text{-messbar}$$

Beweis

a) Übung.

b) Sei $A \in \mathfrak{F}_{\tau_1}$ beliebig. $\forall n \in \mathbb{N}$ gilt:

$$\{\tau_2 \leq n\} \subset \{\tau_1 \leq n\} \implies A \cap \{\tau_2 \leq n\} = \underbrace{A \cap \{\tau_1 \leq n\}}_{\in \mathfrak{F}_n} \cap \underbrace{\{\tau_2 \leq n\}}_{\in \mathfrak{F}_n} \in \mathfrak{F}_n.$$

\implies Beh.

c) zu zeigen: $\{X_\tau^* \in A\} \in \mathfrak{F}_\tau \quad \forall A \in \mathfrak{B}$

zeige also: $\{X_\tau^* \in A\} \cap \{\tau \leq n\} \in \mathfrak{F}_n \quad \forall n \in \mathbb{N}_0$

Es gilt:

$$\{X_\tau^* \in A\} \cap \{\tau \leq n\} = \bigcup_{k=0}^n \underbrace{\{X_k \in A\}}_{\in \mathfrak{F}_k} \cap \underbrace{\{\tau = k\}}_{\in \mathfrak{F}_k} \in \mathfrak{F}_k,$$

$$\text{da } \{\tau = k\} = \underbrace{\{\tau \leq k\}}_{\in \mathfrak{F}_k} \cap \underbrace{\{\tau \leq k-1\}^C}_{\in \mathfrak{F}_k} \in \mathfrak{F}_k.$$

\implies Beh. ■

Bemerkung

a) $\mathfrak{F}_\tau \equiv$ Information, die bis zur zufälligen Zeit τ vorhanden ist.

b) Falls τ P -f.s. endlich, schreibt man X_τ statt X_τ^* .

c) Ist τ eine Stoppzeit und $(X_n)_{n \in \mathbb{N}_0}$ ein stochastischer Prozess, so ist $X^\tau = (X_n^\tau)_{n \in \mathbb{N}_0}$ mit $X_n^\tau := X_{\tau \wedge n} \quad \forall n \in \mathbb{N}_0$ der **gestoppte Prozess**.

Da $\tau \wedge n$ eine Stoppzeit ist, ist wegen Lemma 8.1c) $X_{\tau \wedge n} \mathfrak{F}_{\tau \wedge n}$ -messbar und (X_n^τ) ist $(\mathfrak{F}_{\tau \wedge n})$ -adaptiert.

Satz 8.5

Ist X ein (Sub-, Super-) Martingal und ist τ eine Stoppzeit, so ist auch X^τ ein (Sub-, Super-) Martingal.

Beweis

Sei $c_n := \mathbf{1}_{\{\tau \geq n\}} \implies \{\tau \geq n\} = \{\tau \leq n-1\}^C \in \mathfrak{F}_{n-1}$.

$\implies (c_n)_{n \in \mathbb{N}_0}$ ist vorhersagbar. Da $X_0 + \sum_{k=1}^n c_k(X_k - X_{k-1}) = X_{\tau \wedge n}$, folgt die Behauptung mit Satz 8.4. ■

Bemerkung

Ist X ein Martingal, so auch X^τ und damit gilt $EX_{\tau \wedge n} = EX_0$.

Betrachte Bsp 8.4 mit $\tau := \inf\{k \in \mathbb{N}_0 \mid X_k \geq X_0 + c\}$ und $c_n := \mathbf{1}_{\{\tau \geq n\}}$:

Solange c nicht erreicht ist, wird eine Geldeinheit gesetzt, danach aufgehört. Spielt man maximal n -mal, so ist $X_{\tau \wedge n}$ das Kapital am Ende. Im Mittel kann man das Kapital bei einem fairen Spiel nicht erhöhen.

Beispiel 8.6 (Kartenspiel)

Sei

- S_0 die Anzahl der schwarzen Karten und
- R_0 die Anzahl der roten Karten und
- $N := S_0 + R_0$ die Gesamtzahl an Karten.
- (R_n, S_n) die Anzahl der roten / schwarzen Karten im Stapel, nachdem n Karten aufgedeckt wurden.
- Z_n die Farbe der n -ten aufgedeckten Karte.
- $\mathfrak{F}_n = \sigma(Z_1, \dots, Z_n)$ und
- $X_n := \frac{S_n - R_n}{S_n + R_n}$.

Behauptung: (X_n) ist (\mathfrak{F}_n) -Martingal!

$$\begin{aligned}
 E[X_{n+1} \mid \mathfrak{F}_n] &= E\left[\frac{S_{n+1} - R_{n+1}}{S_{n+1} + R_{n+1}} \mid Z_1, \dots, Z_n\right] \\
 &= \frac{S_n}{S_n + R_n} \left[\frac{S_n - 1 - R_n}{S_n - 1 + R_n}\right] + \frac{R_n}{S_n + R_n} \left[\frac{S_n - R_n + 1}{S_n + R_n - 1}\right] \\
 &= \frac{(R_n + S_n - 1)(S_n - R_n)}{(S_n + R_n)(S_n + R_n - 1)} \\
 &= \frac{S_n - R_n}{S_n + R_n}
 \end{aligned}$$

Sei τ eine Stoppzeit ($\leq N$). Erwarteter Gewinn:

$$\begin{aligned}
 &E[\mathbf{1}_{[Z_{\tau+1} = \text{schwarz}]} - \mathbf{1}_{[Z_{\tau+1} = \text{rot}]}] \\
 &= E\left[\sum_{k=1}^N (\mathbf{1}_{[Z_{k+1} = \text{schwarz}]} - \mathbf{1}_{[Z_{k+1} = \text{rot}]}) \mathbf{1}_{[\tau=k]}\right] \\
 &= \sum_{k=1}^N E\left[E[(\mathbf{1}_{[Z_{k+1} = \text{schwarz}]} - \mathbf{1}_{[Z_{k+1} = \text{rot}]}) \mathbf{1}_{[\tau=k]} \mid \mathfrak{F}_k]\right] \\
 &= \sum_{k=1}^N E\left[\mathbf{1}_{[\tau=k]} \underbrace{E[\mathbf{1}_{[Z_{k+1} = \text{schwarz}]} - \mathbf{1}_{[Z_{k+1} = \text{rot}]} \mid \mathfrak{F}_k]}_{= \frac{S_k - R_k}{S_k + R_k} = X_k}\right]
 \end{aligned}$$

$$= E[X_\tau] = EX_0 = \frac{S_0 - R_0}{S_0 + R_0}$$

$EX_\tau = EX_0$ gilt nur unter einer Bedingung, wie dieses Beispiel zeigt.

Beispiel 8.7 Sei $(Y_n)_{n \in \mathbb{N}}$ eine Folge von u.i.v. ZVen mit

$$P(Y_n = -1) = P(Y_n = 1) = \frac{1}{2}, \quad X_0 \equiv 0$$

Y_n = Ergebnis Münzwurf in Runde n .

Der Spieler setzt 2^{n-1} GE in der n -ten Runde, bei Gewinn erhält er 2^n GE, d.h.

$Y_n \cdot 2^{n-1}$ ist der Geldzu-/abgang in der n -ten Runde.

Kapital nach n Runden:

$$X_n := \sum_{i=1}^n 2^{i-1} Y_i$$

Sei $\mathfrak{F}_n := \sigma(X_0, \dots, X_n)$ und $\tau := \inf\{n \in \mathbb{N} \mid Y_n = 1\}$ d.h. gestoppt wird, wenn erstmals $Y_n = 1$ (\rightarrow Martingalstrategie). $(X_n)_{n \in \mathbb{N}}$ ist ein $(\mathfrak{F}_n)_{n \in \mathbb{N}}$ -Martingal (s. Bsp. 8.1).

Es gilt:

$$P(\tau > k) = \left(\frac{1}{2}\right)^k \quad \forall k \in \mathbb{N} \Rightarrow P(\tau < \infty) = 1$$

und

$$X_\tau = \sum_{k=1}^{\infty} X_k \mathbf{1}_{\tau=k} = \sum_{k=1}^{\infty} \underbrace{\left(-\sum_{i=1}^{k-1} 2^{i-1} + 2^{k-1}\right)}_{=1} \mathbf{1}_{\tau=k} \equiv 1$$

Also ist hier $EX_\tau = 1 \neq EX_0 = 0$.

Vorsicht bei der Nachahmung!

Das benötigte Kapital beträgt $-X_{\tau-1}$ GE und

$$\begin{aligned} E(-X_{\tau-1}) &= E\left(\sum_{k=1}^{\tau-1} 2^{k-1}\right) \\ &= E\left(\sum_{k=1}^{\infty} 2^{k-1} \mathbf{1}_{[\tau > k]}\right) \\ &= \sum_{k=1}^{\infty} 2^{k-1} \underbrace{P(\tau > k)}_{=2^{-k}} = \infty \end{aligned}$$

Satz 8.6 (Optional Stopping Theorem OST)

Es sei $X = (X_n)_{n \in \mathbb{N}}$ ein Supermartingal und τ eine Stoppzeit. Jede der folgenden Bedingungen impliziert, dass $E|X_\tau| < \infty$ und $EX_\tau \leq EX_1$ gilt:

1. τ ist f.s. beschränkt, also $P(\tau < c) = 1$ für ein $c \in \mathbb{R}$.

2. τ ist f.s. endlich und X ist f.s. beschränkt, d.h. $P(\tau < \infty) = 1$ und es gibt ein $c \in \mathbb{R}$ mit $P(|X_n| \leq c) = 1 \ \forall n \in \mathbb{N}_0$.
3. $E\tau < \infty$ und X hat f.s. beschränkte Zuwächse, d.h. $\exists c \in \mathbb{R}$ mit $P(|X_n - X_{n-1}| \leq c) = 1 \ \forall n \in \mathbb{N}$.
4. $P(\tau < \infty) = 1, E|X_\tau| < \infty$ und $\int_{\{\tau > n\}} |X_n| dP \rightarrow 0$ für $n \rightarrow \infty$.

Ist eine dieser Bedingungen erfüllt und X ein Martingal, so gilt: $EX_\tau = EX_1$.

Beweis 1. Ist klar, da hier $X_\tau = X_{\tau \wedge n}$ für ein $n \in \mathbb{N}$ groß ($n > c$). Die Behauptung folgt aus Satz 8.5.

2. Satz 8.5 und majorisierte Konvergenz.
3. Verwende $|X_1| + c(\tau - 1)$ als integrierbare Majorante.
4. Wir zeigen die Aussage für X ist Martingal:

$$\begin{aligned}
 |EX_\tau - EX_{\tau \wedge n}| &= \left| \int X_\tau dP - \int_{\{\tau \leq n\}} X_\tau dP - \int_{\{\tau > n\}} X_n dP \right| \\
 &\leq \left| \int_{\{\tau > n\}} X_\tau dP \right| + \left| \int_{\{\tau > n\}} X_n dP \right| \\
 &\leq \underbrace{\int_{\{\tau > n\}} |X_\tau| dP}_{\rightarrow 0(n \rightarrow \infty)} + \underbrace{\int_{\{\tau > n\}} |X_n| dP}_{\rightarrow 0(n \rightarrow \infty)} \rightarrow 0 \ (n \rightarrow \infty) \quad \blacksquare
 \end{aligned}$$

Beispiel 8.8 (Ruinspiel, vgl. Stochastik I, Bsp 10.4) Spieler I besitze n GE ($n \in \mathbb{N}$), Spieler II $N - n$ GE ($N - n \in \mathbb{N}$). Pro Runde gewinnt Spieler I von Spieler II 1 GE mit W'keit p und verliert eine GE an Spieler II mit W'keit $1 - p$. Spielrunden sind unabhängig. Seien $(Y_n)_{n \in \mathbb{N}}$ u.i.v. ZV mit

$$P(Y_n = 1) = p, \quad P(Y_n = -1) = 1 - p.$$

$X_n := \sum_{k=1}^n Y_k$ ist dann der Gewinn (Verlust) von Spieler I nach n Runden.

Sei

$$\tau := \inf\{n \in \mathbb{N} \mid X_n = N - n \text{ oder } X_n = -n\}$$

$P(X_\tau = -n)$ = Ruinwahrscheinlichkeit von Spieler I.

Sei $\mu = EY_1 = 2p - 1$. Nach Beispiel 8.1 $\mu = 0 \Rightarrow (X_n)$ Martingal. $\mu \leq 0 \Rightarrow (X_n)$

Supermartingal. $\mu \geq 0 \Rightarrow (X_n)$ Submartingal.

Behauptung: $\exists a > 0, 0 < \gamma < 1$, sodass $P(\tau > j) \leq a\gamma^j \ \forall j \in \mathbb{N}$.

Beweis: Sei $k \in \mathbb{N}$.

$$\begin{aligned}
 P(\tau > Nk) &\leq P((Y_1, \dots, Y_n) \neq (1, \dots, 1), \\
 &\quad (Y_{N+1}, \dots, Y_{2N}) \neq (1, \dots, 1), \dots, (Y_{(k-1)N+1}, \dots, Y_{kN}) \neq (1, \dots, 1)) \\
 &\stackrel{(Y_n) \text{ unabh.}}{=} \prod_{v=0}^{k-1} P((Y_{vN+1}, \dots, Y_{(v+1)N}) \neq (1, \dots, 1)) \\
 &= (1 - p^N)^k
 \end{aligned}$$

Für $j > N$ gilt:

$$P(\tau > j) \leq P(\tau > \lfloor \frac{j}{N} \rfloor N) \leq (1 - p^N)^{\lfloor \frac{j}{N} \rfloor} \leq \underbrace{\left((1 - p^N)^{\frac{1}{N}} \right)^j}_{=: \gamma^j} \underbrace{(1 - p^N)^{-1}}_{=: a}$$

■

Also folgt: $P(\tau < \infty) = 1, E\tau = \sum_{j=1}^{\infty} P(\tau \geq j) < \infty$ und $1 = P(\tau < \infty) = P(X_\tau = N - n) + P(X_\tau = -n)$.

Sei nun $M_n := \sum_{k=1}^n (Y_k - \underbrace{EY_k}_{=\mu}), n \in \mathbb{N}_0, M_0 = 0$ und $\mathfrak{F}_n := \sigma(Y_1, \dots, Y_n)$.

Dann ist $(M_n)_{n \in \mathbb{N}_0}$ ein (\mathfrak{F}_n) -Martingal. Das OST ist anwendbar, da (iii) erfüllt ist.

$$\begin{aligned} \Rightarrow 0 &= EM_\tau = P(X_\tau = N - n)(N - n - E\tau\mu) + P(X_\tau = -n)(-n - E\tau\mu) \\ &= P(X_\tau = N - n)(N - n) - P(X_\tau = -n)n - E\tau\mu. \end{aligned}$$

Fall 1: $\mu = 0$ (d.h. $p = \frac{1}{2}$, faires Spiel)

$$\Rightarrow 0 = (1 - P(X_\tau = -n))(N - n) - P(X_\tau = -n)n \Rightarrow P(X_\tau = -n) = \frac{N - n}{N}$$

Fall 2: $p \neq \frac{1}{2}$

Sei $\Theta := \log(\frac{1-p}{p}) \neq 0$ und $L_0 := 1, L_n := \prod_{k=1}^n e^{\Theta Y_k} = e^{\Theta X_n}$.
 $(L_n)_{n \in \mathbb{N}}$ ist ein $(\mathfrak{F}_n)_{n \in \mathbb{N}}$ -Martingal, da

$$E[L_{n+1} \mid \mathfrak{F}_n] = \prod_{k=1}^n e^{\Theta Y_k} \cdot \underbrace{E[e^{\Theta Y_{n+1}}]}_{pe^{\Theta} + (1-p)e^{-\Theta} = 1} = L_n$$

Das Optional Stopping Theorem 8.6 ist anwendbar, da (iv) erfüllt
 $E|L_\tau| = Ee^{\Theta X_\tau} \leq e^{|\Theta|N} < \infty$ und

$$\int_{\{\tau > n\}} |L_n| dP \leq e^{|\Theta|N} \underbrace{P(\tau > n)}_{\rightarrow 0 \text{ (} n \rightarrow \infty)}$$

$$\begin{aligned} \Rightarrow 1 &= EL_0 = EL_\tau = P(X_\tau = N - n)e^{\Theta(N-n)} + P(X_\tau = -n)e^{-\Theta n} \\ \Rightarrow 1 &= (1 - P(X_\tau = -n)) \cdot \left(\frac{1-p}{p}\right)^{N-n} + P(X_\tau = -n) \left(\frac{p}{1-p}\right)^n \\ \Rightarrow P(X_\tau = -n) &= \frac{\phi^N - \phi^n}{\phi^N - 1}, \quad \phi = \frac{1-p}{p} \end{aligned}$$

Optimales Stoppen

Sei (Ω, \mathcal{A}, P) ein Wahrscheinlichkeitsraum und $X = (X_n)_{n=1, \dots, N}$ ein stochastischer Prozess adaptiert an eine Filtration $(\mathfrak{F}_n)_{n=1, \dots, N}$. Es sei $E|X_k| < \infty \quad \forall k = 1, \dots, N$. Betrachte das Optimierungsproblem

$$v := \sup_{\tau \text{ ist Stoppzeit } \leq N} \{EX_\tau\} = EX_{\tau_0}$$

v = maximaler Wert,

τ_0 = optimale Stoppzeit (falls existent). Wegen

$$E|X_\tau| = \sum_{n=1}^N E(|X_n| \cdot \mathbf{1}_{\{\tau=n\}}) \leq \sum_{n=1}^N E|X_n| < \infty$$

nach Voraussetzung ist $v < \infty$. Ist $(X_n)_{n=1,\dots,N}$ ein $(\mathfrak{F}_n)_{n=1,\dots,N}$ Supermartingal, so folgt mit Satz 8.6: $EX_1 \geq EX_\tau \quad \forall$ Stoppzeiten $\tau \leq N$.

Also: $\tau_0 \equiv 1$ ist optimal (sofort aufhören).

Definition

Der Prozess $Z = (Z_n)_{n=1,\dots,N}$ mit

$$Z_N := X_N, \quad Z_n := \max\{X_n, E[Z_{n+1} | \mathfrak{F}_n]\}, \quad n = N-1, \dots, 1$$

heißt **Snell-Einhüllende** von X .

Satz 8.7 Mit den obigen Bezeichnungen gilt:

- a) Z ist ein $(\mathfrak{F}_n)_{n=1,\dots,N}$ -Supermartingal mit $Z_n \geq X_n$ für $n = 1, \dots, N$.
- b) Z ist das kleinste (\mathfrak{F}_n) -Supermartingal, welches X dominiert, d.h. ist $(Y_n)_{n=1,\dots,N}$ ein weiteres (\mathfrak{F}_n) -Supermartingal mit $Y_n \geq X_n$, $n = 1, \dots, N$ so gilt: $Y_n \geq Z_n$ für $n = 1, \dots, N$.

Beweis

- a) Aus der Definition: $Z_n \geq X_n \quad \forall n$, $Z_n \geq E[Z_{n+1} | \mathfrak{F}_n]$, also (Z_n) Supermartingal.
- b) Rückwärtsinduktion:
 $(n = N): Y_N \geq X_N = Z_N$
 $(n \rightarrow n-1): Y_{n-1} \stackrel{Y \text{ Supermartingal}}{\geq} E[Y_n | \mathfrak{F}_{n-1}] \stackrel{\text{I.H.}}{\geq} E[Z_n | \mathfrak{F}_{n-1}]$ und $Y_{n-1} \geq X_{n-1}$
 $\implies Y_{n-1} \geq \max\{X_{n-1}, E[Z_n | \mathfrak{F}_{n-1}]\} = Z_{n-1}$ ■

Satz 8.8

Mit den obigen Bezeichnungen und $\tau_0 = \min\{n \in \{1, \dots, N\} \mid X_n = Z_n\}$ gilt:

- a) τ_0 ist eine Stoppzeit.
- b) $(Z_n^{\tau_0})_{n=1,\dots,N}$ ist ein $(\mathfrak{F}_n)_{n=1,\dots,N}$ -Martingal.
- c) $EX_{\tau_0} = \sup_{\tau \text{ Stoppzeit}} \{EX_\tau\}$

Beweis

a) Wegen $Z_N = X_N$ ist $\tau_0 \leq N$. Es gilt:

$$\{\tau_0 \leq n\} = \bigcup_{i=1}^n \underbrace{\{Z_i = X_i\}}_{\in \mathfrak{F}_i} \in \mathfrak{F}_n$$

b) Es gilt:

$$\underbrace{Z_{n+1}^{\tau_0}}_{=Z_{(n+1) \wedge \tau_0}} - \underbrace{Z_n^{\tau_0}}_{=Z_n \wedge \tau_0} = \mathbf{1}_{\{\tau_0 \geq n+1\}} (Z_{n+1} - E[Z_{n+1} | \mathfrak{F}_n]) \quad (*)$$

da

Fall 1: $\tau_0 \geq n+1$

linke Seite = $Z_{n+1} - Z_n$,

rechte Seite = $Z_{n+1} - \underbrace{E[Z_{n+1} | \mathfrak{F}_n]}_{=Z_n}$, da $X_n < Z_n$ auf $\{\tau_0 \geq n+1\}$. (stimmt)

Fall 2: $\tau_0 \leq n$

$0 = 0$ (stimmt)

Wende nun $E[\cdot | \mathfrak{F}_n]$ auf (*) an:

Da $\{\tau_0 \geq n+1\} = \{\tau_0 \leq n\}^C \in \mathfrak{F}_n$ folgt

$$E[Z_{n+1}^{\tau_0} - Z_n^{\tau_0} | \mathfrak{F}_n] = \mathbf{1}_{\{\tau_0 \geq n+1\}} E[Z_{n+1} - E[Z_{n+1} | \mathfrak{F}_n] | \mathfrak{F}_n] = 0$$

$\implies (Z_n^{\tau_0})$ ist (\mathfrak{F}_n) -Martingal.

c) Wegen b) und Satz 8.6:

$$EZ_1 = EZ_1^{\tau_0} = EZ_N^{\tau_0} = EZ_{\tau_0} = EX_{\tau_0}$$

Für eine beliebige Stoppzeit τ gilt:

$EZ_1 \geq EZ_\tau$, da Z Supermartingal. Und weiterhin:

$$EX_{\tau_0} = EZ_1 \geq EZ_1 \geq EZ_\tau \geq EX_\tau \implies \text{Beh.} \quad \blacksquare$$

Beispiel 8.9 (Das Sekretärinnenproblem) N Bewerber(innen) um eine Stelle stellen sich nacheinander vor. Nach jedem Interview muss entschieden werden, ob die Person die Stelle bekommt.

Annahme: Die Bewerber lassen sie linear anordnen und erscheinen in beliebiger Reihenfolge. ($N!$ mögliche Reihenfolgen)

Welche Strategie maximiert die Wahrscheinlichkeit, dass die beste Person die Stelle bekommt?

- A_n = absoluter Rang des n -ten Kandidaten unter allen N .
- R_n = dessen relativer Rang unter den ersten N . $R_n = \{1 \leq m \leq n \mid A_m \leq A_n\}$.

Es gibt eine Bijektion zwischen den A -Werten und den R -Werten. Somit gilt $\forall r_1, \dots, r_N$, $1 \leq r_i \leq i$, $1 \leq i \leq N$:

$$P(R_1 = r_1, \dots, R_N = r_N) = \frac{1}{N!}$$

Bestimme Randverteilungen:

$$P(R_n = l) = \frac{1}{n} \quad \text{für } l = 1, \dots, n \quad \forall n \in \{1, \dots, N\}$$

und R_1, \dots, R_N unabhängig. Sei nun

$$\bar{X}_n := \begin{cases} 1, & A_n = 1 \\ 0, & \text{sonst} \end{cases}, \quad \mathfrak{F}_n = \sigma(R_1, \dots, R_n)$$

und $X_n = E[\bar{X}_n | \mathfrak{F}_n]$. (X_n) ist (\mathfrak{F}_n) -adaptiert. $P(\bar{X}_\tau = 1) \rightarrow \max$.

$$\begin{aligned} P(\bar{X}_\tau = 1) &= \sum_{n=1}^N P(\bar{X}_n = 1, \tau = n) = \sum_{n=1}^N E \mathbf{1}_{[\tau=n, \bar{X}_n=1]} \\ &= \sum_{n=1}^N \int_{\{\tau=n\}} \bar{X}_n dP = \sum_{n=1}^N \int_{\{\tau=n\}} \underbrace{E[\bar{X}_n | \mathfrak{F}_n]}_{=X_n} dP \\ &= EX_\tau \end{aligned}$$

Also maximiere EX_τ mit Satz 8.8.

$$\begin{aligned} P(R_1 = r_1, \dots, R_{n-1} = r_{n-1}, A_n = 1) &= P(R_1 = r_1, \dots, R_{n-1} = r_{n-1}, R_n = 1, R_{n+1} > 1, \dots, R_N > 1) \\ &= \frac{1}{N!} \cdot 1 \cdot \dots \cdot 1 \cdot n \cdot (n+1) \cdot \dots \cdot (N-1) = \frac{n}{N} \cdot \frac{1}{n!} \end{aligned}$$

$$\begin{aligned} \Rightarrow P(A_n = 1 \mid R_1 = r_1, \dots, R_{n-1} = r_{n-1}, R_n = 1) &= \frac{P(R_1 = r_1, \dots, R_{n-1} = r_{n-1}, R_n = 1, A_n = 1)}{P(R_1 = r_1, \dots, R_{n-1} = r_{n-1}, R_n = 1)} \\ &= \frac{\frac{n}{N} \cdot \frac{1}{n!}}{\frac{1}{n!}} = \frac{n}{N} \end{aligned}$$

$$\Rightarrow X_n = E[\mathbf{1}_{\{1\}}(A_n) | \mathfrak{F}_n] = \begin{cases} \frac{n}{N}, & \text{falls } R_n = 1 \\ 0, & \text{sonst} \end{cases} \quad (*)$$

Behauptung: $\exists (c_n)_{n=1, \dots, N} \subset \mathbb{R}$, $c_n \downarrow$, $c_N = \frac{1}{N}$ und $E[Z_n | \mathfrak{F}_{n-1}] \equiv c_n$ für $n = 1, \dots, N$, wobei Z die Snell-Einhüllende von X ist.

Beweis: Rückwärtsinduktion:

$n = N$:

$$\begin{aligned} E[Z_N | \mathfrak{F}_{N-1}] &= E[X_N | \mathfrak{F}_{N-1}] \stackrel{A_N = R_N}{=} E[\mathbf{1}_{\{1\}}(R_N) | \mathfrak{F}_{N-1}] \\ &\stackrel{R_N, \mathfrak{F}_N \text{ unabh.}}{=} P(R_N = 1) = \frac{1}{N} = c_N. \end{aligned}$$

$n+1 \rightsquigarrow n$:

$$\begin{aligned}
E[Z_n | \mathfrak{F}_{n-1}] &= E[\max\{X_n, E[Z_{n+1} | \mathfrak{F}_n]\} | \mathfrak{F}_{n-1}] \\
&\stackrel{(*)}{=} E[\max\{\frac{n}{N} \cdot \mathbf{1}_{\{1\}}(R_n), c_{n+1}\} | \mathfrak{F}_{n-1}] \\
&= E[\mathbf{1}_{\{1\}}(R_n) \cdot \max\{\frac{n}{N}, c_{n+1}\} + (1 - \mathbf{1}_{\{1\}}(R_n))c_{n+1} | \mathfrak{F}_{n-1}] \\
&\stackrel{R_n, \mathfrak{F}_{n-1} \text{ unabh.}}{=} P(R_n = 1) \cdot \max\{\frac{n}{N}, c_{n+1}\} + (1 - P(R_n = 1)) \cdot c_{n+1} \\
&= \frac{1}{n} \max\{\frac{n}{N}, c_{n+1}\} + (1 - \frac{1}{n})c_{n+1} \\
&\Rightarrow c_n = c_{n+1} + \underbrace{\max\{\frac{1}{N}, \frac{c_{n+1}}{n}\} - \frac{c_{n+1}}{n}}_{\geq 0} \Rightarrow c_n \geq c_{n+1}
\end{aligned}$$

$$\tau^* := \inf\{n \mid Z_n = X_n\}$$

Stoppregel nach Satz 8.8: $\tau^* = \min\{n \mid X_n = Z_n\}$.

- gestoppt wird vor N nur, wenn $R_n = 1$.
- die Werte $X_n \neq 0$ sind wachsend.
- die Werte $E[Z_{n+1} | \mathfrak{F}_n] = c_{n+1}$ fallend.

$$\begin{aligned}
\tau^* &= \min\{1 \leq n \leq N-1 \mid R_n = 1, \frac{n}{N} \geq c_{n+1}\} \wedge N \\
&= \min\{n \geq k_n \mid R_n = 1\} \wedge N.
\end{aligned}$$

Wir bestimmen jetzt noch k_N .

Sei $\tau_k := \inf\{n \geq k \mid R_n = 1\} \wedge N$. Bestimme EX_{τ_k} .

k_N ist dann der k -Wert, bei dem EX_{τ_k} maximal ist. Es gilt

$$\begin{aligned}
EX_{\tau_k} &= \sum_{l=k}^N E[X_l \cdot \mathbf{1}_{\{l\}}(\tau_k)] \\
&= \sum_{l=k}^N \frac{l}{N} \underbrace{P(R_m > 1 \text{ für } m = k, \dots, l-1, R_l = 1)}_{=P(\tau_k=l)} \\
&= \sum_{l=k}^N \frac{l}{N} \underbrace{\left(\prod_{m=k}^{l-1} \frac{m-1}{m} \right)}_{=P(R_m > 1)} \cdot \underbrace{\frac{1}{l}}_{=P(R_l=1)} \\
&\stackrel{\text{Teleskop. Prod.}}{=} \frac{k-1}{N} \sum_{l=k}^N \frac{1}{l-1}
\end{aligned}$$

$\Phi(k) := \frac{k-1}{N} \sum_{l=k}^N \frac{1}{l-1}$ wird maximal in $k_N := \inf\{k \mid \frac{1}{k} + \frac{1}{k+1} + \dots + \frac{1}{N-1} \leq 1\}$.

Beachte: $\lim_{N \rightarrow \infty} \frac{k_N}{N} \stackrel{!}{=} \frac{1}{e}$.

Bei einem großen Bewerberkreis wird man etwa 37 Prozent der Bewerber passieren lassen und dann den ersten nehmen, der besser als alle vorangegangenen ist.

9 Konvergenzsätze für Martingale

Im Folgenden sei (Ω, \mathcal{A}, P) ein W'Raum, $(\mathfrak{F}_n)_{n \in \mathbb{N}}$ eine Filtration und $\mathfrak{F}_\infty := \sigma(\cup_{n \in \mathbb{N}} \mathfrak{F}_n)$.

Definition 9.1 Sei X_1, \dots, X_n eine Folge von ZV und $-\infty < a < b < \infty$.

$U_n[a, b]$ sei die **Anzahl der aufsteigenden Überschreitungen** des Intervalls $[a, b]$ durch X_1, \dots, X_n also

$$U_n[a, b] = \max\{k \leq \lfloor \frac{n}{2} \rfloor \mid \exists \text{ Indizes } 1 \leq i_1 < \dots < i_{2k} \leq n \text{ mit } X_{i_{2j-1}} \leq a, b \leq X_{i_{2j}} \text{ für } j = 1, \dots, k\}$$

Bemerkung 9.1 Wegen

$$\{U_n[a, b] \geq k\} = \bigcup_{1 \leq i_1 < \dots < i_{2k} \leq n} \bigcap_{j=1}^k \{X_{i_{2j-1}} \leq a\} \cap \{X_{i_{2j}} \geq b\} \in \mathfrak{F}_n$$

ist $U_n[a, b]$ eine ZV.

Lemma 9.1 Sei $(X_n)_{n \in \mathbb{N}}$ ein Supermartingal. Dann gilt:

$$EU_n[a, b] \leq \frac{1}{b-a} E(X_n - a)^-$$

Beweis

Sei $p := \lfloor \frac{n}{2} \rfloor + 1$, $\tau_0 \equiv 1$ und für $k = 1, \dots, p$:

$$\tau_{2k-1} := \min\{j \geq \tau_{2k-2} \mid X_j \leq a\} \wedge n$$

$$\tau_{2k} := \min\{j \geq \tau_{2k-1} \mid X_j \geq b\} \wedge n$$

Die (τ_k) sind Stoppzeiten mit $1 \leq \tau_1 \leq \tau_2 \leq \dots \leq \tau_{2p} = n$ und

falls $\tau_{2k-1} < n$, ist $\tau_{2k-1} < \tau_{2k}$.

Sei $k_0 := U_n[a, b]$, d.h. $X_{\tau_{2k}} - X_{\tau_{2k-1}} \geq b - a$ für $k = 1, \dots, k_0$

$$X_{\tau_{2k_0+2}} - X_{\tau_{2k_0+1}} \neq 0 \implies X_{\tau_{2k_0+1}} \leq a, X_{\tau_{2k_0+2}} = X_n$$

$$\implies X_{\tau_{2k_0+2}} - X_{\tau_{2k_0+1}} \geq X_n - a \geq \min\{X_n - a, 0\} = -(X_n - a)^-$$

$$\implies \sum_{k=1}^p (X_{\tau_{2k}} - X_{\tau_{2k-1}}) \geq (b-a) \cdot U_n[a, b] - (X_n - a)^-$$

Wir zeigen jetzt: $E(X_{\tau_{2k}} - X_{\tau_{2k-1}}) \leq 0$.

Sei $c_j := \mathbf{1}_{\{\tau_{2k-1} < j \leq \tau_{2k}\}}$. $(c_j)_{j \geq 2}$ ist vorhersehbar.

$$\{c_j = 1\} = \{\tau_{2k-1} \leq j-1\} \cap \{\tau_{2k} \leq j-1\}^C \in \mathfrak{F}_{j-1}$$

Sei $Y_n = X_1 + \sum_{j=2}^n c_j(X_j - X_{j-1})$, $n \in \mathbb{N}$; $Y_1 := X_1$.

Satz 8.4 $\implies (Y_n)$ ist ein Supermartingal.

$$\begin{aligned}
\Rightarrow EY_n &= E[X_1 + \sum_{j=1}^n c_j(X_j - X_{j-1})] \\
&= EX_1 + \underbrace{E[X_{\tau_{2k}} - X_{\tau_{2k-1}}]}_{\leq 0} \\
&\leq EY_1 = EX_1
\end{aligned}$$

\Rightarrow Beh. ■

Satz 9.1 (Vorwärtskonvergenzsatz von Doob)

Sei $(X_n)_{n \in \mathbb{N}}$ ein $(\mathfrak{F}_n)_{n \in \mathbb{N}}$ -Supermartingal mit der Eigenschaft $\sup_{n \in \mathbb{N}} \{E|X_n|\} < \infty$.

Dann existiert eine \mathfrak{F}_∞ ¹-messbare Zufallsvariable X_∞ mit $E|X_\infty| < \infty$ und $\lim_{n \rightarrow \infty} X_n = X_\infty$ P -f.s.

Beweis

Sei $N := \{\omega \in \Omega \mid \liminf_{n \rightarrow \infty} \{X_n(\omega)\} < \limsup_{n \rightarrow \infty} \{X_n(\omega)\}\}$ und

$U_\infty[a, b] := \lim_{n \rightarrow \infty} \{U_n[a, b]\}$ (existiert, da $U_n[a, b]$ wachsend)

$\Rightarrow N = \cup_{a, b \in \mathbb{Q}, a < b} \{\omega \in \Omega \mid U_\infty[a, b](\omega) = \infty\}$

Lemma 9.1 $\Rightarrow (b - a)EU_n[a, b] \leq E(X_n - a)^- \leq |a| + E|X_n| \quad \forall n \in \mathbb{N}$

Mit der Voraussetzung und monotoner Konvergenz: $EU_\infty[a, b] < \infty$.

$\Rightarrow P(U_\infty[a, b] = \infty) = 0 \Rightarrow P(N) = 0$, da N abzählbare Vereinigung von P -Nullmengen. Außerdem: $N \in \mathfrak{F}_\infty$.

Sei $\tilde{X}_\infty(\omega) := \begin{cases} \lim_{n \rightarrow \infty} \{X_n(\omega)\} & \omega \in N^C \text{ (evtl. } \tilde{X}_\infty(\omega) = \infty) \\ 0 & \omega \in N \end{cases}$

$$\begin{aligned}
\Rightarrow E|\tilde{X}_\infty| &= E\left[\liminf_{n \rightarrow \infty} \{|X_n|\}\right] \\
&\stackrel{\text{Lem. von Fatou}}{\leq} \limsup_{n \rightarrow \infty} \{E|X_n|\} \\
&\leq \sup_{n \in \mathbb{N}} \{E|X_n|\} \\
&< \infty
\end{aligned}$$

Sei $\tilde{N} := \{\omega \in \Omega \mid \tilde{X}_\infty \in \{-\infty, \infty\}\} \Rightarrow P(\tilde{N}) = 0$

folgt $X_\infty := \tilde{X}_\infty \cdot \mathbf{1}_{\tilde{N}^C}$ erfüllt die Bedingung. ■

Bemerkung

(i) $(X_n)_{n \in \mathbb{N}}$ mit der Eigenschaft $\sup_{n \in \mathbb{N}} \{E|X_n|\} < \infty$ heißt **L^1 -beschränkt**.

(ii) Bei Supermartingalen folgt die L^1 -Beschränktheit aus $\sup_{n \in \mathbb{N}} \{EX_n^-\} < \infty$, also z.B. falls $X_n \geq 0$.

¹ $\mathfrak{F}_\infty = \sigma(\cup_{n \in \mathbb{N}} \mathfrak{F}_n)$

Beispiel 9.1 (Verzweigungsprozesse)

Es sei $\{Y_{nk} \mid n, k \in \mathbb{N}\}$ eine Familie von unabhängigen und identisch verteilten \mathbb{N}_0 -wertigen Zufallsvariablen.

$$P_j := P(Y_{nk} = j) \quad \forall j \in \mathbb{N}_0$$

Sei (Z_n) definiert durch

$$Z_1 := 1, \quad Z_{n+1} := \sum_{k=1}^{Z_n} Y_{nk} \quad \forall n \in \mathbb{N}_0 \text{ und } \mu := \sum_{k=1}^{\infty} kp_k < \infty$$

$$\mathfrak{F}_n = \sigma(\{Y_{mk} \mid k \in \mathbb{N}, m \leq n-1\})$$

Es gilt:

$$\begin{aligned} E[Z_{n+1} \mid \mathfrak{F}_n] &= E\left[\sum_{k=1}^{Z_n} Y_{nk} \mid \mathfrak{F}_n\right] \\ &= E\left[\sum_{l=0}^{\infty} \left(\sum_{k=1}^l Y_{nk}\right) \cdot \mathbf{1}_{\{Z_n=l\}} \mid \mathfrak{F}_n\right] \\ &= \sum_{l=0}^{\infty} \underbrace{E\left[\sum_{k=1}^l Y_{nk} \mid \mathfrak{F}_n\right]}_{=E[\sum_{k=1}^l Y_{nk}]} \cdot \mathbf{1}_{\{Z_n=l\}} \\ &= \sum_{l=0}^{\infty} l \cdot \mu \cdot \mathbf{1}_{\{Z_n=l\}} = \mu \cdot Z_n \end{aligned}$$

Sei $X_n := \frac{Z_n}{\mu^n} \implies (X_k)_{k \in \mathbb{N}}$ ist ein $(\mathfrak{F}_n)_{n \in \mathbb{N}}$ -Martingal.

Insbesondere gilt:

$$EZ_n = \mu^n \cdot EX_n = \mu^n EX_1 = \mu^{n-1} EZ_1 = \mu^{n-1} \quad (*)$$

$(X_n)_{n \in \mathbb{N}}$ ist L^1 -beschränkt, da $E|X_n| = EX_n = \frac{1}{\mu} \quad \forall n \in \mathbb{N}$.

Satz 9.1 $\implies \exists X_{\infty}$ mit $X_n \rightarrow X_{\infty}$ P -f.s. .

Falls $\mu < 1$: $\xrightarrow{(*)} P(Z_n \geq \epsilon) \rightarrow 0 \quad (n \rightarrow \infty) \implies X_{\infty} \equiv 0$

Falls $\mu = 1$: X_n ganzzahlig \implies Folge irgendwann konstant. Wenn $P_1 \neq 1 \implies X_{\infty} \equiv 0$

Falls $\mu > 1$: X_{∞} ist nicht degeneriert. $P(X_{\infty} = 0)$ ist Lösung von $g(z) = z$, wobei g erzeugende Funktion von Y ist.

Stichwortverzeichnis

- L^1 -beschränkt, 86
- L^p -Ungleichung, 72
- μ -Dichte, 19
- μ -Integral, 7, 10, 11
- μ -Nullmenge, 18
- μ -fast überall, 18
- μ -integrierbar
 - p -fach, 22
- μ -stetig, 19
- σ -Algebra
 - der τ -Vergangenheit, 74
 - Produkt-, 25
- d -dimensionale Normalverteilung, 58
- p -fach μ -integrierbar, 22

- abzählendes Maß, 6
- adaptiert, 71
- algebraische Induktion, 18

- bedingte Dichte, 67
- bedingter Erwartungswert, 61, 62, 66
- beschränkt
 - L^1 -, 86
 - L^p -, 73
- Bildmaß, 16
- Borel-Cantelli Lemma, 37

- charakteristische Funktion, 41
- charakteristische Funktion (Zufallsvektor), 57
- Continuous Mapping Theorem, 46

- Darstellungssatz von Skorohod, 45
- Dirac-Maß, 5

- Eindeutigkeitssatz für Maße, 6
- Einpunktmaß, 5
- Eintrittszeit, 74
- Elementarfunktion, 7

- Erlang-Verteilung, 34
- Erwartungswert
 - bedingt, 61, 66
 - Version des bedingten, 62
- Erwartungswert (Zufallsvektor), 57

- Faktorisierungssatz, 65
- Faltung, 34
- fast überall, 18
- Filtration, 71

- Gamma-Verteilung, 34
- gemeinsame Verteilung, 31
- gestoppter Prozess, 75
- Gumbelverteilung, 55

- Höldersche Ungleichung, 22

- Jensensche Ungleichung, 21

- Kern, 66
- Konvergenz
 - in Verteilung, 45
 - schwache, 45
- konvex, 21
- Koppelung, 66
- Kovarianzmatrix, 57

- Lebesgue-Maß, 6
- Lebesgue-Stieltjes-Maß, 6
- Lemma
 - Borel-Cantelli, 37
 - von Fatou, 15
- Lindeberg-Bedingung, 49

- Maß
 - Produkt-, 27
- Martingal, 71
- Sub-, 71

- Super-, 71
- Maß, 5
 - σ -endlich, 5
 - endlich, 5
 - Lebesgue-Stieltjes, 6
- Maß mit Dichte, 19
- maßdefinierende Funktion, 6
- Maßraum, 5
- Maßtransport, 16
- Minkowskische Ungleichung, 22
- Normalverteilung
 - d -dimensionale, 58
- Nullmenge, 18
- Optional Stopping Theorem, 77
- Ordnungsstatistik, 35
- OST, 77
- Produkt- σ -Algebra, 25
- Produktmaß, 27
- Projektion, 25
- Prozess
 - gestoppter, 75
- quasi-integrierbar, 11
- Randdichte, 34
- Satz
 - Faktorisierungs-, 65
 - Integration bezüglich des Bildmaßes, 17
 - Transformations-, 17, 33
 - Transformationssatz, 32
 - von der majorisierten Konvergenz, 15
 - von Doob, 72
 - von Helly, 47
 - von Lebesgue, 15
 - von Radon-Nikodym, 20
- schwache Konvergenz, 45
- Snell-Einhüllende, 80
- Stetigkeitssatz für charakteristische Funktionen, 48
- stochastisch unabhängig, 31
- stochastischer Prozess, 71
- Stoppzeit, 74
- straff, 47
- Submartingal, 71
- Submartingal-Ungleichung, 72
- Supermartingal, 71
- Theorem
 - Optional Stopping-, 77
- Transformationssatz, 17
- Übergangskern, 66
- unabhängig
 - stochastisch, 31
- Ungleichung
 - L^p -, 72
 - Höldersche, 22
 - Jensensche, 21
 - Minkowskische, 22
 - Submartingal-, 72
- Verteilung
 - Erlang-, 34
 - Gamma-, 34
 - gemeinsame, 31
 - Gumbel, 55
- Verteilungskonvergenz, 57
- Wahrscheinlichkeitsmaß
 - straffes, 47
- Zentraler Grenzwertsatz von Lindeberg-Lévy, 49
- Zufallsgröße, 7
- Zufallsvariable, 7
- Zylindermengen, 25